



Herramienta Soporte al Diagnóstico del Melanoma usando Imagenes Dermatoscópicas

Cristian Felipe Ocampo Blandón

Universidad Nacional de Colombia, Sede Manizales
Facultad de Ingeniería y Arquitectura
Departamento de Ingeniería Electrónica, Electrónica y Computación
Manizales, Colombia
2011

Herramienta Soporte al Diagnóstico del Melanoma usando Imágenes Dermatoscópicas

Cristian Felipe Ocampo Blandón

Tesis presentada como requisito parcial para optar al título de:
Magíster en Ingeniería - Automatización Industrial

Director:
Prof. Juan Carlos Riaño Rojas. Ph.D.

Línea de Investigación:
Procesamiento de Imágenes. Sistemas de diagnóstico automático
Grupo de Investigación:
PCM Computational Applications

Universidad Nacional de Colombia
Facultad de Ingeniería y Arquitectura
Departamento de Ingeniería Eléctrica, Electrónica y Computación
Manizales, Colombia
2011

A Support Tool for Melanoma Diagnosis by using Dermoscopy Images

Cristian Felipe Ocampo Blandón

A thesis presented for the degree of:
Master of Engineering - Industrial Automation

Supervisor:
Prof. Juan Carlos Riaño Rojas. Ph.D.

Research Areas:
Digital Image Processing, Automatic Diagnosis System
Research Group:
PCM Computational Applications

National University of Colombia
Faculty of Engineering and Architecture
Department of Electrical, Electronic and Computing Engineering
Manizales, Colombia
2011

A mi familia.

Agradecimientos

A cada uno de los integrantes de mi familia, que han hecho su mejor esfuerzo por colaborarme y entenderme. A Angélica Jiménez Muñoz por su paciencia, compresión y especialmente, por su entrega, apoyo y compañía desinteresada.

A mi tutor Juan Carlos R. R. y a la profesora Elisabeth R. P., que con su inmensa generosidad me ofrecieron sugerencias y recursos materiales, para el desarrollo de este proyecto.

Agradezco al equipo de investigación del posgrado en dermatología de la Universidad de Caldas por el soporte medico brindado.

A todas las personas que contribuyeron directa ó indirectamente al desarrollo y finalización de este proyecto.

El autor agradece a la Dirección de Investigaciones (DIMA) de la Universidad Nacional de Colombia, sede manizales, por la financiación del proyecto número 11659, titulado *Herramienta de Soporte al Diagnóstico del Melanoma usando Imágenes dermatoscópicas*, bajo el programa de **Apoyo a Tesis de Posgrado-DIMA 2010**.

Resumen

El Melanoma, catalogado como la forma más mortal de los canceres de piel (Carcinoma de células Basales, Carcinoma de células Escamosas y Melanoma), incrementa su incidencia a nivel mundial cada año. Después de diagnosticado, las posibilidades de supervivencia se reducen considerablemente. En sus etapas iniciales puede ser controlado por medio de la extirpación de la lesión, sin embargo, es fundamental descubrirlo tan pronto como sea posible. Para el análisis del melanoma han sido propuestos múltiples exámenes visuales; *Regla ABCD, Método de Menzies, Lista de los 3 y 7 puntos*, con los que se pretende detectar su presencia mediante la búsqueda exhaustiva de patrones asociados a malignidad. Esta tarea se ha vuelto uno de los retos cotidianos del dermatólogo.

Como instrumento para enfrentar las dificultades visuales, la dermatoscopía sobresale como una sencilla técnica de amplificación iluminada que ha demostrado su utilidad en la categorización de las proliferaciones melanocíticas, no obstante, su desempeño es insuficiente para la detección precisa de malignidad, reflejando valores de desempeño del [75-84] % cuando el examen es realizado por un dermatólogo experto.

En este trabajo se plantean las estrategias para el desarrollo de un sistema de diagnóstico automático del Melanoma por medio del empleo de imágenes capturadas con la técnica de dermatoscopía. Para el desarrollo del sistema se propone un esquema modular de cinco etapas: Adquisición, Pre-procesamiento, Segmentación, Extracción de Características y Clasificación. Como principales aportes, se desarrolló la sustitución de los vellos en la imagen mediante operaciones morfológicas, fueron propuestos dos métodos de manipulación del color para la corrección de contraste, un algoritmo robusto para la segmentación de imágenes y la integración de medidas locales para la caracterización de malignidad. El sistema propuesto cuantifica la presencia de tres características, específicamente: Patrón reticular atípico, asimetría de patrones y velo blanco-azulado. Como resultado de la clasificación de características con la técnica de máquinas de vectores de soporte, el sistema propuesto obtiene un desempeño del [90.62, 100] % para los valores de sensibilidad y especificidad.

Palabras clave: Dermatoscopía, Melanoma, Lista de los 3 puntos, diagnóstico asistido por computador, procesamiento de imágenes, svm.

Abstract

Melanoma, catalogued as the most mortal skin cancers (basal cell carcinoma, scamous cell carcinoma and melanoma), has increased its global incidence each year. After diagnosis, the survival possibilities are considerably reduced. In initial stages, the illness can be controlled by means of the lesion extirpation; nevertheless, it is crucial to detect the cancer as soon as possible. For melanoma analysis, several screening methods have been proposed (Menzies method, three and seven point checklist). With these methods, an exhaustive search of patterns associated to malignity is used for detecting illness presence. This task has become one of the current challenges of dermatologist.

As an instrument for tackling visual difficulties, dermoscopy has been considered as a simple illuminated amplification method for the melanocytic proliferation categorization. However, its performance is not high enough for the accuracy detection of malignity; showing performance values between 75 % and 84 %, when the test is carried out by an expert dermatologist. In this study, strategies for developing an automatic melanoma diagnosis system using dermoscopy images were proposed. For this issue, a modular scheme of five stages was implemented as follows: Acquisition, Preprocessing, Segmentation, Feature Extraction and Classification. The principal contributions were: The hair substitution in the image by means of morphological operations, enhancement contrast color methods, a robust image segmentation algorithm and finally, local measures integration for the malignity characterization.

The proposed system quantified the presence of three main features: Atypical reticular pattern, blue-white veil and pattern asymmetry. Performance of 90.62 % and 100 % for sensitivity and specificity were obtained by employing support vector machine classifier.

Palabras clave: Dermatoscopy, Malignant Melanoma, 3 Point Checklist, computer aided diagnosis, image processing, svm.

Contenido

Agradecimientos	IX
Resumen	XI
Contenido	XIV
Lista de símbolos	XVII
Lista de Figuras	XVIII
Lista de Tablas	XXI
1. Introducción	3
2. Marco Contextual	7
2.1. Factores de incidencia de los rayos UV	7
2.2. Melanoma	9
2.3. Procedimientos dermatológicos para la detección de melanoma	10
2.3.1. Regla ABCD	10
2.3.2. El Método de Menzies	12
2.3.3. La Lista de Verificación de los 7 Puntos	12
2.3.4. Lista de 3 puntos	13
2.4. Dermatoscopia	15
2.5. Sistemas de diagnóstico automático por computador	16
2.5.1. Antecedentes	16
2.5.2. Estado del Arte	16
2.6. Contextualización Técnica	19
2.6.1. Descripción del Mapa de color e Imágenes Indexadas	19
3. Preprocesamiento	21
3.1. Introducción	21
3.1.1. Estado del Arte	21
3.2. Método para la Eliminación de Vellos	23
3.3. Corrección de Contraste	28

3.4. Desarrollo e Implementación de los Métodos para la corrección de contraste	29
3.4.1. Compactación del Color	29
3.4.2. Proyección discriminante del Color	34
3.5. Marco Experimental	37
3.5.1. Bases de datos	37
3.5.2. Medidas de desempeño	37
3.5.3. Calculo de desempeño para los métodos de remoción de vello	38
3.5.4. Discusión y Resultados	39
3.6. Conclusiones	42
4. Segmentación	45
4.1. Introducción	45
4.1.1. Estado del Arte	45
4.2. Descripción general	46
4.2.1. Segmentación mediante la regresión del color	46
4.2.2. Ajuste del Mapa de color al modelo Gaussiano	49
4.3. Mejoramiento de la Segmentación mediante la detección de la región de interés (ROI)	51
4.3.1. Descripción del método para la detección ROI	52
4.4. Marco Experimental	57
4.4.1. Bases de datos	57
4.4.2. Medidas de desempeño	57
4.4.3. Discusión y Resultados	58
4.5. Conclusiones	61
5. Caracterización y Clasificación	63
5.1. Extracción de Características	65
5.1.1. Patrón Reticular	66
5.1.2. Velo Azul	67
5.1.3. Asimetría	68
5.2. Clasificación	70
5.3. Marco Experimental	70
5.3.1. Descripción del conjunto de datos	71
5.3.2. Medidas de desempeño	72
5.3.3. Experimentos de clasificación	72
5.3.4. Discusión y Resultados	75
5.4. Conclusiones	83
6. Conclusiones y Trabajo Futuro	85
6.1. Trabajos Futuros	87

A. Anexo: Protocolo de Adquisición	88
A.1. Elección de los Parámetros de la Cámara (<i>Canon PowerShot A2200</i>)	89
B. Anexo: Aproximación de Funciones Mediante Ajuste Polinomial Usando el Método Mínimos Cuadrados	91
C. Anexo: Descripción de las Características Empleadas	93
C.1. Características Relevantes Obtenidas en la etapa de Clasificación	94
D. Anexo: Publicaciones y Memorias de Eventos	95
Bibliografía	96

Lista de símbolos

Símbolo Término

\oplus	Operación Morfológica de dilatación.
$I_{n \times m}$	Imagen de un solo canal, con dimension de n filas y m columnas.
I^C	Complemento de la imagen I .
$A \bullet B$	Producto punto a punto de las imágenes A y B .
$BW(I)$	Binarización de la imagen I

Abreviaturas

Abreviatura Término

ANN	Red Neuronal Artificial.
DOG	Derivada ordinaria de la función de Gauss.
LMT	Arbol de Modelo Logístico
LOG	Laplacian of Gaussian.
KL	Karhunen-Loéve.
$K - nn$	K-Vecinos más cercanos.
MM	Melanoma Maligno.
PSL	Pigmented Skin Lesion.
ROI	Región de interés.
SVM	Máquinas de vectores de soporte.

Lista de Figuras

1-1.	Esquema General del Sistema de Diagnóstico Propuesto.	5
2-1.	Indice de Rayos UV actual sobre la superficie terrestre. Febrero 15 de 2011. .	8
2-2.	Imágenes con presencia de patrones relevantes, según la Regla ABCD. (a). Asimetría de patrones. (b). Borde Irregular. (c). Velo Azul. (d). Patrón Reticular.	11
2-3.	Dermatoscópio empleado para la adquisición de las imágenes.	15
2-4.	Matriz que posee los índices asociados al mapa de color, (Imagen Indexada).	20
3-1.	Esquema general del modulo de Preprocesamiento.	21
3-2.	(a). Imagen con presencia de vellos. (b). Propagación normal de un Vello sobre la región superficial de la imagen.	23
3-3.	(a). Perfil ideal de un vello. (b). Perfil de un vello en condiciones normales. (c). Kernel correspondiente a la Función DOG. (d). Convolución del vello ideal con el Kernel DOG. (e). Convolución de un vello normal con el Kernel DOG.	24
3-4.	Kernel DOG bidimensional, rotado en los ángulos principales (a). 0° . (b). 45° . (c). 90° . (d). 135°	25
3-5.	(a). Imagen dermatoscópica con presencia de vellos. (b). Imagen $R(x, y)$ resultante del procedimiento de detección de líneas oscuras. (c). Detección de las estructuras relevantes mediante umbralización. (d). Máscara M_k asociada a la dispersión de los vellos.	26
3-6.	(a). Imagen Original sin la presencia de los vellos identificados en la máscara M_k . (b). Representación de la superficie ocupada por los vellos S_a . (c). Imagen resultante del método de eliminación de vellos H_L	28
3-7.	(a). Imagen con un objeto de tonos rojos, I_r . (b). Dispersión espacial del color para I_r . (c). Imagen con objetos de tonos rojos y azules, I_{rb} . (d). Dispersión espacial del color para I_{rb}	30
3-8.	(a). Imagen dermatoscópica, I_d . (b) Dispersión espacial del color para I_d . .	30
3-9.	Estructura del método propuesto para la compactación del color.	31
3-10.	(a). Densidad del color. (b). Dispersión del mapa de color con la densidad correspondiente a cada punto.	32
3-11.	(a). Umbral que promueve la separación de los grupos $Thr = 0,2285$. (b). Agrupaciones relevantes.	33

3-12. Dispersión del color orientado a los centros de gravedad asociados a las agrupaciones de interés.	33
3-13. (a). Imagen final contrastada con $\alpha = 0,3$. (b). Dispersión del color final con $\alpha = 0,3$. (c). Imagen final contrastada con $\alpha = 1$. (b). Dispersión del color final con $\alpha = 1$	34
3-14. Consecuencia de la elección inapropiada de colores predominantes.	34
3-15. Esquema general para el desarrollo de la Proyección discriminante del color.	35
3-16. (a). Imagen dermatoscópica original. (b). Dispersión espacial del color para la imagen original. (c). Imagen obtenida mediante la proyección del color. (d). Dispersión espacial del color para la imagen mejorada.	36
3-17. (a). Identificación manual de los vellos sobre la imagen original, mediante la selección puntos. (b). Imagen binaria obtenida del procedimiento de identificación manual para la imagen original. (c). Identificación manual de los vellos sobre la imagen procesada, mediante la selección puntos. (d). Imagen binaria obtenida del procedimiento de identificación manual para la imagen procesada.	39
3-18. (a). Imagen dermatoscópica con presencia de vellos. (b). Máscara obtenida con el método inicialmente propuesto para la detección de vellos. (c). Imagen resultante del método propuesto para la eliminación de vellos. (d). Máscara obtenida con la modificación del método inicial para la detección de vellos. (e). Imagen resultante del método modificado para la eliminación de vellos. . .	40
3-19. (a). Imagen dermatoscópica con presencia de vellos. (b). Imagen obtenida con el método de eliminación de vellos propuesto en este trabajo. (c). Imagen obtenida mediante el método DullRazor. (d). Imagen resultante luego de aplicar la reconstrucción de las superficies ocupadas por los vellos.	41
4-1. Esquema general del modulo de Segmentación.	45
4-2. (a). Imagen dermatoscópica. (b). Dispersión del color.	47
4-3. (a). Proyección espacial a los canales $R - B$. (b). Proyección espacial a los canales $R - G$. (c). Proyección espacial a los canales $G - B$	47
4-4. Transformación del color que contribuye a la separación de los clusters. . . .	48
4-5. Reconocimiento del umbral que separa las clases (Piel y Lesión).	48
4-6. (a). Imagen resultante de eliminar los colores superiores al umbral. (b). Imagen segmentada.	49
4-7. (a). Imagen dermatoscópica. (b). Diagrama de dispersión del color. (c). Bordes detectados por el especialista.	49
4-8. Imagen segmentada manualmente, conservando las regiones asociadas a piel (a) y lesión (c). Diagramas de dispersión de los colores asociados a piel (b) y lesión (d).	50
4-9. (a). Proyección espacial de color en los canales $R - G$. (b). Ajuste gaussiano del color obtenido mediante la técnica de GMM	51

4-10. (a). Imagen resultante de aplicar clustering mediante <i>GMM</i> . (b). Imagen segmentada.	51
4-11. (a). Imagen normal con presencia de objetos que perjudican la etapa de segmentación. (b). Detección manual de la región de interés.	52
4-12. (a). Imagen dermatoscópica luego de ser empleado el modulo de preprocesamiento propuesto. (b). Imagen procesada en escala de grises.	53
4-13. Dispersión de la lesión melanocítica tanto por columnas como por filas.	54
4-14. Aproximación parabólica de la señal original, tanto por filas como por columnas.	55
4-15. Resultado parcial del procedimiento para resaltar la región de interés por filas y columnas.	55
4-16. Resultado final del procedimiento para identificas la región de interés, por filas y columnas.	56
4-17. (a). Máscara binaria que resalta la región de interés ROI. (b). Imagen original restringida a la Máscara ROI. (c). Imagen asociada a la región ROI.	57
4-18. (a). Imagen dermatoscópica. (b). Efecto tipo tunel, resultado de conservar colores presentes en la lesión. (c). Mascara asociada a la region de interes. (d). Imagen segmentada final producto de la intersección con la imagen segmentada y la mascara ROI.	59
5-1. (a). Imagen dermatoscópica. (b). Máscara binaria asociada a la lesión melanocítica, obtenida mediante el método de segmentación propuesto. (c). Imagen RGB asociada a la máscara binaria obtenida en la etapa de segmentación.	65
5-2. Esquema general del procedimiento diseñado para la detección del patrón reticular atípico.	66
5-3. Secuencia de imágenes obtenidas mediante la aplicación del procedimiento de detección del patrón reticular: (a). Imagen original con presencia de factor reticular, presentada en escala de grises. (b). Imagen resultante IF_{log} luego de aplicar el Filtro LOG. (c). Imagen IF_{log} umbralizada. (d). Imagen obtenida mediante la operación morfológica de erosión. (e) Objetos asociados a la presencia del factor reticular. (f). Orificios ó islas finales. (g). Factor reticular superpuesto sobre la imagen de entrada.	67
5-4. Secuencia de imágenes obtenidas con el procedimiento para la detección de velo azul: (a). Imagen dermatoscópica que presenta velo azul en su superficie. (b). Imagen obtenida luego de la normalización del color. (c). Regiones que poseen todos los colores pertenecientes al intervalo mencionado. (d). Imagen que indica la detección del velo azul.	68
5-5. (a). Imagen binaria obtenida mediante el procedimiento de segmentación propuesto. (b). Curvatura asociada al perímetro de la imagen binaria. (c). Puntos extremos relacionados con el ángulo θ	69

5-6. (a). Desempeño de clasificación para el método $MSV - RBF$. (b). Desempeño de clasificación para el método $MSV - RBF$	77
5-7. (a). Desempeño de clasificación para el MSV Polinomial. (b). Desempeño de clasificación para el método Knn	78
5-8. Diagrama del aporte informativo de cada vector propio.	81
5-9. Dispersión de los datos proyectados con LDA en el espacio 3D.	82

Lista de Tablas

2-1. Regla ABCD.	11
2-2. Método de Menzies.	12
2-3. Lista de verificación de los 7 Puntos.	13
2-4. Definición de los criterios dermatoscópicos para la lista de los tres puntos.	13
2-5. Desempeño de los Procedimientos de diagnóstico en términos de la Sensibilidad y Especificidad.	14
2-6. Sistemas de diagnóstico asistido por computador.	18
3-1. Valores usados para el cálculo del desempeño.	37
3-2. Desempeño general de los métodos utilizados para la remoción de vellos.	40
3-3. Desempeño de los métodos para el realce de contraste.	42
4-1. Desempeño del método propuesto para la detección ROI.	58
4-2. Desempeño de los métodos de segmentación.	60
5-1. Desempeño de los Métodos de Clasificación.	75
5-2. Desempeño del clasificador SVM-RBF para el conjunto de datos formado con las características originales más relevantes.	79
5-3. Desempeño del clasificador SVM-RBF para el conjunto de datos reducido en dimensión, mediante PCA.	81
5-4. Desempeño del clasificador SVM-RBF para el conjunto de datos reducido en dimensión, mediante LDA.	82
A-1. Configuración de la Cámara	89
A-2. Desempeños de Segmentación de las imágenes obtenidas mediante la variación de los parámetros de la cámara.	90

1. Introducción

Las condiciones climatológicas actuales como el calentamiento global, la excesiva exposición solar sin precaución y factores adversos asociados a la producción humana, fomentan la aparición de desordenes y enfermedades de la piel, en particular el cáncer ó Melanoma. El Melanoma se ha consolidado como una de las enfermedades cutáneas con mayor crecimiento en este siglo; actualmente posee una incidencia global de 132.000 casos nuevos por año, lo que hace merito para denominarlo como el cáncer más letal de todos los de su tipo [74]. En Colombia, se calcula que anualmente se pueden desarrollar aproximadamente 1.000 casos nuevos de melanoma y cerca de 220 personas mueren debido a esta enfermedad [26].

El Melanoma al ser un cáncer que se manifiesta de manera silenciosa con una dispersión amplia y profunda alrededor de la lesión, en la mayoría de los casos imposibilita establecer una acción oportuna para combatirlo. Así, el diagnóstico temprano del Melanoma ofrece suficientes condiciones para elevar considerablemente las expectativas de vida. Sin embargo, aunque existen métodos tradicionales y automáticos, todavía no existe un medio ó técnica estandarizada que sea rápida, efectiva y poco invasiva para la detección certera de este mal. Por la ausencia de un instrumento práctico y confiable que aporte significativamente en la tarea de diagnóstico, la ocurrencia en nuevos casos de melanoma continuará incrementando temporalmente poniéndose en riesgo la calidad de vida humana. No obstante, los desarrollos más prometedores para contrarrestar este problema son los realizados en torno a los sistemas automáticos [59].

Como tratamiento para el control del melanoma existen métodos que terminan siendo perjudiciales para la salud del paciente, al producir daños colaterales, especialmente la quimioterapia.

Por ser necesaria la continua inspección acerca de la evolución de estas lesiones, existen técnicas tradicionales semi-cuantitativas que simplifican el diagnóstico. Entre los procedimientos más populares empleados por los dermatólogos se encuentran *la Regla ABCD, Método de Menzies y Lista de los 7 Puntos*. Son métodos de examinación desarrollados para determinar si la lesión requiere de un análisis profundo por parte de un dermatólogo experimentado. Adicionalmente, buscando reducir la subjetividad implícita en el análisis, lo cual permite que sean utilizados por dermatólogos inexpertos. Las características de búsqueda comunes para los procedimientos previos son: Patrón reticular atípico, velo blanco-azulado, asimetría de patrones, color y borde. De acuerdo al criterio del especialista, es asignado un punaje de dispersión específico para cada patrón. Aunque los procedimientos son populares por su practicidad su desempeño no es suficiente, por lo cual, los especialistas decidieron integrar

una técnica que permitiera ampliamente la visualización de la lesión, con lo cual se obtuvo un incremento notable en la precisión diagnóstica. Esa técnica es llamada dermatoscopía o Microscopía de Epiluminiscencia (ELM), procedimiento diagnóstico no invasivo que permite observar estructuras de la dermis y epidermis mediante un sistema de amplificación de la imagen acoplado a un sistema de iluminación que permite superar la distorsión producida por la reflexión y refracción de la superficie cutánea, mostrando así patrones de pigmento y de vascularización invisibles al ojo desnudo.

A pesar de los esfuerzos tenidos al incluir nuevas técnicas en el momento de evaluación no se ha logrado obtener resultados elevados. Particularmente atribuibles a descuidos accidentales en la búsqueda minuciosa de un patrón, al agotamiento físico a causa del exhaustivo análisis, a las adversidades del medio, especialmente falta de contraste, entre otros. Por tal motivo los sistemas de diagnóstico asistido por computador son una opción oportuna para validar la decisión del especialista, contribuir en la tarea de diagnóstico, disminuir el tiempo de análisis por imagen, que conduce a la optimización en la distribución de las tareas médicas. El propósito de estos métodos no es reemplazar al experto, es ofrecer un aporte apropiado que permita corroborar y argumentar la decisión que el dermatólogo con sus conocimientos y experiencia ha dictaminado.

Algunos grupos de investigación han hecho su aporte en la detección automática del Melanoma aplicando métodos clásicos o de desarrollo reciente en la implementación del sistema, en general conservando una estructura modular de la siguiente forma: Detección (Identificación del área afectada), Descripción (Extracción de características asociadas a malignidad) y Decisión (Diagnóstico de la lesión, Benigna o Melanoma) [74, 47, 46]. El empleo de herramientas de este tipo ha mostrado la efectividad en los resultados siendo tan fiables o significativamente superiores a los obtenidos por un especialista, [37].

Con base en lo anterior, como objetivo general de esta tesis se propone desarrollar una herramienta que sirve al diagnóstico automático del melanoma, integrando el enfoque tradicional de los procedimientos de examinación manual con un sistema dermatoscópico que contribuye a generar una imagen digital de alta calidad. De este modo el sistema podrá ser utilizado para realizar un seguimiento periódico de la lesión, así mismo, reducir el impacto del cáncer de piel y las nefastas consecuencias sobre las personas que la padecen.

Luego de identificar las deficiencias de múltiples sistemas diagnósticos reportados en la literatura, entre las que pueden ser consideradas principales debilidades se encuentran: la falta de un protocolo de adquisición serio [78, 48, 74], la ausencia de una etapa de pre-procesamiento sólida para la eliminación o reducción de ruido (Particularmente Vellosidad, Poros y Burbujas), [78] y el no incluir medidas objetivas para la caracterización de las lesiones [78, 56]. De no corregir las debilidades, fácilmente se puede modificar la confiabilidad del diagnóstico.

Con el ánimo de corregir las anomalías de los sistemas actuales y de implementar un sistema eficiente, se propone integrar procedimientos seleccionados minuciosamente de la bibliografía reciente y procedimientos propuestos que permitan el procesamiento efectivo de imágenes con características de adquisición desconocidas, pero que cumplan con ciertas condiciones

de detalle.

Para el desarrollo de la herramienta propuesta, se propone el esquema modular mostrado en la figura 1-1.

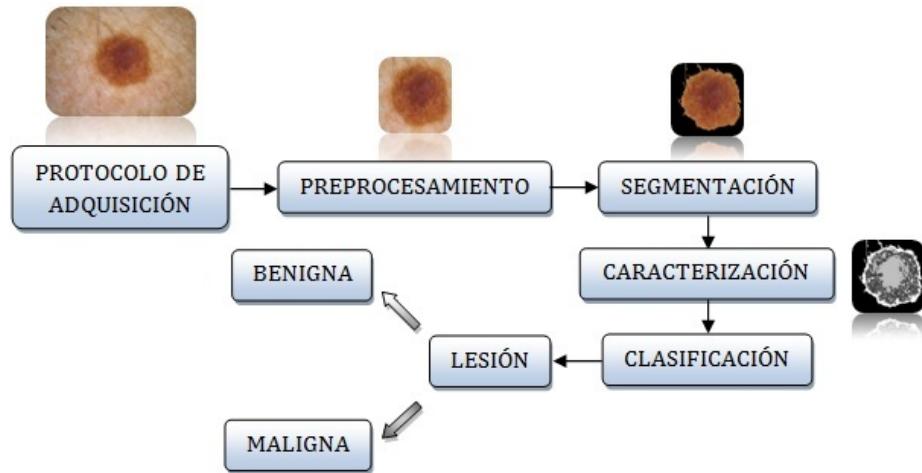


Figura 1-1.: Esquema General del Sistema de Diagnóstico Propuesto.

Para la implementación robusta del sistema se conformó un banco de imágenes dermatoscópicas tanto de tejidos normales como anormales, las cuales pudieran ser empleadas para el entrenamiento y evaluación del sistema en condiciones reales. Las imágenes fueron tomadas a personas pertenecientes a la zona Cafetera Colombiana. Además, se capturaron de tal forma que presentaran características visuales mínimamente variables; tales como, alto contraste en el área de interés y elevado detalle en las características presentes. Como consecuencia se reduce el error de crecimiento exponencial en las etapas sucesivas. Error que básicamente es introducido por el inadecuado procedimiento de digitalización de las imágenes. Por consiguiente, la influencia negativa del procedimiento de adquisición en la detección automática del Melanoma y sus patrones relevantes será mínima.

Para tal fin, integrando el modulo inicial, se sitúa el protocolo de adquisición de imágenes dermatoscópicas, especialmente diseñado para obtener imágenes que satisfagan las exigencias del sistema y esencialmente para que conserven alta calidad en nitidez. En la metodología de adquisición, para el desarrollo del protocolo de captura se prestó especial atención a la iluminación de la zona de interés (Lesión y Patrones Melanocíticos) buscando que los patrones clínicos fueran suficientemente contrastados. Adicionalmente, se manipularon las condiciones de humedad sobre la lesión, dimensión de la imagen, distancia con el foco y por último, presión superficial. El sistema de adquisición de imágenes está conformado por un dermatoscópio *Dermlite II Pro* unido a una cámara *Canon PowerShot A2200* configurada especialmente para la captura de imágenes dermatoscópicas.

Los parámetros óptimos de la cámara se establecieron mediante la captura de una imagen por cada alternativa disponible en la cámara, segmentado dichas imágenes y escogiendo los

parámetros respecto al mejor desempeño de segmentación. Como resultado, se obtuvieron 108 imágenes que fueron segmentadas mediante el Método de Otsu, ver Anexo A.

Cada uno de los módulos desde la etapa de Preprocesamiento, corresponden a un capítulo específico de este trabajo donde serán comentados con mayor detalle.

El modulo de Preprocesamiento (Capítulo 3), fue integrado al sistema general con el propósito de eliminar el ruido sobre la imagen capturada, especialmente, vello y poros de la piel. En el capítulo 4 se describen los procesos de segmentación propuestos, los cuales son los aportes principales de esta investigación. En el capítulo 5 se realiza el proceso de caracterización de los patrones melanocíticos buscando eliminar la subjetividad de los criterios clínicos, adicionalmente, se analiza el proceso de clasificación de las imágenes dermatoscópicas. Finalmente, el ultimo capítulo describe las principales conclusiones y trabajos hacia el futuro de este estudio.

2. Marco Contextual

El incremento de temperatura actual, el caos medioambiental y factores relacionados al desarrollo y producción humana generan las condiciones óptimas para que la radiación UV ingrese sin mayor dificultad a través de la capa atmosférica igualmente debilitada a causa de la aparición notable del efecto invernadero. Modelos computacionales predicen que un 10 % en la reducción de la estratosfera puede provocar aproximadamente 300.000 nuevos casos de no-melanoma y 4.500 casos de melanoma a nivel mundial cada año [76]. En vista que Colombia se encuentra en una región geográfica la cual posee un índice de rayos UV elevado, la población Colombiana es vulnerable de sufrir las lesiones causadas por las constantes manifestaciones de estos rayos. Se calcula que anualmente se podrían desarrollar más de 1.000 casos nuevos de melanoma, provocando que aproximadamente 220 personas mueran de esta enfermedad [26]. Cifras alarmantes que no pueden pasar desapercibidas.

La Radiación UV se encuentra dividida en tres bandas de su longitud de onda característica, radiación UVA, UVB y UVC. Donde la exposición a la banda UVB; caracterizada por pertenecer a las longitudes de onda superiores a 280nm e inferiores a 315nm, representa la banda que provoca el impacto más nocivo sobre la salud humana, animal y de todo organismo viviente. La Radiación UV, aunque esencial para la producción de vitamina D es causante principal del desarrollo de múltiples desordenes clínicos dermatológicos. Los cuales contribuyen a la aparición de lesiones minúsculas que fácilmente pasan desapercibidas y sin atención adecuada, evolucionan en uno de los cánceres más comunes de este siglo, el Melanoma o Cáncer de piel. El Melanoma es una patología a la cual todo ser vivo está en riesgo de poseer por una exposición solar frecuente, directa y sin precaución adecuada.

2.1. Factores de incidencia de los rayos UV

Estudios realizados por la Organización Mundial de la Salud, sugieren que el índice de radiación UV se modifica con respecto a las características geográficas y medioambientales según la región, incrementando con los siguientes factores:

- Cuando el sol se encuentra ubicado perpendicularmente sobre la tierra y en temporadas específicas del año, especialmente en verano.
- Cercanía con la línea ecuatorial.

- En días despejados. Incluso en días nublados, básicamente, por la dispersión de los rayos UV a causa de la reflexión de las moléculas de agua y finas partículas localizadas en la atmósfera.
- Altitud, con una variación del 10-12 % por cada kilómetro (En relación al mar) recorrido.
- Variación ó reducción de la capa de ozono en las temporadas del año.
- Reflexión de los suelos.

Aunque las personas de tez blanca son las más propensas a padecer cáncer de piel, nadie está exento de sufrirlo, pues es en gran porcentaje de la superficie terrestre donde los rayos UV son altamente dañinos para el humano, especialmente en la región cercana a la línea ecuatorial, como se muestra en la figura 2-1, la cual indica la variación actual de los rayos UV sobre la tierra. Imagen adquirida con el satélite SCIAMACHY-KNMI y tomada de la Agencia de Estudios Aeroespaciales - Holanda¹.

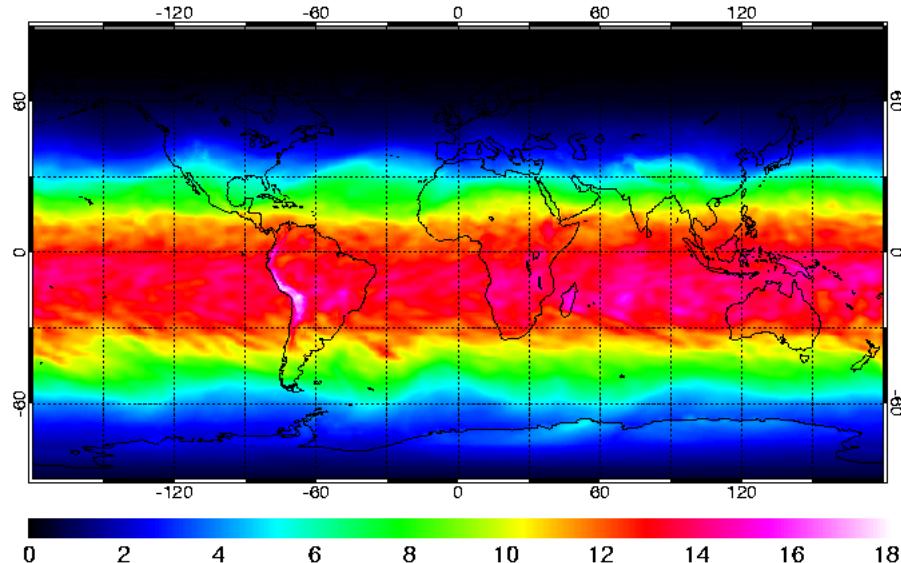


Figura 2-1.: Índice de Rayos UV actual sobre la superficie terrestre. Febrero 15 de 2011.

El Índice de rayos ultravioleta solar mundial (IUV) es una medida de la intensidad de la radiación UV solar en la superficie terrestre. El IUV posee magnitudes superiores a cero, en una escala que inicia con el nivel de exposición bajo ($IUV < 2$), moderado ($3 \leq IUV \leq 5$), alto ($6 \leq IUV \leq 7$), muy alto ($8 \leq IUV \leq 10$) y extremadamente alto ($IUV > 11$). Específicamente, Colombia está entre los tres países que posee los índices de radiación UV más elevados a nivel mundial [34], superando valores del 11 IUV. Según la tabla de categorías

¹<http://www.temis.nl/>, Imagen Capturada: Febrero 15 de 2011.

de exposición a la radiación UV proporcionada por la *OMS*, índices superiores a este indican que Colombia sufre una exposición extremadamente alta y cuanto más alto es el indicador, mayor es la probabilidad de adquirir lesiones cutáneas y oculares, y a su vez, más rápido es su aparición y desarrollo [77].

Debido a la fuerte influencia de la Radiación UV en la generación de lesiones cutáneas y a la elevada razón de muertes como consecuencias de estas, los dermatólogos enfocan su interés en desarrollar estrategias para detener o reducir el impacto, partiendo de estrategias de prevención ó sencillamente con el frecuente y exhaustivo análisis de lesiones pigmentadas aparentemente alarmantes, pues el melanoma o cáncer de piel es posible de controlar si ha sido diagnosticado prematuramente.

2.2. Melanoma

Dentro de las proliferaciones melanocíticas cutáneas se encuentran lesiones comunes, como los Nevus Melanocíticos (lunares comunes adquiridos), que en gran proporción los seres humanos poseemos, y el Melanoma. El Melanoma es la formación patológica de un tejido maligno cuyos componentes sustituyen los tejidos normales con un comportamiento biológico particularmente agresivo, al punto de constituir una de las principales causas de muerte por enfermedad cutánea [85].

El cáncer de piel se caracteriza por ser una enfermedad silenciosa, son frecuentes los casos de personas que adquirieron la lesión Melanocítica que sin notar la evolución de la enfermedad, al momento de detectarlo es prácticamente imposible combatirlo. Adicional al factor solar, dentro de los posibles causantes de esta patología también se encuentra el aporte genético, la exposición a radiación artificial ó el uso periódico de cabinas de bronceado.

El cáncer de piel usualmente es indoloro, se revela con la generación de un tumor luego del crecimiento descontrolado de las células de la piel, reacomodándose desde la capa mas externa de la epidermis hacia adentro o viceversa. Dependiendo del sentido en el que se concentra el tejido dañino, se adquiere un nivel de amenaza diferente. En caso de ser tumor maligno se pueden afectar órganos aledaños a la lesión, algo que no ocurre generalmente con el comportamiento de un tumor benigno.

Los síntomas de poseer cáncer de piel se reconocen por el abultamiento o sangrado repentino de la lesión y enrojecimiento o generación de costra. Luego de su diagnóstico y previamente establecido el carácter de la lesión, la zona puede ser tratada mediante una serie de procedimientos quirúrgicos en los que retiran la lesión de la región afectada [54]. Estas prácticas ocasionalmente resultan incómodas, dolorosas o antiestéticas para el paciente.

La tarea de diagnóstico especialista comúnmente se realiza bajo la vulnerabilidad a factores asociados al entorno visual que podrían provocar la imprecisión del análisis. Para identificar la presencia de melanoma se inspeccionan patrones específicos sobre la lesión cutánea que sugiere la atención del especialista, en vista de ser un procedimiento tan serio y minucioso el proceso se torna extenuante. Para el diagnóstico del melanoma, también se encuentra el

análisis del tejido maligno luego de ser extraído por medios quirúrgicos de la región afectada, lo que comúnmente se denomina biopsia, [72, 33].

2.3. Procedimientos dermatológicos para la detección de melanoma

Con base en el significado histológico y en la frecuencia de aparición de cada estructura sobre las lesiones melanocíticas ó tejidos sospechosos, se ha concluido que los patrones estrechamente asociados a patologías melanocíticas dañinas son: Retículo pigmentado prominente o atípico, puntos y glóbulos irregulares, proyecciones irregulares, velo azul-gris ó azul-blanquecino, áreas desestructuradas, estructuras de regresión, estructuras vasculares [9].

En la práctica, no todos los especialistas están de acuerdo con incluir las características previas, por lo cual son diversos los procedimientos de diagnóstico en los que se consideran nuevas características o se eliminan otras. Además, los nuevos procedimientos son diseñados para evitar al máximo la influencia de la experiencia sobre el diagnóstico, no obstante, los primeros métodos requerían de amplio conocimiento empírico para ser utilizados exitosamente. De ellos, el método más popular se conoce como *Análisis de Patrones*, enfoque dermatoscópico clásico para el diagnóstico de lesiones pigmentadas de la piel, caracterizado por ofrecer un diagnóstico basado en un análisis cualitativo y apoyado en la evaluación subjetiva de múltiples criterios dermatoscópicos que requieren conocimiento especial para ser identificados con suficiente seguridad [94]. Con lo cual *Análisis de Patrones*, es complejo de aplicar y es empleado principalmente por especialistas experimentados.

En el año 2000, se promovió la organización de una reunión virtual llamada *The 2th Consensus Net Meeting on Dermoscopy*, con la que se pretendió refinar la terminología dermatoscópica, evaluar las diferentes estructuras dermatoscópicas de interés, así como los métodos diagnósticos más notables [9, 49, 93]. Los métodos diagnósticos evaluados fueron: Análisis de Patrones, Regla ABCD, Método de Argentino y Lista de verificación de los 7 puntos. A continuación se ofrece una descripción más amplia de cada uno de ellos.

2.3.1. Regla ABCD

Método de diagnóstico semi-cuantitativo, se basa en la asignación de un puntaje relacionado a la propagación de los patrones relevantes sobre la lesión. Estableciendo como patrones decisivos: Asimetría, Bordes, múltiples Colores y estructuras Dermatoscópicas [84].

- **Asimetría (A):** Patrón generado por el crecimiento descontrolado de la lesión, debido a mayores concentraciones en diferentes regiones el perímetro de la lesión tiende a poseer una forma irregular, ver figura 2.2(a).
- **Borde (B):** Las lesiones melanocíticas poseen bordes abruptos en sus extremos. Las lesiones benignas suelen tener bordes que se desvanecen suavemente. Ver figura 2.2(b).

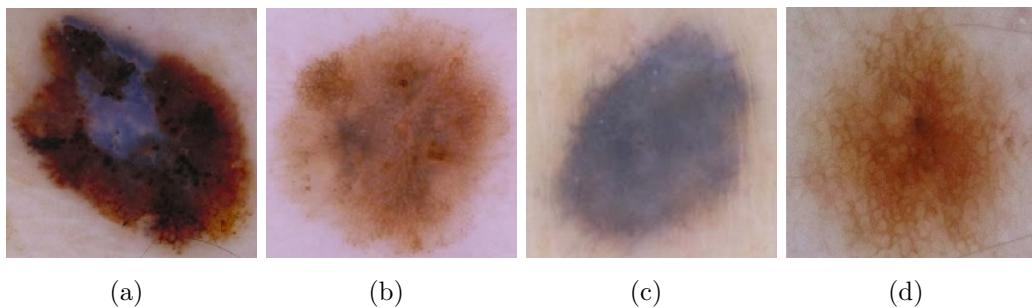


Figura 2-2.: Imágenes con presencia de patrones relevantes, según la Regla ABCD. (a). Asimetría de patrones. (b). Borde Irregular. (c). Velo Azul. (d). Patrón Reticular.

- **Color (C):** Relacionado al exceso de melanina bajo la superficie del tumor, provocando un color diferente a una concentración diferente sobre una región específica [82], figura 2.2(c).
- **Estructuras Dermatoscopicas (D):** Se refiere a un conjunto de patrones que indican el grado de malignidad de la lesión, ver figura 2.2(d).
 1. Ramificaciones.
 2. Pigmentación Reticular: Consiste en una conexión de líneas entrecruzadas que provocan la generación de huecos, regulares o irregulares. Las líneas indican mayor cantidad de melanina en esa región.
 3. Ausencia de estructuras ó Homogeneidad
 4. Puntos y glóbulos.

En la Tabla 2-1, se muestran los índices que pueden ser asignados a cada patrón. Al establecer un factor de peso apropiado, luego son empleados para calcular el puntaje dermatoscópico total TDS, que es la variable que indica el tipo de malignidad de la lesión y corresponde a:

$$TDS : 1,3(A) + 0,1(B) + 0,5(C) + 0,5(D) \quad (2-1)$$

Tabla 2-1.: Regla ABCD.

Patrón	Posibles Índices	Factor de Peso
Asimetría (A)	[0-2]	1.3
Bordes (B)	[0-8]	0.1
Color (C)	[1-6]	0.5
Estructuras Dermatoscópicas (D)	[1-5]	0.5
Benigna	Sospechosa	Altamente Sospechosa
$TDS < 4,75$	$4,8 < TDS \leq 5,45$	$TDS > 5,45$

2.3.2. El Método de Menzies

Desarrollado para simplificar el diagnóstico de Melanoma y superar la inexperiencia por parte de principiantes. Con el fin de evitar errores asociados a la experiencia implícita en la asignación del puntaje, el método se enfoca en identificar la presencia de un conjunto de estructuras exclusivas del melanoma maligno, en caso de encontrarse tales características el diagnóstico será positivo, por el contrario, si solo se encuentran las dos características asociadas a pigmentación normal, el diagnóstico será negativo de poseer Melanoma Maligno (*MM*). La Tabla 2-2 ofrece una descripción más detallada del diagnóstico asociado a la presencia de los patrones a considerar mediante este método [64].

Tabla 2-2.: Método de Menzies.

Diagnóstico	Características
Benigno	Simetría de Patrones Un color
Maligno	Asimetría de Patrones Más de un Color Existencia de uno o los nueve patrones positivos: 1. Velo Blanco-Azul. 2. Varios puntos cafés. 3. Pseudópodos. 4. Distribución radial. 5. Despigmentación tipo cicatriz. 6. Puntos negros periféricos. 7. Múltiples colores (5-6). 8. Múltiples puntos de color Azul/Gris. 9. Amplio pigmento Reticular.

2.3.3. La Lista de Verificación de los 7 Puntos

De manera similar al procedimiento previo y con menos características a inspeccionar sobre la imagen, este método jerarquiza los patrones que indican la existencia de melanoma sobre la lesión. Para tal fin, el procedimiento incluye características que son asociadas al Melanoma Maligno con un grado de incidencia específico. A las características especialmente relacionadas con el Melanoma se las llama de Mayor Criterio y a las menos similares se les llama características de Menor Criterio. A un criterio más elevado sobre la lesión, se le asigna un puntaje superior [8], ver Tabla 2-3.

Para una descripción más profunda de los patrones relevantes y su correlación histológica, consultar [14, 49, 93].

Tabla 2-3.: Lista de verificación de los 7 Puntos.

Criterio	Características	Puntaje ρ_i
Mayor	Pigmento Reticular atípico.	2
	Patrón vascular atípico.	2
	Velo Azul-Blanquecino.	2
Menor	Líneas Irregulares.	1
	Pigmentación Irregular.	1
	Puntos Irregulares.	1
	Áreas de Regresión.	1
Melanoma	No Melanoma	
$\sum \rho_i \geq 3$	$\sum \rho_i < 3$	

2.3.4. Lista de 3 puntos

Entre los algoritmos de diagnóstico visual la lista de los tres puntos podría clasificarse como el más simple. Está basado en la evaluación de solo tres criterios dermatoscópicos, entre ellos asimetría, patrón reticular atípico y por ultimo estructuras blanco-azuladas. En la Tabla 2-4, se encuentra la definición de cada criterio diagnóstico. La lesión pigmentada de la piel se define sospechosa al verificar la presencia de dos o tres criterios.

En [45] se realizó un estudio preliminar donde fue evaluado el desempeño de la lista de verificación de los 3 puntos, concluyendo que este procedimiento diagnóstico permite que los inexpertos obtengan valores de sensibilidad comparables a los obtenidos por los expertos, lo cual es ratificado en [94]. También fue evaluado el método con respecto al diagnóstico conseguido por un grupo de voluntarios, dentro de los que se incluían personas con profesiones asociadas a la dermatología y diferentes. En ese estudio tenían como objetivo reevaluar los resultados iniciales con un gran número de observadores independientemente de la profesión y experiencia en dermatoscopía. Como resultado, concluyen que este método es una herramienta simple, precisa, reproducible y posible de utilizar para el diagnóstico del cáncer de piel.

Tabla 2-4.: Definición de los criterios dermatoscópicos para la lista de los tres puntos.

Lista de los 3 Puntos	Definición
Asimetría	Asimetría de color y estructura en uno o dos ejes perpendiculares
Retículo Atípico	Retículo pigmentado con orificios irregulares y líneas gruesas.
Estructuras blanco azuladas	Cualquier tipo de coloración azulada, blanquecina o ambas.

Los algoritmos previamente mencionados han sido desarrollados no solo para reducir el impacto del conocimiento empírico que podría conducir al conflicto de opiniones entre especialistas, sino también, para reducir la complejidad del procedimiento de diagnóstico comúnmente aceptado por los dermatólogos experimentados, *Análisis de Patrones*.

Aunque existen múltiples reportes bibliográficos exponiendo las medidas de desempeño general de los algoritmos de diagnóstico populares, no es posible establecer con exactitud su precisión real, en vista de la variabilidad de los datos mostrados por cada investigación individual, ya sea por las estrategias de adquisición de las imágenes o sencillamente por el número de imágenes empleadas en el diagnóstico. Debido a la variabilidad de los experimentos es impropio inferir el comportamiento general de un método específico, aun más cuando se considera exclusivamente una pequeña muestra de imágenes. A pesar de lo anterior, en la Tabla 2-5, se muestran los desempeños de los algoritmos de diagnóstico comentados en la sección 2.3. Todos los resultados excepto el último fueron obtenidos en el encuentro de dermatoscopía realizado el año 2000 y se podría considerar que son los reportes más serios, en vista que el evento agrupo múltiples dermatólogos expertos enfocados en el mismo análisis.

Tabla 2-5.: Desempeño de los Procedimientos de diagnóstico en términos de la Sensibilidad y Especificidad.

Algoritmo de Diagnóstico	Desempeño	
	Sensibilidad %	Especificidad %
Análisis de Patrones, [93].	83.7	83.4
Regla ABCD, [93].	82.6	70
Lista de los 7 puntos, [93].	83.6	71.1
Método de Menzies, [93].	85.7	71.1
Lista de los 3 puntos, [94].	91	71.9

Si bien todos métodos, según la Tabla 2-5, poseen valores muy similares, actualmente continua la disputa por establecer que método se desempeña de manera óptima. Y aunque, la lista de los 3 puntos no fue incluido en el consenso virtual, en [38, 94] corroboran que es un procedimiento superior a los métodos semejantes, argumentando que este procedimiento de diagnóstico clasificó exitosamente todos los melanomas incluidos en las pruebas, permite a dermatólogos inexpertos obtener altos valores de precisión en el diagnóstico y puede ser llevado a la práctica sin mayores tropiezos. Por el contrario, los métodos: Análisis de patrones, lista de los 7 puntos y Regla ABCD, son dependientes de la experiencia y por consiguiente, propensos a resultados incorrectos cuando son empleados por personal no capacitado [58]. Es por tal razón y en particular por la aplicabilidad, sencillez y la baja dependencia con la experiencia, que se emplea **La lista de los 3 Puntos** como el procedimiento de evaluación que ofrecerá el criterio diagnóstico en el presente trabajo.

2.4. Dermatoscopía

Con el objetivo de incrementar el desempeño del análisis especialista comúnmente se emplean dispositivos que aumentan la dimensión de la lesión, ofreciendo la visualización de estructuras relevantes con un elevado nivel de detalle. La Dermatoscopía como parte de esas herramientas ofrece varias ventajas en relación a otras técnicas de análisis dermatológico, especialmente al diagnóstico a ojo desnudo [51] ó incluso a técnicas de adquisición de imágenes controladas, donde es frecuente el empleo de aceite de inmersión sobre la lesión, filtros especiales u otros procedimientos que buscan mejorar la nitidez de las estructuras pigmentadas. La Dermatoscopía también llamada Microscopía de Epiluminiscencia (*ELM*), es una sencilla técnica diagnóstica de amplificación iluminada que ha demostrado su utilidad en la categorización de proliferaciones melanocíticas, permitiendo la clasificación de estructuras malignas con facilidad e incrementando la sensibilidad en el diagnóstico especialista de 10 % a 27 % [78]. Dentro de las ventajas que ofrece la Dermatoscopía, se encuentran:

- Superior nitidez de la zona de interés.
- Técnica diagnóstica no invasiva.
- Disminución de biopsias innecesarias.
- Posible seguimiento dermatoscópico de lesiones sospechosas.

El dermatoscópio es un dispositivo que posee un lente óptico con un factor de amplificación de **10x**, además de un juego de leds de polarización cruzada y lineal, que en conjunto generan 32 leds apropiadamente distribuidos, Figura 2-3. El modo de polarización lineal provoca que se ilumine la parte superficial de la lesión, por el contrario la polarización cruzada supera el reflejo provocado por la epidermis, definiendo estructuras pigmentadas profundas y nítidas [29]. Del acople del dermatoscópio a una cámara digital, su pueden capturar las imágenes dermatoscópicas ó también llamadas imágenes melanocíticas.



Figura 2-3.: Dermatoscopio empleado para la adquisición de las imágenes.

2.5. Sistemas de diagnóstico automático por computador

2.5.1. Antecedentes

Los sistemas de diagnóstico automático fueron propuestos como un intento por reducir la variabilidad del diagnóstico visual a ojo desnudo obtenido por el examen especialista, en los que usualmente influyen factores no estandarizados por el medio científico. Luego de ser notable la creciente aparición del melanoma, el primer reporte asociado a sistemas diagnósticos fue incluido en la literatura alrededor de 1985 [28].

En un estudio realizado por G. Day et al, analizan los desarrollos asociados en esta área desde sus inicios hasta finales de la década de los 90, en esa investigación determinan que los sistemas de diagnóstico reportados en la literatura estaban estructurados para reconocer el Melanoma, siguiendo los mismos procedimientos empleados por el especialista.

Tales sistemas se caracterizaban por utilizar imágenes adquiridas sin un estándar específico, lo que afectó significativamente la etapa de segmentación. Luego de la aparición de la dermatoscopia a inicios de los 90 y de la elevada precisión del diagnóstico al utilizar esta técnica, se popularizó el empleo de imágenes dermatoscópicas para la detección automática de melanoma. Debido a razones comerciales, la etapa de segmentación de imágenes no fue descrita ampliamente sino a partir de la segunda mitad de la década del 90.

Respecto a la clasificación, fueron principalmente aplicados métodos estadísticos entre ellos Análisis discriminante, redes neuronales artificiales y clasificadores lineales. Con base en las tablas desarrolladas por Gay et al., hasta finales de los años 90 los intervalos de sensibilidad y especificidad para los sistemas de diagnóstico de melanoma conocidos eran de [74-96] % en sensibilidad y [60-86] % en especificidad.

2.5.2. Estado del Arte

Actualmente los desarrollos en el diagnóstico automático del melanoma siguen siendo notables, ya sea inspirados en buscar mejores desempeños que los obtenidos por sistemas previos, en ofrecer sistemas que puedan ser tan eficientes como un dermatólogo experto ó impulsados por el conocimiento que se tiene acerca de la mortalidad del melanoma. A continuación, se ofrecerá un reporte basado en las contribuciones, conclusiones y resultados de las investigaciones asociadas al tema.

En la revisión de diversos trabajos publicados en la última década, el perfeccionamiento de sistemas de diagnóstico automático de melanoma sigue siendo un área activa. Con base en las investigaciones realizadas, se hace imprescindible el uso de sistemas diagnóstico según las siguientes razones, se manifiesta y se establece el Melanoma como el cáncer de piel más peligroso [78], debido a que posee el mayor índice de crecimiento en la tasa de incidencia a nivel mundial. Según [13] las estadísticas sugieren que en la última década, 4 Millones de personas fueron diagnosticadas con Melanoma y de ellas 500.000 posiblemente fallecieron por la misma razón, con el agravante de que pudieron vivir 25 años adicionales.

Los estudios analizados comparten la idea de que el Melanoma es fácil de curar si es diagnosticado en sus etapas tempranas o de lo contrario, la esperanza de vida se reduce a menos de un año [74]. Igualmente, la mayoría considera adecuado generar una herramienta que asista objetivamente al diagnóstico del Melanoma en las prácticas diarias de los especialistas, herramienta necesaria para incrementar la precisión del diagnóstico, que en dermatólogos expertos se encuentra en el rango del 75-84 % [48]. En el diagnóstico especialista, son muchas las condiciones que influyen para omitir accidentalmente variables relevantes, especialmente la dimensión de la lesión, siendo más difícil diagnosticar acertadamente cuando la lesión es más pequeña.

En general, los sistemas de diagnóstico examinados están basados en imágenes dermatoscópicas y se componen de tres módulos principales: Segmentación, Extracción de características y Clasificación, siendo notable la variedad de métodos para cada etapa. A continuación se mencionaran algunos relevantes. Adicionalmente en la Tabla 2-6, se puede observar un esquema general de cómo están integrados los sistemas de diagnóstico estudiados.

En [78], procesaron un conjunto de 152 imágenes con un método de segmentación no explícito. Realizan un conjunto de medidas sobre la imagen agrupándolas entre geométricas, morfológicas y colorimétricas. Luego las medidas son clasificadas mediante un sistema compuesto por el clasificador de Análisis Discriminante Lineal, Árboles de decisión y el clasificador de los k vecinos más cercanos. De la clasificación obtuvieron valores de desempeño del 80 % en sensibilidad y del 79 % en especificidad.

En [48], desarrollaron un sistema de diagnóstico con aplicación en línea. El prototipo inicial empleo segmentación mediante un algoritmo automático de umbralización y este prototipo genero valores de sensibilidad del 87 % y una especificidad del 93 %. Corrigiendo los errores del prototipo inicial, reconsideraron como algoritmo de segmentación el método de crecimiento de regiones, con el objetivo de hacer comparable la segmentación automática con la manual. Además realizaron otras mejoras relacionadas al tiempo de diagnóstico y extracción de características. En total fueron calculadas 64 características agrupadas en relación a cada ítem de la Regla ABCD. Posteriormente la clasificación se realizó con Redes neuronales artificiales obteniendo una pareja de sensibilidad y especificidad del 97 % y 86 % respectivamente. Para el diagnóstico automático se emplearon 319 imágenes tomadas bajo un protocolo específico.

Al analizar detalladamente los sistemas de diagnóstico, es fácil notar que en la mayoría, la captura de imágenes posee la ausencia de un protocolo de adquisición definido. Por lo anterior la inestabilidad de los resultados es inminente, a no ser que el sistema sea lo suficientemente robusto para aceptar imágenes con altas modificaciones, lo cual tampoco es comentado.

De acuerdo a la segunda columna de la Tabla 2-6, aunque en los últimos años ha sido fuertemente criticado el procedimiento de diagnóstico de la Regla ABCD, este ha servido de inspiración para ser aplicado en la mayoría de sistemas de diagnóstico automático, mostrando resultados superiores que el diagnóstico por expertos dermatólogos.

Tabla 2-6.: Sistemas de diagnóstico asistido por computador.

Sistema Automático/ Publicación	Basado	Segmentación	Extracción de Características	Clasificación
H. Ganster et al. 2001. [39]	Indefinida	Fusión: 3D Clustering Umbralización	Globales: Color Forma.	$K - nn$
A. Sbones et al. 2003. [78]		Indefinida	Geométricas. Morfológicas. Cromáticas.	Sistema Mixto. LDA, Knn y Arboles de decisión
H. Iyatomi et al. 2005. [48]	Regla ABCD	Crecimiento de Regiones	Morfológicas. Cromáticas. Estadísticas	Redes Neuronales Artificiales
M. Rahman et al. 2007. [69]	Indefinido	Umbralización Iterativa	Textura. Cromáticas.	SVM Gaussian ML. $K - nn$
H. Iyatomi et al. 2008. [47]	Regla ABCD	Crecimiento de Regiones	Color. Simetría. Borde, Textura	Redes Neuronales
G. Capdehourat et al. 2009.[13]	Regla ABCD y Método de Argenziano	Método de Otsu	Morfológicas Cromáticas Textura	Arboles de decisión
J. F. Alcón et al. 2009.[4]	Regla ABCD	Método de Otsu	Asimetría Borde Color	Arboles de decisión Fusionado con Redes Bayesianas
I. Gola et al. 2010.[42]	Método de dos pasos	Indefinida	P. Reticulado P. Globular	Indefinida
G. Leo et al. 2010.[56]	Método de Argenziano	Método de Otsu	Cromáticas. Textura.	Arboles de decisión
D. Ruiz et al. 2011. [74]	Regal ABCD	Método de Otsu	Morfológicas Cromáticas Textura Borde	Perceptron Multicapa, Clasificador Bayesiano, Knn.
G. Capdehourat et al. 2011. [12]	Soporte Clínico	Metodo de Otsu a Color	Color, Forma. Textura. Locales	Arboles de Desición
I. Gola et al. 2011. [46]	Regla ABCD	Doble Umbralización	Global. Locales: Velo Azul Reticulo, Globulos,	Indefinido

En la etapa de segmentación, el Método de Otsu ha sido el más empleado. Si bien es fuertemente aceptado en la literatura por el excelente comportamiento que posee, la complejidad

de las imágenes Melanocíticas impiden su uso eficiente porque al ser un procedimiento de umbralización, en la mayoría de los casos se pierde información asociada a la región difusa de la lesión, es decir, los bordes. Con respecto a la caracterización de los patrones Melanocíticos, fue frecuente su reconocimiento mediante descriptores de forma, color y textura que fueron clasificados por diversos enfoques de maquinas de aprendizaje.

2.6. Contextualización Técnica

Para el desarrollo e implementación del sistema se hizo uso de variadas herramientas elaboradas en el área de procesamiento digital de imágenes. Sin embargo, con la intención de contextualizar al lector, a continuación se describen algunos con los conceptos requeridos.

2.6.1. Descripción del Mapa de color e Imágenes Indexadas

Básicamente, el Mapa de color se define como toda la gama de colores presentes en una imagen RGB. Puntualmente, el Mapa de color $Cmap_{N \times 3}$ es una matriz con dimensión de tres columnas por tantas filas como tonos diferentes y sin repetición posea la imagen $I_{n \times m \times 3}$, donde cada fila representa un color específico y definido por la combinación de las componentes primarias, es decir, Rojo, Verde y Azul.

$$Cmap_{i \times 3} = \{(R_i, G_i, B_i) \in \mathbb{J}^3 : \begin{cases} R_i = I_{n \times m \times 1}(x_s, y_s), \\ G_i = I_{n \times m \times 2}(x_s, y_s), \\ B_i = I_{n \times m \times 3}(x_s, y_s) \end{cases}\} \quad (2-2)$$

Donde $x_s \in \{1 : stp : n\}$, $y_s \in \{1 : stp : m\}$, $\mathbb{J} = [0, 1]$.

La extracción del Mapa de Color se realiza al adquirir la intensidad asociada a las componentes de la imagen original cada stp pixeles, por filas y columnas, hasta recorrer toda la imagen. Si la longitud de paso es igual a uno, $stp = 1$, se tendría un Mapa de Color tan grande como el producto de la dimensión original de la imagen, $N = n \times m$, siendo ineficiente su manipulación en términos computacionales, pero si stp es muy grande, provoca que se pierda información importante en imágenes con dimensión reducida.

Sin embargo, como consecuencia de la alta resolución requerida en imágenes biomédicas, se obtienen imágenes con dimensiones casi exageradas, razón por la cual, no es necesario recorrer más de la mitad de los pixeles contenidos en la imagen, específicamente, en este trabajo se estableció un $stp = 10$, sin pérdida de información. Para restringir a que el Mapa de Color contenga tonos exclusivos, se busco iterativamente las intensidades repetidas y entonces eliminarlas; para facilitar la búsqueda, se redondeo a 4 la cantidad de números después del

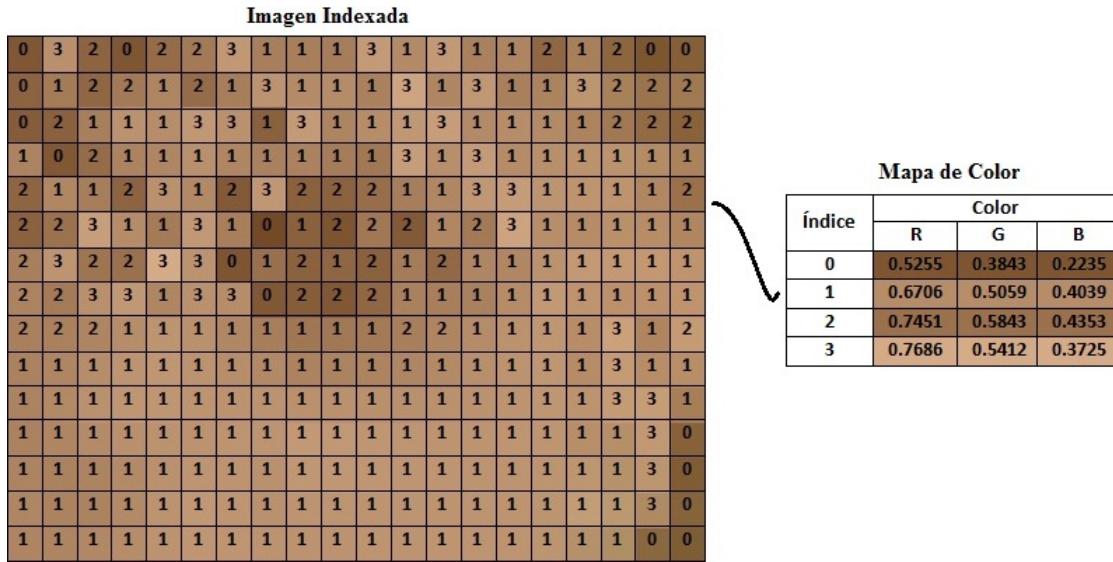


Figura 2-4.: Matriz que posee los índices asociados al mapa de color, (Imagen Indexada).

punto decimal.

Después de extraer el Mapa de Color, se obtiene una representación casi exacta de la imagen original, estableciendo un arreglo que relaciona cada pixel de la imagen RGB con un índice del Mapa de Color, la imagen resultante se denomina imagen indexada, Figura 2-4.

Para mayor información consultar [43].

3. Preprocesamiento

3.1. Introducción

En este capítulo se estudian las técnicas que tienen como objetivo remover ó atenuar todo tipo de objeto que perturbe la región de interés. Para tal fin, se realiza un análisis comparativo de los métodos populares y los métodos propuestos asociados al tema. Esto con la intención de identificar los procedimientos más robustos que integraran esta etapa del sistema pero que también contribuyen al incremento de la capacidad del mismo en el área de eliminación de ruido y realce de contraste. Como principales aportes, se desarrolló una técnica de remoción y sustitución de vellos mediante reconstrucción morfológica multiescala, así mismo, se encontró el espacio de color en el que las imágenes exhiben el mejor contraste. Entre los espacios de color estudiados se incluyeron las transformaciones del espacio de color, la proyección discriminante del color y la compactación del color. La descripción de los métodos propuestos se dará en las siguientes secciones conservando el orden del esquema mostrado en la figura 3-1.

3.1.1. Estado del Arte

Los sistemas de diagnóstico automático para la detección de patologías clínicas, han sido ampliamente aceptados en los últimos años gracias al gran soporte que ofrecen en la decisión especialista. Estas herramientas emplean técnicas que reducen la subjetividad asociada a los métodos tradicionales de diagnóstico ó sencillamente son capaces de realzar importantes detalles en las imágenes.

En virtud que en múltiples tareas de reconocimiento las características que definen al objeto de interés poseen bajo contraste, las técnicas de mejoramiento de la imagen se han convertido

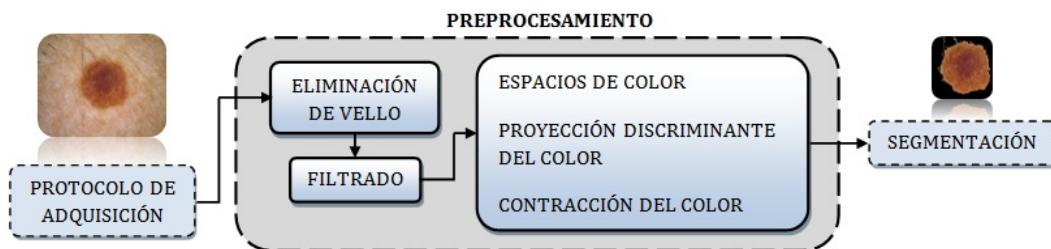


Figura 3-1.: Esquema general del modulo de Preprocesamiento.

en la etapa inicial como parte integral del preprocesamiento [23, 21]. Por consiguiente, estos algoritmos son popularmente empleados no solo en áreas asociadas a la medicina [89, 83, 79], sino también en la industria [1, 31] ó reconocimiento biométrico [91, 50], adicionalmente, para el acondicionamiento de imágenes dermatoscópicas.

El acondicionamiento de imágenes dermatoscópicas se refiere específicamente a la adecuación de la imagen para realizar con mayor éxito y facilidad las posteriores tareas de procesamiento, en particular, segmentación y extracción de características.

A pesar del incremento obtenido en nitidez al usar dispositivos dermatoscópicos, la etapa de preprocesamiento es particularmente necesaria en este tipo de imágenes, puesto que los bordes generalmente tienden a desaparecer suavemente en la región periférica de las lesiones. Además, las imágenes pueden presentar dificultades inherentes a la lesión en cuestión, como por ejemplo, patrones de color irregular o fragmentación relacionada a la despigmentación del color [15] y dependiendo del procedimiento de adquisición poseen pobre contraste ó burbujas de aire. En conjunto las dificultades previas provocan como resultado que la detección automática de las lesiones melanocíticas sea compleja y en muchos casos ineficiente.

Para superar los inconvenientes previamente mencionados, alrededor de este tema se han desarrollado ciertas estrategias en el preprocesamiento. Por ejemplo el equipo de Celebi et al., que podría ser considerado como el grupo con mayor contribución reciente en este tema, construyen una imagen con dos nuevos canales partiendo de la imagen dermatoscópica original. En la nueva imagen conservan exclusivamente el canal azul argumentando que las lesiones son más prominentes en este canal. Además incluyen el canal de luminancia y por último, el canal con mayor varianza de la transformación Karhunen-Loéve (KL) [87]. Para la corrección de contraste emplean el método de Delgado et. al [41] que mediante la decorrelación del espacio de color pretende maximizar la separación entre el fondo y la lesión [16]. En [80], P. Schmid evaluó el comportamiento de un método de segmentación; diseñado mediante la integración de técnicas de clustering, valiéndose de imágenes dermatoscópicas transformadas al espacio de color L^*u^*v .

En general, entre las técnicas de preprocesamiento empleadas para la adecuación de la imagen, se utiliza popularmente la transformación del espacio de color y el suavizado de la imagen, especialmente con filtros gaussianos o promedio.

En tanto la eliminación de vellos alrededor de la lesión es levemente considerada. Los pocos reportes que se encuentran en la literatura son basados en técnicas de interpolación lineal (DullRazor [55]) y restauración mediante ecuaciones diferenciales parciales [27]. Inicialmente se plantea un modelo de los vellos, posteriormente se detectan y finalmente se descartan de la imagen. Los reportes indican que el modelado de los vellos puede realizarse a partir de la sucesión de perfiles [2] o por medio de la substracción del fondo a través de operaciones morfológicas [98]. Entre los procedimientos comunes se encuentran la rasuración manual y métodos automáticos que eliminan los vellos de acuerdo a su respectivo modelado, con la desventaja que la mayoría de procedimientos automáticos modifican la textura de la región de interés, causando la alteración de detalles discriminantes.

3.2. Método para la Eliminación de Vellos

En la figura 3-2, se indica la región de la imagen en la que se despliega verticalmente un vello, la sección transversal del mismo y su respectiva representación tridimensional. Como se observa en la figura 3.2(b), el interés del método es encontrar la región asociada a la depresión provocada por la presencia de vello, que se puede presentar en múltiples orientaciones.

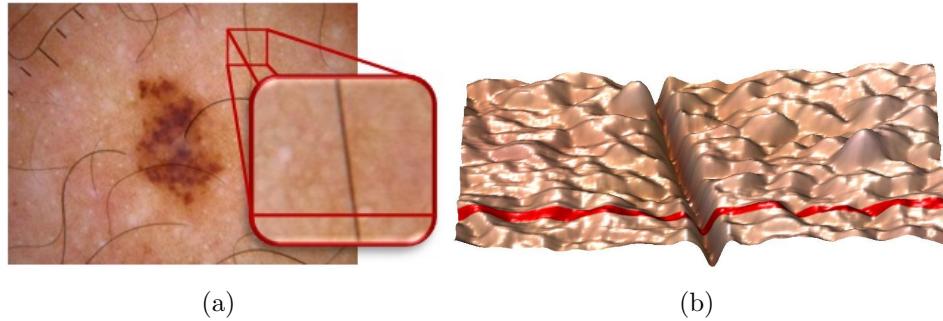


Figura 3-2.: (a). Imagen con presencia de vellos. (b). Propagación normal de un Vello sobre la región superficial de la imagen.

La identificación de vellos se realiza en función de las principales características que los definen. Estos son especialmente diferenciados por poseer estructuras alargadas, delgadas, con tonos oscuros e incluso, tonos suficientemente claros lo que ocasionalmente provoca el efecto de uniformidad con el medio. De acuerdo a lo anterior, el reconocimiento de vellos se realiza con base en la detección de la estructura geométrica mas semejante a estos, es decir, líneas oscuras. Para tal fin, se respalda el estudio a través de la investigación realizada por Qabbas et al. [3], que propone emplear la convolución de la imagen con una ventana asociada a la primer derivada de la función gaussiana; método propuesto en [95], el método sugiere la detección de vellos basándose en la sección transversal de los mismos.

Tradicionalmente, la detección de bordes y líneas oscuras se realiza con base en el empleo de la segunda derivada de la función gaussiana, sin embargo, se conoce que provoca altas respuestas para objetos con intensidades claras [95]. Con lo cual, la remoción de los vellos podría verse afectada al aceptarse regiones no deseadas, que particularmente son caracterizadas por poseer tonos claros.

En [95], fue mostrado que el kernel asociado a la derivada de la función gaussiana se desempeña eficientemente en la detección de líneas oscuras, generando respuestas más precisas. Considerando que las lesiones melanocíticas poseen patrones relevantes con tonalidades claras (Patrón reticular, velo azul-blanquecino, bordes, etc.), en este trabajo se emplea la función DOG, ecuación 3-1.

$$g'(X) = -\frac{X}{\sqrt{2\pi}|\Sigma|^{\frac{3}{2}}} e^{-\frac{1}{2}X^T \text{inv}(\Sigma)X} \quad (3-1)$$

Considérese la sección transversal de un vello ideal, figura 3.3(a). Es evidente que las fluctuaciones asociadas a los poros o cambios de iluminación no afectan la imagen, por el contrario, en condiciones normales la sección transversal de un vello (Linea horizontal, resaltada en color rojo en la figura 3.2(a)), se comporta tal como se indica en la figura 3.3(b). Al calcular la convolución con kernel DOG (figura 3.3(c)) sobre ambos perfiles, se concluye fácilmente que el centro de la depresión se ubica en el medio de dos puntos extremos que poseen signos opuestos, figura 3.3(d). El primer valor extremo debe ser máximo local, sin embargo, debido a las fluctuaciones existentes en una imagen normal se dificulta la detección exitosa, figura 3.3(e). Una sencilla solución a este problema se propone más adelante cuando la convolución se realiza en 2D.

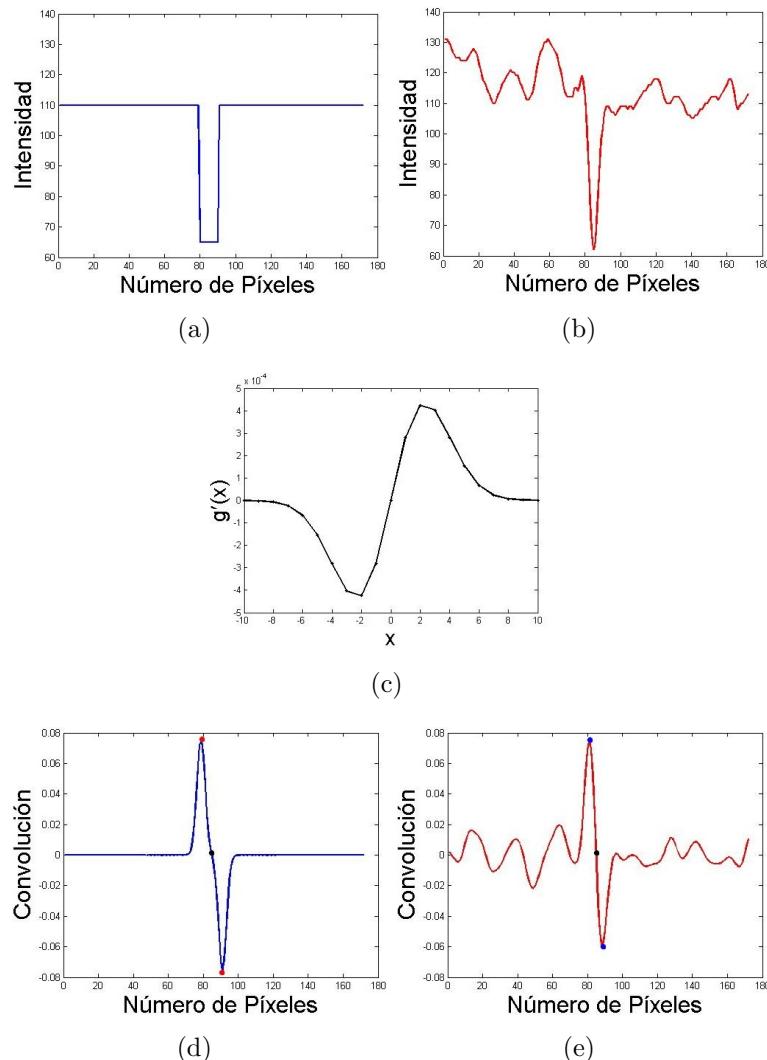


Figura 3-3.: (a). Perfil ideal de un vello. (b). Perfil de un vello en condiciones normales. (c). Kernel correspondiente a la Función DOG. (d). Convolución del vello ideal con el Kernel DOG. (e). Convolución de un vello normal con el Kernel DOG.

Basándose en los conceptos previos se puede extrapolar la idea en dos dimensiones, donde se debe tener especial cuidado con la rotación del kernel alrededor de su eje principal. La rotación del kernel asegura la detección de los velllos en sus múltiples orientaciones, básicamente, porque en la imagen los velllos se despliegan con ángulos aleatorios. Por lo tanto la generación del kernel $g'(x, y)$ se obtiene, no solo definiendo la dimensión de la ventana w , sino también con base en el ángulo θ sugerido por el usuario, ecuaciones 3-2.

$$\begin{aligned} x' &= x \cos(\theta) + y \sin(\theta) \\ y' &= y \cos(\theta) - x \sin(\theta) \\ X &= [x' \ y'] \end{aligned} \tag{3-2}$$

El arreglo X de las ecuaciones 3-2, pasa a ser el argumento en la ecuación 3-1, previamente expuesta. Debido al costo computacional implícito en el proceso se consideran exclusivamente las orientaciones principales para la generación del kernel, figura 3-4, que son 0° , 45° , 90° y 135° .

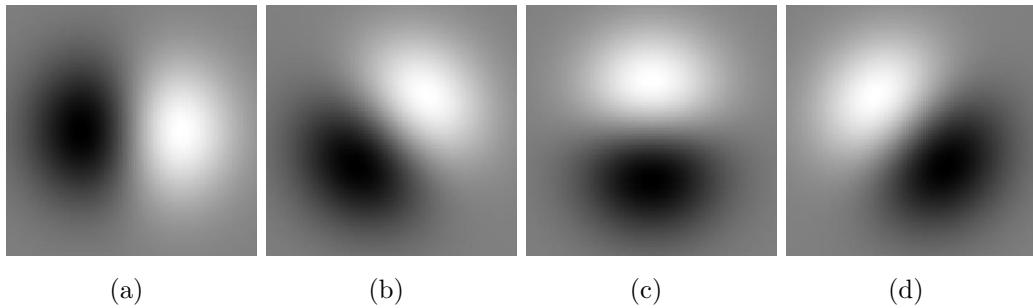


Figura 3-4.: Kernel DOG bidimensional, rotado en los ángulos principales (a). 0° . (b). 45° . (c). 90° . (d). 135° .

En este punto, la convolución garantiza que el kernel $g'(x, y)$ será aplicado sobre toda la superficie de la imagen $I(x, y)$, generando como resultado una imagen filtrada $F(x, y)$ de todo tipo de estructura uniforme que no cumple con ser lo suficientemente variable para ser consideradas en el cálculo, ver ecuación 3-3.

$$F_i(x, y) = I(x, y) * g'_i(x', y') \tag{3-3}$$

Finalmente, el reconocimiento del centro de cada línea asociada a una concavidad específica en la imagen original, puede ser definido por la siguiente expresión:

$$Cn_i = \begin{cases} F_i(x - d, y) + |F_i(x + d, y)|, & F_i(x - d, y) > 0 \& F_i(x + d, y) < 0 \\ 0, & \text{Otro caso.} \end{cases} \tag{3-4}$$

Cada arreglo i de las expresiones previas corresponde a una rotación específica sobre el kernel empleado. Para la integración de todos los arreglos, se elige la intensidad máxima asociada al pixel en la posición (x, y) de todos los canales Cn_i , ecuación 3-5.

$$R(x, y) = \max(Cn_i(x, y)) \quad (3-5)$$

Como resultado de la combinación de todos los canales Cn_i se obtiene una imagen con estructuras correspondientes a las líneas oscuras (Vellos), no obstante, también se definen estructuras indeseadas, figura 3.5(b). Las regiones indeseadas son eliminadas con la aplicación de un algoritmo de umbralización (Método de Otsu), donde previamente ha sido aplicada la operación morfológica de cierre sobre la imagen $R(x, y)$ y por conveniencia con una estructura morfológica cuadrada de dimensión ws . Con la operación de cierre el fondo se torna más homogéneo y se conserva suficiente contraste sobre las regiones de interés, de este modo la técnica de umbralización es más efectiva. En la medida que la estructura morfológica aumenta su dimensión, el algoritmo de umbralización aceptará regiones con tonos similares a los de interés, es decir blancos, siendo a su vez más impreciso. Implicitamente la operación morfológica está extendiendo el histograma de la imagen $R(x, y)$ lo que permite encontrar un umbral más discriminante en la clasificación de los tonos asociados a fondo y vello.

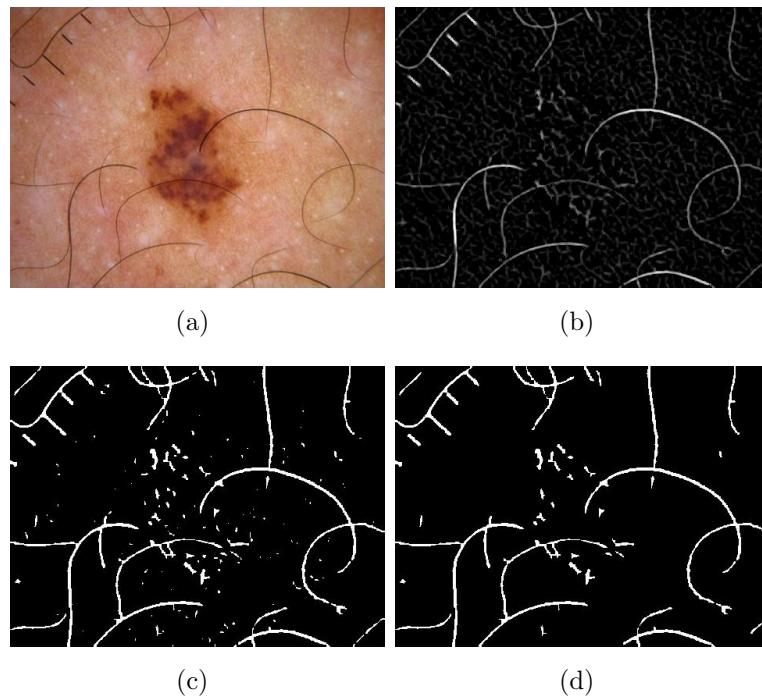


Figura 3-5.: (a). Imagen dermatoscópica con presencia de vellos. (b). Imagen $R(x, y)$ resultante del procedimiento de detección de líneas oscuras. (c). Detección de las estructuras relevantes mediante umbralización. (d). Máscara M_k asociada a la dispersión de los vellos.

La elección de la estructura morfológica corresponde a la que provoca la mínima alteración de líneas y al mismo tiempo suaviza el fondo. La estructura morfológica adecuada fue la cuadrada, en el análisis se consideraron además las estructuras en forma de diamante, rectangular, circular, lineal y octagonal. Buscando que la operación morfológica no genere resultado exagerados, se definió un ventaneo con dimensión acorde al tamaño de los velllos $ws = 5$. Luego de la umbralización (Figura 3.5(c)), fue aplicado un filtro de área para eliminar las regiones que no pertenecen a los vellos, considerando adecuado la substracción de los objetos con área inferior a 20 píx, (Figura 3.5(d)).

Por último, luego de obtener la máscara binaria M_k (Figura 3.5(d)) que define las zonas ocupadas por vellos en la superficie de la imagen original $I(x, y)$, son utilizadas nuevamente las operaciones morfológicas con la intención encontrar la aproximación superficial S_a que sustituirá apropiadamente las regiones asociadas al vello.

Para la construcción de la nueva superficie considere la imagen original sin las regiones asociadas a los vellos, figura 3.6(a). Ahora suponga que esta imagen se dilata n veces con estructura morfológica creciente. Lo que ocurre con cada iteración es que paulatinamente se desvanecen los espacios vacíos, esto se debe a que nuevas intensidades ocupan esta región. Teniendo en cuenta el concepto previo, la superficie S_a se construye con las nuevas intensidades que ingresan en los huecos para la dilatación de estructura circular actual conservando únicamente las intensidades que ingresaron por primera vez dentro de la región a construir, con lo cual se garantiza obtener una superficie uniforme y precisa.

Con base en lo anterior, cada ocasión que es aplicada la operación de dilatación se genera una nueva imagen, la cual contiene los nuevos píxeles que ingresaron en la región ocupada por los vellos, así, hasta eliminar por completo todas las regiones definidas en la máscara M_k . La función de aproximación final será la suma del aporte de cada dilatación, ecuación 3-6.

$$S_a = S_{a1} + S_{a2} + S_{a3} + \cdots + S_{an} \quad (3-6)$$

Cada imagen S_{ai} es calculada teniendo en cuenta los píxeles que ya han ocupado alguna región dentro de la máscara, básicamente, para evitar ser considerados en una nueva búsqueda, como resultado, cada iteración depende de la anterior. La imagen aproximación S_a (Figura 3.6(b)), se calculó mediante la ecuación 3-7.

$$S_a = \sum_{i=1}^n ([I \cdot M_k] \oplus W_i) \cdot \left[\bigcup_j^{i-1} \text{BW}(S_{aj}) \right]^C \quad (3-7)$$

Donde $\text{BW}(S_{aj})$ corresponde a la imagen binaria de todos los valores diferentes de cero, en la imagen S_{aj} .

La expresión necesaria para calcular la imagen libre de vellos H_L (Figura 3.6(c)), se indica en la ecuación 3-8.

$$H_L = \underbrace{I \cdot M_k^C}_A + \underbrace{S_a}_B \quad (3-8)$$

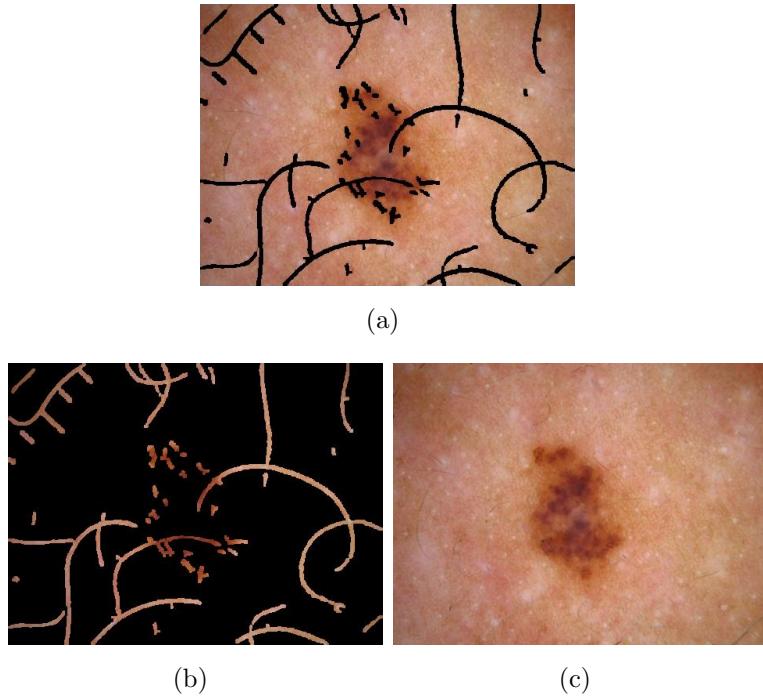


Figura 3-6.: (a). Imagen Original sin la presencia de los vellos identificados en la máscara M_k . (b). Representación de la superficie ocupada por los vellos S_a . (c). Imagen resultante del método de eliminación de vellos H_L .

Esencialmente, el elemento A de la ecuación 3-8 elimina todas las intensidades asociadas a las regiones ocupadas por los vellos (Figura 3.6(a)), las cuales son posteriormente ocupadas por la aproximación encontrada S_a . La imagen resultante y desprovista de vellos H_L se muestra en la figura 3.6(c).

3.3. Corrección de Contraste

La necesidad de aplicar métodos que mejoren el contraste de las imágenes melanocíticas se fundamenta especialmente en que las regiones más externas de la lesión se combinan uniformemente con las zonas asociadas a la piel, lo cual dificulta la tarea de segmentación. Con el propósito de superar ese tipo de dificultades han sido utilizadas las transformaciones del espacio de color para incrementar el contraste en las dos regiones principales, que son las regiones asociadas a piel y a lesión.

Teniendo en mente las agrupaciones que se deben contrastar, en este trabajo se implementaron las siguientes técnicas para la corrección de contraste: Compactación del Color, Proyección discriminante del Color. Las cuales emplean el mapa de color; la totalidad de tonos diferentes en la imagen dermatoscópica, para encontrar la proyección discriminante y la distribución espacial que maximizan la separación entre las dos clases principales, es decir,

los grupos de colores pertenecientes a Fondo (Tonos Claros) y Lesión (Tonos Oscuros). Por cada método propuesto se genera un arreglo del Mapa de Color (Colormap) diferente que posteriormente serán aplicados a la imagen original indexada.

Sin embargo, como se verá más adelante, en este trabajo se sugiere que no es necesaria la corrección de contraste, por las siguientes razones:

- La brecha que separa los colores asociados a lesión y piel es muy angosta, lo que provoca que al transformar las tonalidades pertenecientes a piel, inevitablemente también se afectaran las regiones correspondientes a lesión y a la poste contribuye a incrementar las falsas detecciones en etapas posteriores.
- Las transformaciones del color son sensibles a las condiciones iniciales de la imagen, variando drásticamente cuando la imagen no posee parámetros de adquisición estándar.
- La imagen original en el espacio RGB exhibe mejores niveles de contraste que en relación a otras transformaciones.

3.4. Desarrollo e Implementación de los Métodos para la corrección de contraste

3.4.1. Compactación del Color

Considere la imagen mostrada en figura 3.7(a), la cual posee exclusivamente un objeto con un color específico, que a su vez posee todos sus colores difusos asociados. Si el Mapa de color es obtenido y se asigna como el conjunto de datos (figura 3.7(b)) es posible notar la formación de una distribución del color, comenzando por los oscuros, transitando por los tonos puros y finalizando por los tonos claros. Tal variación del color está principalmente relacionada con la iluminación aplicada al objeto, la cual no es uniforme sobre la superficie de la jarra. La misma situación ocurre cuando otro objeto se agrega a la escena (figura 3.7(c)) por conveniencia suponga nuevamente que este posee un color principal y condiciones de iluminación similares, sin importar la forma geométrica es fácil concluir que en este caso como en el previo las distribuciones del color se concentraron alrededor de ambos tonos principales, que son: Azul y Rojo, figura 3.7(d).

En condiciones de iluminación adecuadas los colores difusos tienden a converger al color predominante, lo que implica que la imagen se encuentra bien contrastada.

Teniendo en cuenta lo anterior, se deduce que los objetos que pertenecen a una clase específica u objeto en la imagen pueden ser reconocidos por las agrupaciones que los conforman en el espacio de color, tal como en la figura 3.7(d). Una situación equivalente ocurre con las imágenes dermatoscópicas que usualmente generan dos concentraciones principales en la dispersión del color (Figura 3-8), las cuales son relacionadas a los objetos notables definidos como lesión y fondo. Como se comentó en un principio, una dificultad importante en este tipo

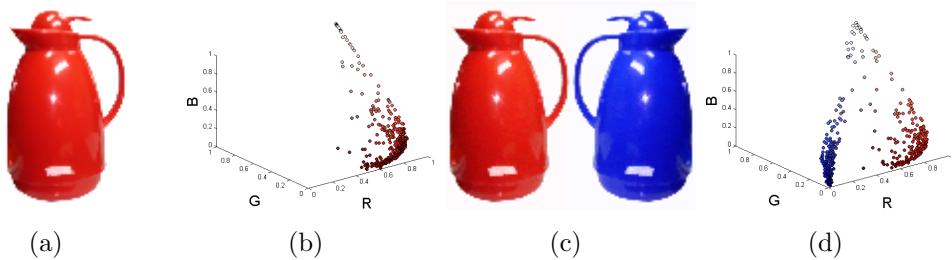


Figura 3-7.: (a). Imagen con un objeto de tonos rojos, I_r . (b). Dispersión espacial del color para I_r . (c). Imagen con objetos de tonos rojos y azules, I_{rb} . (d). Dispersión espacial del color para I_{rb} .

de imágenes es la suavidad con la que los bordes de la lesión se desvanece hasta convertirse homogéneos con la piel, lo cual provoca en el espacio de color que la dispersión entre las clases sea más reducida y que la dispersión dentro de las clases sea más grande.

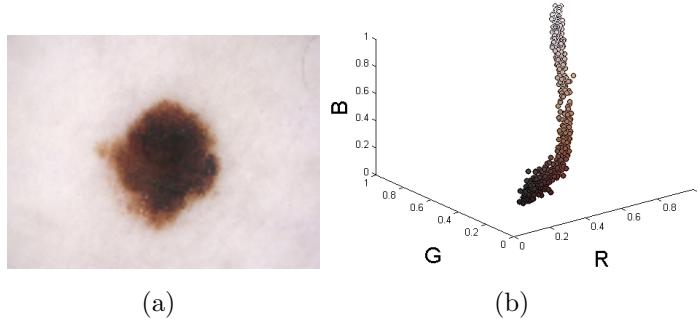


Figura 3-8.: (a). Imagen dermatoscópica, I_d . (b) Dispersión espacial del color para I_d .

Puesto que el contraste de la imagen está fuertemente relacionado con la dispersión del color, además con la intensión de incrementar el contraste en las imágenes, se propone un método que identifica las distribuciones de color asociadas a lesión y piel. Este método define los colores predominantes como el centro de gravedad de cada agrupación y finalmente ofrece la posibilidad de orientar los tonos más cercanos hacia estos. En conclusión, el realce de contraste de este método se basa en la compactación de las agrupaciones aparentes sobre su centro de gravedad, como consecuencia, incrementará la separación entre los grupos y se eliminarán los colores difusos. Para llevar a cabo el procedimiento se sugiere el esquema de la figura 3-9.

Búsqueda de las agrupaciones relevantes

Después de obtener el Mapa de Color, el objetivo es identificar las agrupaciones asociadas a fondo y lesión. Estas agrupaciones son regiones en el espacio donde se presentan altos niveles de concentración del color, es decir, tonos claros relacionados con el fondo y tonos oscuros

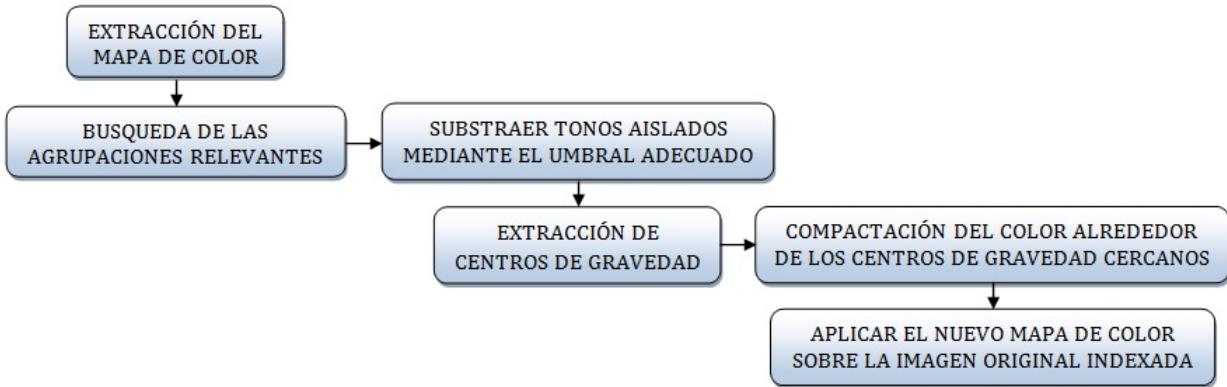


Figura 3-9.: Estructura del método propuesto para la compactación del color.

relacionados con lesión. Por consiguiente, se propone una medida de densidad espacial que define el grado de proximidad entre cualquier punto (R_i, G_i, B_i) y sus vecinos.

Densidad Espacial del Color

Sea D la matriz simétrica que define la distancia Euclídea entre los puntos (i, j) del Mapa de Color $Cmap_{N \times 3}$, donde los elementos de su diagonal principal son cero, ecuación 3-9.

$$D_{ixj} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1j} \\ d_{21} & d_{22} & \cdots & d_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ d_{i1} & d_{i2} & \cdots & d_{ii} \end{bmatrix} \quad (3-9)$$

Con la intención de conocer los valores que se encuentran más cerca entre ellos, la densidad se define como el inverso de cada elemento de la matriz D haciendo que los valores cercanos a cero tiendan a ser más significantes, es decir, todas las intensidades que se encuentran en la vecindad del i -ésimo color, ecuación 3-10.

$$Dt(k) = \sum_{k=1}^i \frac{1}{D_{kk}} \quad (3-10)$$

Donde $D_{kk} = D(k, m)$ y $m \in [1, j]$. Obteniendo la densidad del Mapa de Color con el método propuesto (Figura 3.10(a)), es fácil notar la alta concentración en colores claros. Si cada valor de densidad es asignado como el radio de su punto respectivo en el Mapa de Color, se obtiene una representación más fiel de las regiones espaciales que pertenecen tanto a las agrupaciones de tonos claros, como oscuros, figura 3.10(b).

Identificación de las Densidades Relevantes

Después de normalizar el vector Dt , es necesario identificar el umbral adecuado que permite el reconocimiento de las agrupaciones representativas, es decir, separar las clases mediante la

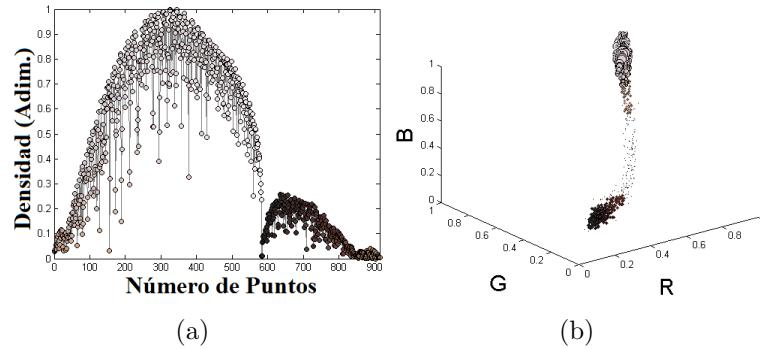


Figura 3-10.: (a). Densidad del color. (b). Dispersión del mapa de color con la densidad correspondiente a cada punto.

eliminación de tonos que poseen densidad insignificante que en la figura 3.10(b) pertenecen a la región intermedia. El procedimiento para encontrar el umbral adecuado se describe en el Algoritmo 1. Cuando el vector de distancias d ha sido encontrado, el umbral se define como

Algorithm 1 Algoritmo de Busqueda del Umbral Adecuado

Require: Extraer el Mapa de Color $Cmap_{Nx3}$ y generar el vector Dt .

Require: $Dts =$ Organizar el vector Dt de forma ascendente.

```

1: while  $i \leq N$  do
2:    $S_p =$  Encontrar las posiciones que cumplen con  $(Dt > Dts(i))$  .
3:   Clases = Kmeans( $Cmap(S_p)$ , Dos Poblaciones).
4:    $Pr_a =$  Encontrar (Clases==1).  $Pr_b =$  Encontrar (Clases==2).
5:    $M_{ai} = \frac{1}{N_a} \sum Cmap(Pr_a)$ .  $M_{bi} = \frac{1}{N_b} \sum Cmap(Pr_b)$ ,  $\{N = N_a + N_b\}$ .
6:    $d(i) = \sqrt{\sum_{j=1}^3 (M_{ai}(j) - M_{bi}(j))^2}$ .
7:    $i = i + 1$ .
8: end while
```

el valor $Thr = Dts(i)$, donde i , es el punto máximo del vector d . El umbral Thr promueve la separación de los cluster y garantiza que se encontraran las dos agrupaciones principales, figura 3-11, de las cuales es fácil obtener el centro de gravedad asociado.

Compactación del Color

Al obtener los centros de gravedad M_a (Fondo) y M_b (Lesión), figura 3-12, se induce a que la distribución original de Mapa de Color conserve dirección hacia cada uno de ellos, por lo cual, los colores asociados a ambos centros de gravedad serán los tonos predominantes en la imagen final, promoviendo la separación entre clases, reduciendo la dispersión de las clases y en consecuencia, incrementando la definición de ambos objetos en la imagen.

La nueva distribución del Mapa de Color \overline{Cmap} , se logró obteniendo la diferencia entre el Mapa de Color y la separación de los puntos cercanos al centro de gravedad de la clase

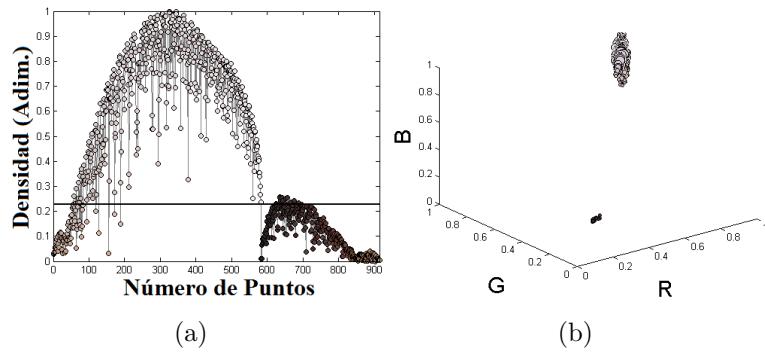


Figura 3-11.: (a). Umbral que promueve la separación de los grupos $Thr = 0,2285$. (b). Agrupaciones relevantes.

$c = a, b$, siendo a la clase asociada con el fondo y b la clase perteneciente a lesión, ecuación 3-11.

$$\overline{Cmap}(P_c) = Cmap(P_c) + \alpha(Cmap(P_c) - M_c) \quad (3-11)$$

Donde P_c corresponde a todos los puntos del Mapa de Color $Cmap$ cercanos a la clase c y α es el factor de contraste.

Nótese que si la separación entre los puntos cercanos y el centro de gravedad es nula, la incidencia será máxima y no se tendrán colores diferentes a los tonos asociados con los centros de gravedad, lo que corresponde a un incremento total en el contraste. Por el contrario, si la separación es parcial se logrará un incremento del contraste moderado. Para manipular el factor de separación que de otro modo también controla el factor de contraste, se agrega la variable α definida por valores en el intervalo $[0,1]$.

Si $\alpha = 1$, se obtendrá una imagen completamente contrastada, lo que indica que cada agrupación se contrae totalmente alrededor de su centro de gravedad cercano. Finalmente, esta imagen podría ser vista como una máscara de segmentación, dado que es binaria y resalta

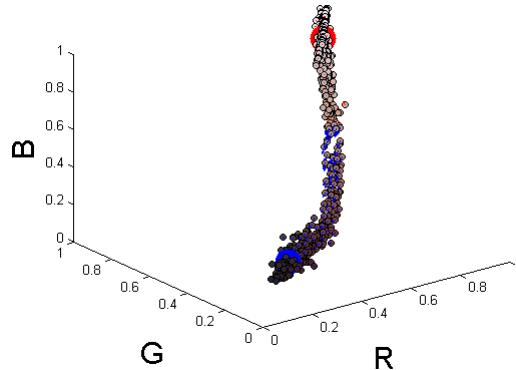


Figura 3-12.: Dispersión del color orientado a los centros de gravedad asociados a las agrupaciones de interés.

las regiones asociadas a las regiones de interés, figura 3.13(c). No obstante, la intención no es segmentar, sino definir regiones asociadas a bordes con intensidad tenue, figura 3.13(a).

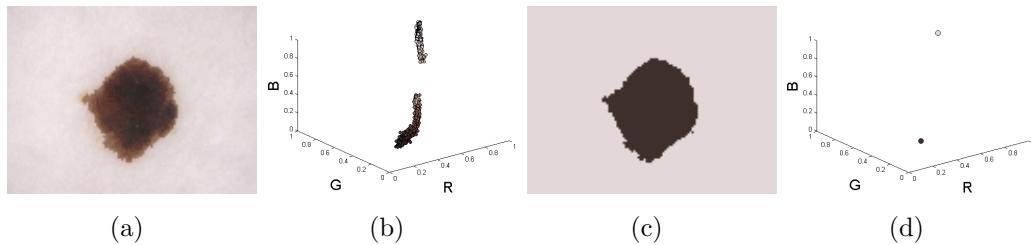


Figura 3-13.: (a). Imagen final contrastada con $\alpha = 0.3$. (b). Dispersión del color final con $\alpha = 0.3$. (c). Imagen final contrastada con $\alpha = 1$. (b). Dispersión del color final con $\alpha = 1$.

La importancia en la detección de los centros de gravedad, básicamente radica en que si estos no pertenecen a las dos agrupaciones principales modificaran las características cromáticas de la imagen final, por consiguiente, se realzaran al mismo tiempo colores que podrían pertenecer tanto a regiones asociadas al fondo como a la lesión, figura 3-14.

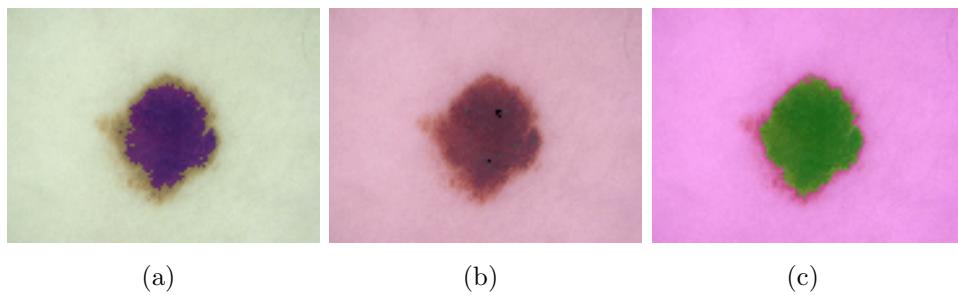


Figura 3-14.: Consecuencia de la elección inapropiada de colores predominantes.

3.4.2. Proyección discriminante del Color

Los métodos de reducción de dimensionalidad son principalmente empleados para la generación de un conjunto de datos discriminante, desarrollados con el interés de evitar el contenido redundante del conjunto de datos original con dimensión elevada. Tales métodos usualmente son construidos con base en medidas generales y precisas de los datos, especialmente relacionadas a las características de dispersión espacial de sus agrupaciones representativas, por ejemplo, la dispersión entre y dentro de las clases. Aplicando esas medidas es posible encontrar la rotación espacial que mejor indica la separación de las clases, sea en la dimensión actual o en una dimensión inferior.

Teniendo en cuenta lo anterior se propone un método que busca automáticamente las proyecciones discriminantes del Mapa de Color perteneciente a imágenes dermatoscópicas. Para

lo cual recurrimos al soporte académico de la investigación realizada por Yan et al. [90], en la que desarrollan dos medidas para caracterizar la dispersión de los datos; dispersión local y global. Posteriormente encuentran la proyección espacial w_p que maximiza la separación entre las clases. Con la intención de realzar el contraste de las imágenes dermatoscópicas empleamos la proyección propuesta en [90] para luego aplicarla directamente sobre el Mapa de Color. Para el desarrollo de la idea se propone el procedimiento general mostrado en el diagrama 3-15.

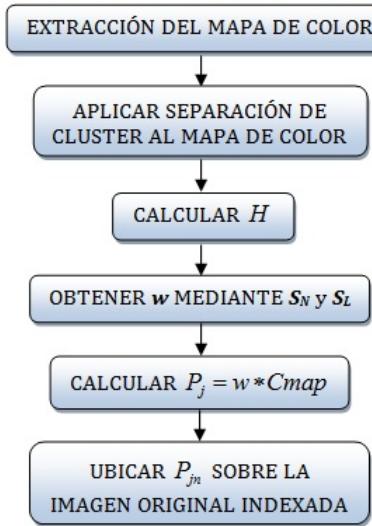


Figura 3-15.: Esquema general para el desarrollo de la Proyección discriminante del color.

Con base en [90], el criterio $J(w_p)$ usado para incrementar la dispersión no local y al mismo tiempo reducir la dispersión local en el Mapa de Color es similar al criterio de Análisis Discriminante Lineal *LDA*. La ecuación 3-12 indica el criterio empleado.

$$J(w_p) = \frac{w_p^T S_N w_p}{w_p^T S_L w_p} \quad (3-12)$$

Donde la matriz w_p se obtiene mediante la descomposición de valores propios generalizados, empleando las matrices de dispersión local S_L y global S_N . La dispersión local S_L se calcula a través del promedio cuadrado de la distancia Euclídea entre cualquier pareja de puntos x_i , x_j que pertenecen a la clase relacionada al fondo C_b o a la clase relacionada a la lesión C_a dentro del arreglo del Mapa de Color $Cmap$, ecuación 3-13.

$$S_L = \frac{1}{2N^2} \sum_i^N \sum_j^N H_i (Cmap_i - Cmap_j) * (Cmap_i - Cmap_j)^T \quad (3-13)$$

La dispersión no local S_N se caracteriza por el promedio cuadrado de la distancia Euclídea entre cualquier pareja de puntos que pertenecen a la clase relacionada al fondo C_b , ecuación

3-14.

$$S_N = \frac{1}{2N^2} \sum_i^N \sum_j^N (1 - H_i)(Cmap_i - Cmap_j) * (Cmap_i - Cmap_j)^T \quad (3-14)$$

Para la identificación de los clusters se desarrolla un vector de etiquetas H que define las clases C_a y C_b en el arreglo del Mapa de Color, ecuación 3-15.

$$H_i = \begin{cases} 1, & Cmap_i \in C_a \\ 0, & Cmap_i \in C_b \end{cases} \quad (3-15)$$

Mientras el Análisis Discriminante Lineal es un método que requiere supervisión en tanto que las etiquetas son ingresadas por el usuario, el método propuesto por Yan et al. sugiere la posibilidad de emplear el algoritmo de los *K*-vecinos más cercanos para la generación del vector H de manera no supervisada. En este caso, para la identificación de los clusters de interés H se aplica el procedimiento desarrollado con base en la densidad de los colores (Sección 3.4.1), del cual se obtienen los centros de gravedad pertenecientes a las dos agrupaciones más relevantes (Fondo y Lesión) y que luego serán empleados como las dos etiquetas de entrenamiento en un algoritmo de clasificación supervisada (*Knn*, *SVM*), asignando el arreglo del Mapa de Color como los datos de evaluación. Finalmente, después de calcular las variables S_N , S_L y w_p se procede, como lo indica el quinto modulo del esquema general, obtener el nuevo arreglo del Mapa de Color que despues de normalizado P_{jn} es aplicado sobre la imagen indexada, figura 3-16.

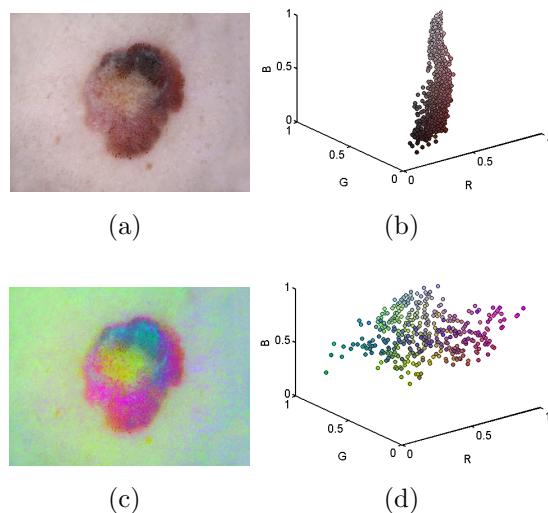


Figura 3-16.: (a). Imagen dermatoscópica original. (b). Dispersión espacial del color para la imagen original. (c). Imagen obtenida mediante la proyección del color. (d). Dispersión espacial del color para la imagen mejorada.

3.5. Marco Experimental

Se realizaron dos experimentos principales, concernientes al esquema propuesto para la remoción de vellos y el otro para identificar el método de corrección de contraste más efectivo. En general, se determinó un proceso de evaluación de manera cualitativa y cuantitativa bajo la supervisión de un equipo de especialistas en dermatología pertenecientes a la Universidad de Caldas.

3.5.1. Bases de datos

La implementación de los métodos propuestos se realizó en **Matlab® R2008a**, fueron evaluados con una base de datos preliminar compuesta por un conjunto de 54 imágenes adquiridas bajo el protocolo de adquisición diseñado (Apendice A) y 23 imágenes capturadas con un protocolo de adquisición desconocido. Las imágenes poseían un nivel de perturbación específico, es decir, algunas exhibían una influencia significativa, parcial ó nula de ruido. Tomando como ruido: vellos, marcas métricas, burbujas de aire y bajo contraste. Las imágenes generadas con el protocolo de adquisición conocido, fueron capturadas con un dermatoscópio *DermLite II Pro*, empalmado a una cámara *Canon PowerShot A2200*. Estas fueron digitalizadas en formato RGB-Color, con una dimensión de 1200x1600 que posteriormente, para efectos de procesamiento fueron reducidas a su tercera parte, sin pérdida de información.

3.5.2. Medidas de desempeño

El desempeño general de los métodos fue calculado mediante la Sensibilidad S_n y Especificidad S_p (Tabla 3-1), usando las imágenes segmentadas automáticamente I_{pm} , con respecto a las imágenes segmentadas manualmente I_{sp} por el experto. El desempeño final fue calculado mediante la media geométrica de la Sensibilidad y Especificidad de cada imagen procesada.

Tabla 3-1.: Valores usados para el cálculo del desempeño.

	Formula
Verdaderos Positivos	$T_p = \sum_i \sum_j (I_{sp} \times I_{pm})$
Verdaderos Negativos	$T_n = \sum_i \sum_j [(1 - I_{sp}) \times (1 - I_{pm})]$
Falsos Positivos	$F_p = \sum_i \sum_j [(1 - I_{sp}) \times I_{pm}]$
Falsos Negativos	$F_n = \sum_i \sum_j [I_{sp} \times (1 - I_{pm})]$
Sensibilidad	$S_n = T_p(T_p + F_n)^{-1}$
Especificidad	$S_p = T_n(T_n + F_p)^{-1}$
Desempeño Final	$P_r = \sqrt{S_n \times S_p}$

Nótese que dependiendo del experimento las imágenes segmentadas automática y manualmente definirán un objeto específico para cada ocasión. Es decir, una máscara de vellos cuando el experimento se realizó para el método de remoción de vellos. Y lesión, cuando el experimento se realizó para los métodos de realce de contraste. Aunque son las mismas medidas de desempeño para ambos experimentos, los métodos para la remoción de vellos requieren especial atención, por eso se dedica la siguiente sección a este tema.

3.5.3. Calculo de desempeño para los métodos de remoción de vellos

Para la evaluación de desempeño, fue extraída manualmente la máscara de vellos tanto para la imagen original como para la imagen procesada. Por la exagerada presencia de vellos en la imagen, la detección manual de estos es una tarea laboriosa, por esta razón, usualmente los métodos para la remoción de vellos no evalúan cuantitativamente los algoritmos ó su desempeño no es presentado mediante los valores de sensibilidad y especificidad. Con la intención de corregir este problema, se diseño una herramienta para la detección supervisada de los vellos. Esta herramienta permite modelar los vellos con unos cuantos puntos seleccionados por el especialista, figura 3.17(a). Los puntos son usados para generar una curva mediante splines y posteriormente para generar una imagen binaria con las líneas encontradas, la cual representa la máscara de vellos original, figura 3.17(b). De este modo, se reduce drásticamente la tarea de detección manual de los vellos. De la base de datos total fueron seleccionadas 36 imágenes, dentro de las cuales se detectaron manualmente 586 líneas oscuras integradas por vellos y marcas métricas. En promedio la dispersión de los vellos y marcas métricas ocupó un 3.152% de la superficie original de cada imagen, los cuales se definían con características variables, específicamente en coloración, ancho, largo y tortuosidad.

Como resultado del procedimiento de selección de vellos fueron generadas dos imágenes binarias, una que representa la máscara M_{ko} de vellos extraídos de la imagen sin procesar (Figura 3.17(b)) y la otra que corresponde a la máscara M_{ka} de los vellos que no fueron detectados con el método propuesto (Figura 3.17(d)) lo que indica que los otros vellos fueron identificados y sustituidos apropiadamente. Sin embargo, como se desea conocer el desempeño de detección del método, se calcula la imagen que posee los vellos detectados exitosamente, la cual es generada mediante la substracción de ambas máscaras, ecuación 3-16.

$$M_{kd} = M_{ko} - M_{ka} \quad (3-16)$$

Finalmente, se puede expresar cuantitativamente la precisión de los métodos en términos de la sensibilidad y la especificidad, Tabla 3-1. Donde la máscara obtenida por el método propuesto M_{kd} corresponde a la imagen generada automáticamente I_{pm} y la máscara obtenida manualmente M_{ko} equivale a la imagen segmentada manualmente I_{sp} .

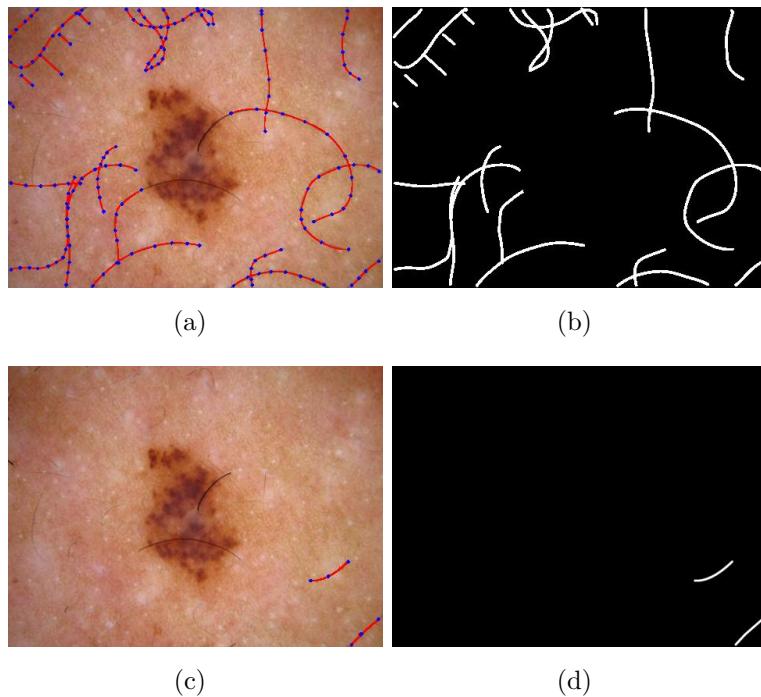


Figura 3-17.: (a). Identificación manual de los vellos sobre la imagen original, mediante la selección puntos. (b). Imagen binaria obtenida del procedimiento de identificación manual para la imagen original. (c). Identificación manual de los vellos sobre la imagen procesada, mediante la selección puntos. (d). Imagen binaria obtenida del procedimiento de identificación manual para la imagen procesada.

3.5.4. Discusión y Resultados

Como conclusión del análisis cualitativo, el equipo de dermatología inicialmente definió que el método realizado para la substracción de vellos no era eficiente, en vista que este aparte de sustituir vellos también eliminaba pigmento y márgenes asociadas a la lesión, figura 3.18(c). No obstante, se concluyó que ese inconveniente era específicamente producido por todos los objetos de la máscara M_k que ocupaban regiones asociadas a la lesión, figura 3.18(b). Como propuesta para solucionar esa complicación, se decidió eliminar de la máscara de vellos M_k , todos los objetos presentes en las regiones pertenecientes a lesión. Lo cual involucró el uso de un método que no demandará suficientes recursos y que adicionalmente se desempeñara apropiadamente. En esos términos, fue seleccionado el método de Otsu. Como resultado, se obtuvieron imágenes más precisas, procesadas por una técnica eficiente y de bajo costo computacional en tiempo y memoria.

Al repetir el análisis sobre las imágenes procesadas mediante el método modificado, el equipo de especialistas lo aprobó porque no altera la calidad de la imagen, no inserta ruido y no deteriora las regiones de estudio (Figura 3.18(e)).

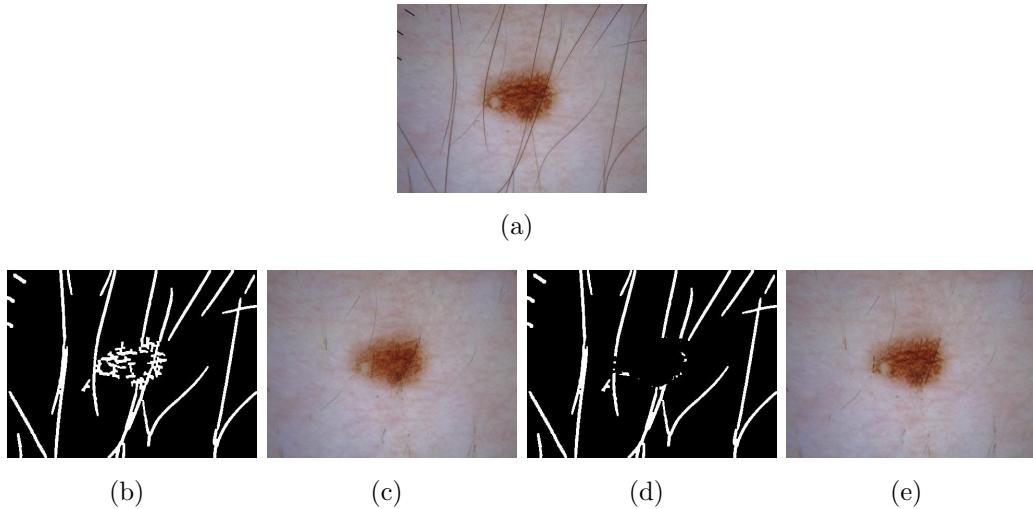


Figura 3-18.: (a). Imagen dermatoscópica con presencia de vellos. (b). Máscara obtenida con el método inicialmente propuesto para la detección de vellos. (c). Imagen resultante del método propuesto para la eliminación de vellos. (d). Máscara obtenida con la modificación del método inicial para la detección de vellos. (e). Imagen resultante del método modificado para la eliminación de vellos.

Para el estudio cuantitativo, además del método propuesto, en el análisis de desempeño se incluyó la técnica popularmente empleada para la remoción de vellos, *DullRazor*. Respecto a la detección de vellos, los valores de desempeño para ambos métodos son mostrados en la Tabla 3-2. Los resultados presentados indican la superioridad del método propuesto para detectar eficientemente los vellos.

Tabla 3-2.: Desempeño general de los métodos utilizados para la remoción de vellos.

Método	Detección de Vellhos	Sustitución de Máscara	Desempeño	
			Sens. %	Espec. %
<i>DullRazor</i>	Operación Morfológica de Cierre	Interpolación Bilineal	88.65	99.81
Propuesto	DOG Convolución, Umbralización	Reconstrucción Morfológica Multiescala	94.14	99.89

En general, la estructura del método propuesto para la detección de vellos resulta ser adecuada, en vista que no elimina regiones asociadas a la lesión y presenta varias ventajas en comparación con otros métodos que cumplen la misma función. Específicamente, se comparó el método con el algoritmo *DullRazor* [55] y la técnica de reconstrucción de imágenes basada

en ejemplos (Exemplar-Based Inpainting) [27]. Al aplicar DullRazor sobre las imágenes de la base de datos se determinó que procesa las imágenes en un promedio de 1.08 seg/imagen (Lenguaje C), mientras el método propuesto lo hizo en un promedio de 13.84 seg/imagen (Matlab). Sin embargo, DullRazor presentó en ocasiones fallas, específicamente en la eliminación de vellos donde la región de interés posee líneas paralelas. Además no detecta con eficiencia los vellos sobre la imagen y al reconstruir las regiones ocupadas por los vellos mediante interpolación lineal agrega en la imagen final discontinuidades, difumina regiones y mezcla colores [2]. Paralelamente, se evaluó el algoritmo de reconstrucción de imágenes basado en ejemplos¹, siendo evidente el exagerado costo computacional necesario para obtener la superficie que sustituye la región de un solo vello, además, aunque la aproximación también es construida con base en la superficie que rodea los vellos, este no generó una representación adecuada, confirmando lo expuesto en [2]. La figura 3-19, muestra la comparación de las imágenes obtenidas con los métodos analizados.

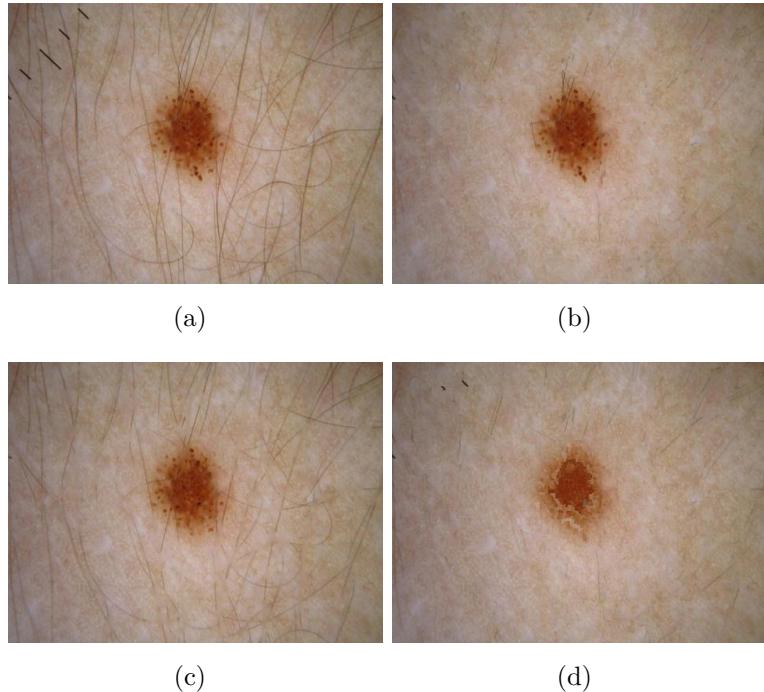


Figura 3-19.: (a). Imagen dermatoscópica con presencia de vellos. (b). Imagen obtenida con el método de eliminación de vellos propuesto en este trabajo. (c). Imagen obtenida mediante el método DullRazor. (d). Imagen resultante luego de aplicar la reconstrucción de las superficies ocupadas por los vellos.

En tanto que los métodos propuestos para la corrección de contraste, fueron evaluados asumiendo que el método más eficiente corresponde al que resalta apropiadamente la región de interés sin incrementar el ruido. Entonces, teniendo en cuenta que la manera mas eficaz

¹Cortesía de Sooraj Bhat <http://www.cc.gatech.edu/~sooraj/inpainting/>

de evaluar la región de interés es la segmentación, cada imagen procesada con los métodos propuestos fue posteriormente segmentada con el método de Otsu [65] y comparada con la segmentación manual ofrecida por el especialista. En el análisis, además de los métodos propuestos para el realce de contraste, también fueron considerados los espacios de color $L^*a^*b^*$, XYZ , $CMYK$, $u'v'L$ y L^*ch . El desempeño asociado a cada transformación se presenta en la Tabla 3-3.

Aunque las transformaciones de color más correlacionadas con la imagen original como XYZ ó $CMYK$ deberían mostrar desempeños similares a la imagen en el espacio RGB , el contraste que ofrecen es insuficiente para detectar la lesión de manera precisa. Para imágenes dermatoscópicas el espacio $CMYK$ atenua bordes difusos haciendo más uniforme el cambio entre piel y lesión por el contrario el espacio XYZ provoca un contraste exagerado de tal manera que ingresa ruido.

Tabla 3-3.: Desempeño de los métodos para el realce de contraste.

Método de Realce	Desempeño de Segmentación
$L^*a^*b^*$ to RGB	54.34
$L^*a^*b^*$ to XYZ	66.04
$CMYK$	7.29
$L^*a^*b^*$	21.86
XYZ	82.77
XYZ to $u'v'L$	14.48
$L^*a^*b^*$ to L^*ch	70.74
<i>PCA Projection</i>	26.87
<i>FDA Projection</i>	26.25
<i>Yan et al. Projection</i>	61.03
RGB	83.72
Compactación del Color	83.62
Proyección Discriminante del Color	65.45

3.6. Conclusiones

Entre las características principales para la identificación del melanoma se encuentra el borde, el cual generalmente posee bajo contraste y el notable ruido inherente a lesiones pigmentadas de la piel. Particularmente el vello e iluminación no homogénea son los más desfavorables, provocando que la detección automática sea una tarea compleja. Para combatir las principales dificultades de este tipo de imágenes en este trabajo se propone un modulo para el

preprocesado de la imagen, con el cual la detección de la lesión melanocítica (Segmentación) sea exitosa.

Para la detección de vellos, se empleo la convolución de la imagen con una ventana correspondiente a la primera derivada de la función guassiana rotada en los ángulos principales, luego se encontró una representación de la superficie ocupada por los vellos mediante la dilatación iterativa de la imagen, con lo cual se corrige la falsa detección de vellos y se obtiene una representación uniforme y apropiada que no altera bruscamente la estructura morfológica de la lesión. Los resultados obtenidos sugieren que el método propuesto para la eliminación de vellos cumple exitosamente su función, consiguiendo un desempeño general equivalente al 96.97 %. Lo que indica que el método contribuye a despejar de la imagen todo tipo de estructuras indeseables.

Con respecto a la corrección de contraste de la región de interés, fueron propuestos dos algoritmos que promueven la apropiada distribución del Mapa de Color, corrección de contraste basado en la compactación del color y basado en la proyección discriminante del color. El primer método está basado en la redistribución de todas las intensidades del Mapa de Color alrededor de las dos tonalidades predominantes en la imagen, asociadas a lesión y piel. En cambio el segundo, está desarrollado con la intención de obtener la distribución más discriminante del Mapa de Color, que reubica sobre el espacio las intensidades que mejor definen el objeto al que pertenecen (Lesión y Piel). En relación a otros procedimientos, los resultados indican que ambos métodos aportan considerablemente en el realce de contraste, en especial el método de la compactación del color que ocupa el segundo lugar en mejor desempeño, debajo del espacio de color original (RGB). Aun así, en vista que el mapa de color puede ser extraído de cualquier imagen compuesta por tres canales, los métodos de realce de contraste propuestos pueden ser aplicados sobre estas. En este caso se utilizaron sobre imágenes dermatoscópicas, sin embargo, también pueden ser aplicados sobre otro tipo de imágenes a color.

A causa de no encontrar un método que incremente eficientemente el contraste sobre la región de interés, como estrategia alterna se decidió analizar el comportamiento de la ecualización del histograma, no obstante, nuevamente se obtuvieron resultados desfavorables. Con base en los resultados obtenidos, es notable que el espacio de color original posee el contraste más adecuado sobre la región de interés, siendo el que favorece con mayor precisión la detección automática (Segmentación) de las lesiones pigmentadas de la piel. Por este principal aporte, se decide trabajar con la imagen original (filtrada y sin vellos) en las etapas posteriores.

4. Segmentación

4.1. Introducción

El propósito de la segmentación es delimitar dentro de la imagen todas las regiones asociadas a lesión, separándola de la piel, del cual como resultado se genera una imagen binaria [0, 1], donde el bit 1 representa las regiones correspondientes a lesión y el bit 0 corresponde a piel [78]. La etapa de segmentación no solo ayuda a determinar exactamente el área asociada a las regiones de interés (Lesión Pigmentada de la Piel) sino que también aporta a que los algoritmos de extracción de características realicen sus mediciones exclusivamente sobre el área afectada, contribuyen con la exactitud del diagnóstico y reducen tiempos de análisis en regiones irrelevantes. Como principales aportes, se presenta un método que segmenta la lesión pigmentada de la piel empleando como criterio el color y también se elabora un método que contribuye a incrementar el desempeño de segmentación, básicamente restringiendo la imagen original a la superficie perteneciente a la región de interés. Ver figura 4-1.

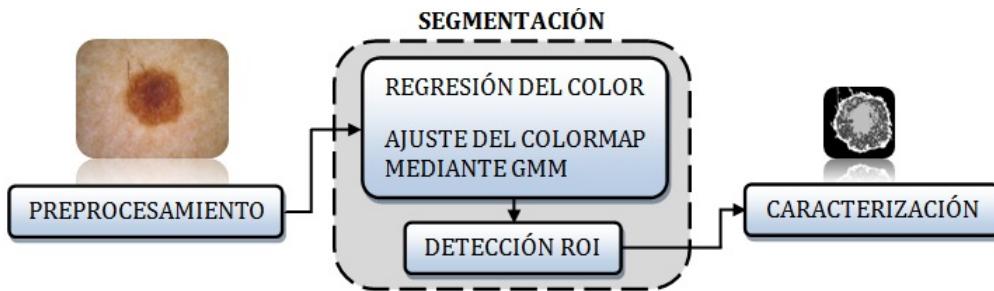


Figura 4-1.: Esquema general del modulo de Segmentación.

4.1.1. Estado del Arte

Las técnicas frecuentemente utilizadas para la segmentación de lesiones pigmentadas se clasifican en [15]: métodos basados en regiones [70], métodos iterativos como crecimiento de regiones, contornos activos (Snakes) [99, 100, 48, 19], métodos de umbralización [17, 13, 56, 74, 40] o métodos de clustering [80, 62]. Aunque los métodos de umbralización son los más populares, el método de Otsu es el preferido, básicamente por su sencillez y buen desempeño. No obstante, su eficiencia es cuestionada, específicamente porque un umbral lineal es incapaz de conservar regiones periféricas de la lesión que se combinan con el fondo, con lo cual es

común que este tipo de métodos sufra de sobre-segmentación. Otros autores proponen la detección del borde mediante la búsqueda del gradiente [73, 11], sin embargo, en muchas ocasiones la lesión posee patrones de uniformidad, como bordes difusos, los cuales podrían pasar desapercibidos y fácilmente el método se vuelve impreciso [88]. Si bien el método de contornos activos es también renombrado por ser considerablemente eficiente en la detección de lesiones con contornos bruscos, su debilidad radica en varios aspectos: la elevada cantidad de iteraciones requerida para la finalización, haciéndolo poco práctico; la fuerte influencia que posee el contorno inicial, mientras más ajustado a las fronteras de la lesión más preciso el desempeño [63], además su desempeño es inestable respecto a las estructuras internas de esta, siendo impreciso cuando la parte interna de la lesión posee regiones variables.

Con base en la bibliografía [99, 100, 17], la mayoría de trabajos en el área orientan sus enfoques de manera independiente al color, fundamentados con el hecho de que las lesiones pigmentadas frecuentemente presentan una variedad de colores que son similares a los tonos localizados en regiones de piel, como consecuencia, se prefieren otros criterios de segmentación diferentes al color [88, 70]. A pesar de lo anterior, en este trabajo se encuentra apropiado implementar un análisis en torno a esta variable, adoptando el color como herramienta principal para determinar las regiones en la imagen que se encuentran relacionadas a lesión y piel, esencialmente, porque el color es la característica más prominente en el reconocimiento visual de la lesión pigmentada de la piel. Para tal fin son propuestos dos métodos que buscan separar de manera precisa las formaciones principales del color y para atenuar el impacto generado por la similitud de colores Lesión-Piel se filtra todo objeto fuera de la región de interés mediante el algoritmo de detección ROI.

4.2. Descripción general

En el espacio de color, las imágenes dermatoscópicas poseen la propiedad de conformar agrupaciones individuales para sus objetos principales que son, lesión y fondo, (Figura 4.2(a)). Con base en esa premisa, en el capítulo previo se elaboró un procedimiento que eleva el contraste sobre la región de interés sin incrementar la definición de regiones asociadas a piel. Ahora, en este capítulo se proponen dos enfoques desarrollados alrededor de ese concepto, específicamente, identificando las fronteras que separan eficientemente las distribuciones predominantes en el espacio de color, figura 4.2(b).

4.2.1. Segmentación mediante la regresión del color

Considere una imagen *PSL* (Lesión pigmentada de la piel) normalmente obtenida (Figura 4.2(a)), es posible notar las dos agrupaciones principales en la dispersión del mapa de color, figura 4.2(b). Con el ánimo de obtener una representación más detallada de ambas agrupaciones se analiza la dispersión del color en dos dimensiones, figura 4-3. A partir de esas proyecciones, es visible la alta dependencia entre los canales $G - B$, además, es más evidente

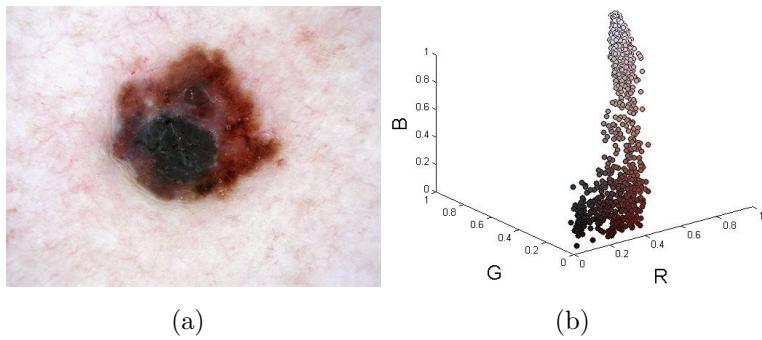


Figura 4-2.: (a). Imagen dermatoscópica. (b). Dispersión del color.

la separación entre las parejas restantes, $(R - B, R - G)$. Teniendo en cuenta lo anterior y con la intención de facilitar la manipulación del color se trabaja con la combinación de canales que más información ofrece, es decir, los canales menos correlacionados. Por lo tanto, la combinación de los canales $G - B$ puede ser omitida, en vista que ofrece información redundante.

Se puede observar que los dos canales menos correlacionados son los canales $R - B$, figura 4.3(a). Luego note que la zona media de su dispersión, es la región del espacio en la que principalmente se evidencia la separación de ambos grupos, con lo cual, el valor medio de los datos es una región indicada para ubicar las fronteras de dispersión de ambas clases. Ahora bien poniendo en práctica lo anterior, son centrados los datos en el origen. Entonces se obtiene el valor absoluto de los datos resultantes, ecuación 4-1, lo que permite la fácil visualización de los puntos que corresponden tanto a lesión como a fondo, específicamente la transición de clases se ubica en la región donde los puntos tienden a ser mínimos, figura 4.4(a).

$$F(R) = |B - \bar{B}| \quad (4-1)$$

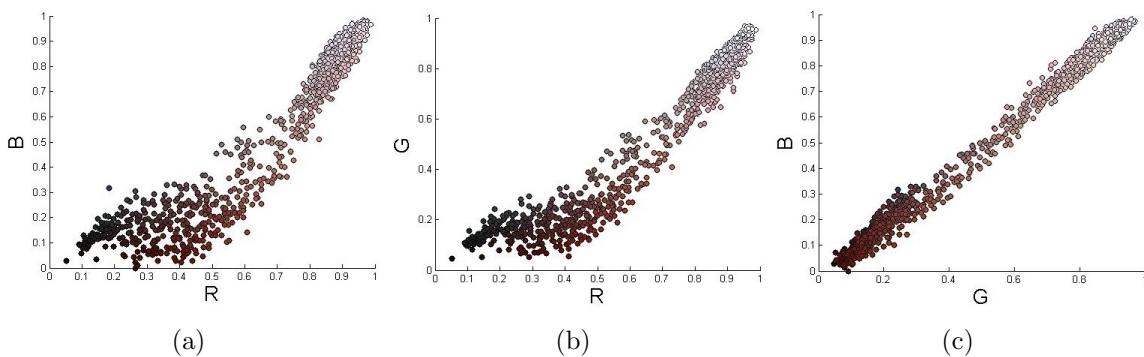


Figura 4-3.: (a). Proyección espacial a los canales $R - B$. (b). Proyección espacial a los canales $R - G$. (c). Proyección espacial a los canales $G - B$.

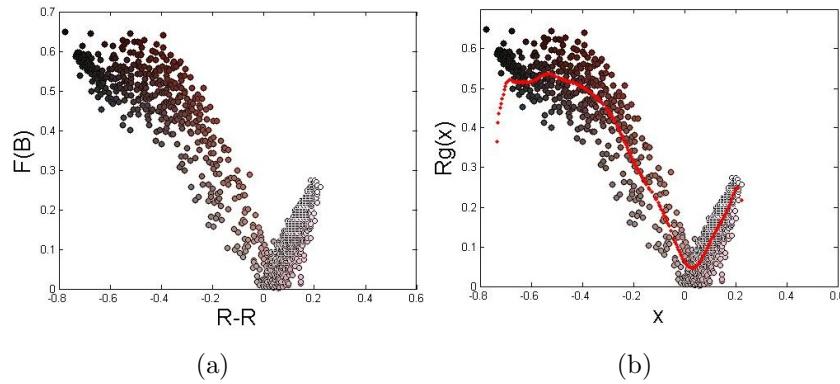


Figura 4-4.: Transformación del color que contribuye a la separación de los clusters.

Sin embargo, la identificación precisa del lugar asociado al valor mínimo no es posible, dada la numerosa cantidad de puntos en esa región, por lo tanto, se obtiene la regresión del color con la intención de reconocer eficientemente la posición de este punto. La regresión del color se realiza mediante ajuste polinomial por mínimos cuadrados [86], preferiblemente de grado elevado para capturar una buena representación de los datos, figura 4.4(b).

No obstante, el grado elevado de la función polinomial en general provoca que la regresión calculada no represente fielmente las regiones externas de la distribución, por lo tanto, se determina un intervalo de confianza en el cual se encuentra con mayor probabilidad el valor mínimo. El intervalo de confianza es generado mediante la suposición de que la dispersión de los datos en el eje horizontal posee una distribución normal, específicamente porque la mayor concentración de los puntos se sitúa en la región cercana al mínimo (Figura 4.4(b)). Además, la cantidad de puntos en las regiones externas tiende a ser cada vez menor, en consecuencia, es posible aplicar sobre la regresión obtenida Rg el criterio $T_{hr} = \mu \pm \sigma$ sin pérdida de información, región sombreada en la figura 4-5. Luego, el valor mínimo que separa los colores asociados a fondo y lesión, se encuentra con facilidad.

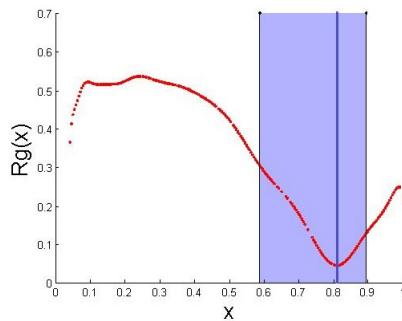


Figura 4-5.: Reconocimiento del umbral que separa las clases (Piel y Lesión).

Por último, en el Mapa de Color se asigna una etiqueta a todos los colores que pertenecen a fondo, es decir, todos los colores superiores al umbral localizado, luego el nuevo Mapa de color es reemplazado en la imagen indexada y como resultado se obtiene la imagen segmentada, la imagen resultante posee algunas regiones sobre el fondo que fácilmente son eliminadas con filtrado de área, figura 4-6.

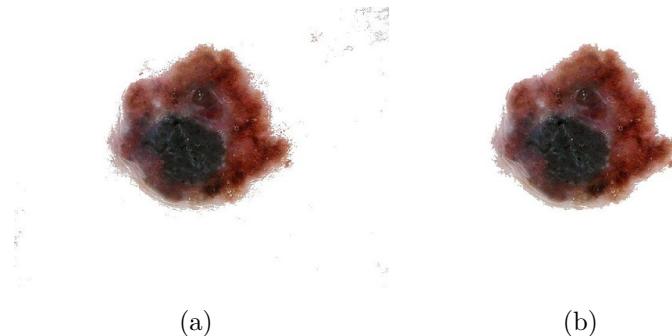


Figura 4-6.: (a). Imagen resultante de eliminar los colores superiores al umbral. (b). Imagen segmentada.

4.2.2. Ajuste del Mapa de color al modelo Gaussiano

Considere la lesión dermatoscópica de la figura 4.7(a) tomada bajo el protocolo de adquisición diseñado en este trabajo (Apéndice A) y su dispersión del color, figura 4.7(b). Para fines prácticos, observe la región de interés (Figura 4.7(c)), en la cual han sido determinados manualmente los bordes que separan la lesión pigmentada y el fondo, esta imagen fue segmentada manualmente por un dermatólogo experto.

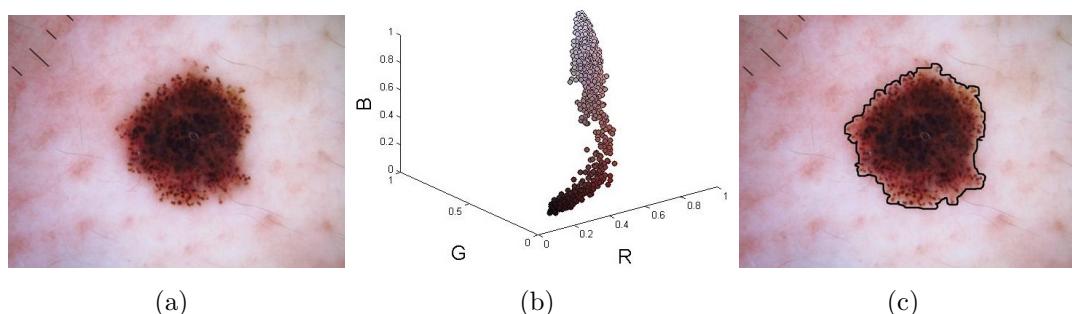


Figura 4-7.: (a).Imagen dermatoscópica. (b). Diagrama de dispersión del color. (c). Bordes detectados por el especialista.

Al graficar de manera separada todos los colores que se encuentran dentro y fuera del perímetro resaltado por el especialista, (Figura 4-8), es posible notar que ambas agrupaciones

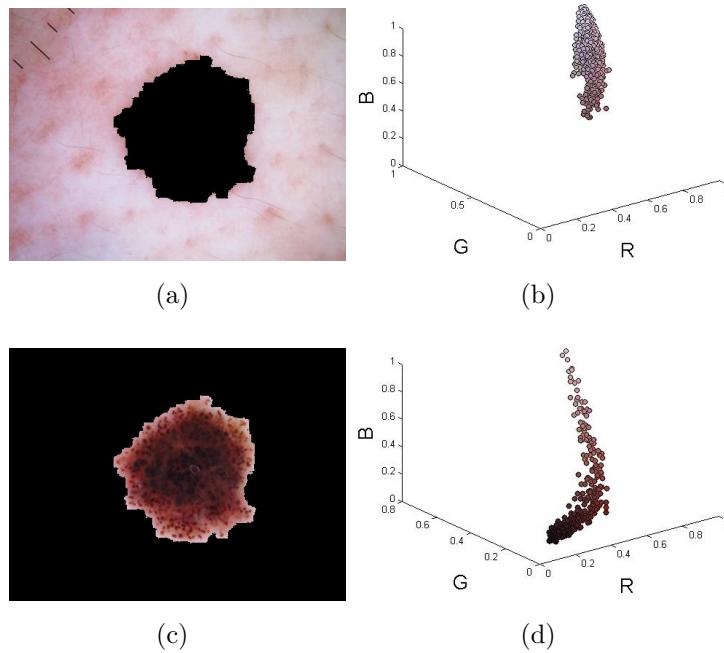


Figura 4-8.: Imagen segmentada manualmente, conservando las regiones asociadas a piel (a) y lesión (c). Diagramas de dispersión de los colores asociados a piel (b) y lesión (d).

tienden a concentrarse en puntos precisos de su distribución. Específicamente, los colores correspondientes a piel (Figura 4.8(b)) se agrupan en las regiones cercanas al límite del color blanco [1, 1, 1] y los colores asociados a lesión se concentran en las regiones cercanas al color negro [0, 0, 0]. Sin embargo, como consecuencia de que las lesiones se difuminan con la piel, la distribución del color para la lesión se caracteriza por estar más dispersa en el espacio de color, figura 4.8(d). En vista que ambas agrupaciones se concentran en un centro de gravedad específico, es posible aprovechar esta cualidad para el reconocimiento de los colores asociados a las agrupaciones principales, luego segmentar.

Teniendo en cuenta que las imágenes dermatoscópicas poseen un canal que no ofrece suficiente información, nuevamente se emplean los dos canales menos correlacionados (Figura 4.9(a)). Debido a la alta semejanza entre las agrupaciones principales y la distribución gaussiana, la identificación de los clusters se realizó mediante el ajuste del mapa de color al modelo gaussiano, para lo cual se emplea el algoritmo de modelos de mezclas gaussianas *GMM*, [61, 36, 60].

Finalmente, luego de identificar ambas agrupaciones (Figura 4.9(b)) se procede a etiquetar el mapa de color y a sustituirlo sobre la imagen indexada, (Figura 4.10(a)), a la cual se le aplica filtrado de área y la operación morfológica de dilatación con el interés de suavizar los bordes y recuperar regiones asociadas a bordes difusos, generando la imagen segmentada, figura 4.10(b).

4.3 Mejoramiento de la Segmentación mediante la detección de la región de interés (ROI)

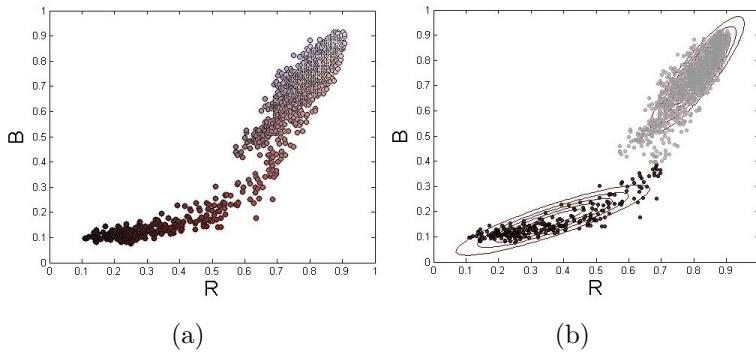


Figura 4-9.: (a). Proyección espacial de color en los canales $R - G$. (b). Ajuste gaussiano del color obtenido mediante la técnica de GMM .

4.3. Mejoramiento de la Segmentación mediante la detección de la región de interés (ROI)

Considerando la amplia variedad de estructuras, formas y características físicas (Iluminación, Contraste, Vellos, etc.) inmersas en las lesiones melanocíticas, fácilmente se puede generar una debilidad en el reconocimiento automático de la lesión (Segmentación). Con la intención de reducir el posible error asociado a esas características no solo se propone incluir la etapa de preprocesamiento, sino también se propone un método que ofrece una detección parcial de la región ocupada por la lesión melanocítica, el tipo de método propuesto popularmente se clasifica en la literatura como Detección de la Región de Interés (ROI - Siglas en Ingles) y básicamente contribuye a que la segmentación final de la lesión sea más precisa. Un caso práctico se presenta en la imagen 4-11, nótese que las regiones externas de la imagen poseen intensidades oscuras y similares a las tonalidades que definen la lesión pigmentada de la piel y podrían ser tenidas en cuenta en la segmentación final. Adicionalmente, cabe mencionar

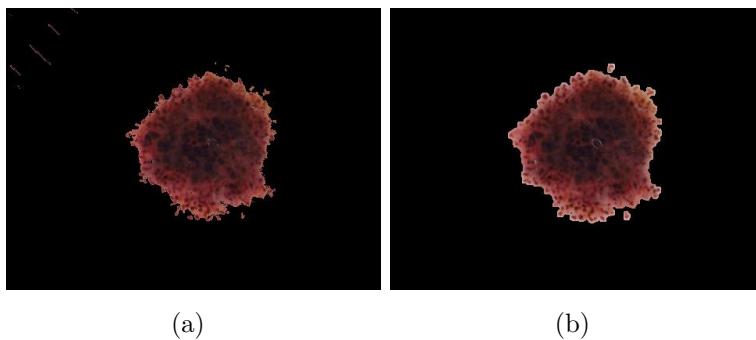


Figura 4-10.: (a). Imagen resultante de aplicar clustering mediante GMM . (b). Imagen segmentada.



Figura 4-11.: (a). Imagen normal con presencia de objetos que perjudican la etapa de segmentación. (b). Detección manual de la región de interés.

que se encuentran cuerpos con características cromáticas similares que pueden poseer una apariencia aleatoria y también pueden ser localizadas en cualquier parte de la imagen. Es necesario tener en cuenta ese tipo de características desconocidas principalmente porque la piel es el órgano más expuesto del cuerpo humano y fácilmente se pueden generar daños superficiales localizados en la vecindad de la lesión melanocítica.

Particularmente, la imagen 4.11(a) posee varios de esos objetos, entre los que se destacan, la gran cantidad de vellos dispersos en la imagen, líneas con tonos blancos, poros de dimensión significativa que no logran ser eliminados en la etapa de filtrado y además el efecto tipo túnel incluido en la etapa de adquisición como consecuencia de no respetar el protocolo diseñado. El efecto tipo túnel se presenta como un patrón de iluminación especial, en el que la lesión se encuentra bien contrastada, pero a sus alrededores la iluminación se atenúa uniformemente hasta que las regiones externas tienden a poseer un color oscuro. Este patrón es debido a que las superficies corporales no son suficientemente planas.

En vista que la presencia de objetos aleatorios puede ser ocasionada de manera natural o accidental y teniendo en cuenta que estos podrían alterar el diagnóstico se propone como estrategia para no incluirlos, detectar el perímetro cuadrado que encierra la lesión melanocítica, para luego limitar el procesamiento exclusivamente sobre esta región. La figura 4.11(b), posee la detección manual de la región de interés, es necesario que la región detectada encierre con precisión la dispersión de la lesión y a la vez no posea objetos aleatorios indeseables.

4.3.1. Descripción del método para la detección ROI

La lesión melanocítica es la región más contrastada en la superficie de las imágenes dermatoscópicas. No obstante, la presencia de factores adversos contamina el contraste de la región de interés, sin embargo, la implementación de la etapa de preprocesamiento es desarrollada con el interés de generar un prototipo cada vez más cercano al ideal, figura 4-12.

A causa de la atenuación del ruido sobre la imagen original, como consecuencia la imagen

4.3 Mejoramiento de la Segmentación mediante la detección de la región de interés (ROI)

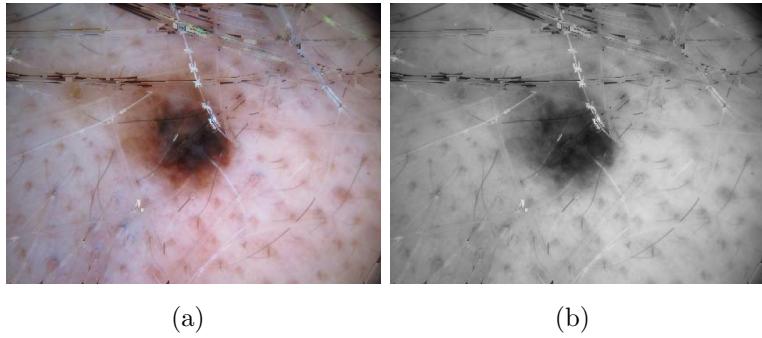


Figura 4-12.: (a). Imagen dermatoscópica luego de ser empleado el modulo de preprocesamiento propuesto. (b). Imagen preprocesada en escala de grises.

resultante ofrece amplias facilidades para la detección de la región de interés, como por ejemplo, respeta ampliamente las características que definen la lesión melanocítica y despeja considerablemente toda la región ocupada por los vellos.

Ahora bien, incluso en la imagen en escala de grises es notable que la región de interés posee mayor contraste. Aprovechando que esta región no se fracciona en múltiples objetos, es posible identificar su posición sumando todas las intensidades asociadas a cada fila en la columna i -esima de la imagen, por comodidad previamente se aplica el complemento de la imagen I_{n*m}^C para convertir relevantes las intensidades oscuras, ecuación 4-2.

$$Sf_i = \sum_{j=1}^n I^C(j, i) \quad (4-2)$$

Al aplicar la ecuación 4-2 sobre la imagen I_{n*m}^C se obtiene la señal Sf , luego de normalizada se comporta como en la figura 4.13(a). Aunque el preprocesamiento busca eliminar todo el ruido posible y así resaltar la región de interés, la figura 4-13 es un claro ejemplo de la complejidad asociada al tema. Si la imagen tuviera total contraste y no estuviera contaminada con ruido las regiones fuera del intervalo definido en las señales de la figura 4-13, serían aproximadamente iguales a cero. La región media de la señal (Región encerrada por el intervalo) corresponde a la dispersión de la lesión de manera vertical dentro de la imagen y básicamente no se define claramente, figura 4.13(a). Asimismo para la dispersión horizontal de la lesión, figura 4.13(b). Para resaltar estas regiones, las zonas externas de la señal son atenuados al restar la señal original normalizada $\bar{S}f$ con la señal \hat{y} , la cual aproxima las regiones extremas de la señal original sin considerar la concavidad asociada a la lesión. Teniendo en cuenta que la función con ese tipo de características es una función parabólica, se realiza el modelado de la señal original con una aproximación parabólica. La cual es modelada mediante la técnica de mínimos cuadrados.

Básicamente la técnica de mínimos cuadrados contribuye a encontrar los parámetros de la función modelo que se aproxima con mayor exactitud a la señal original, en este caso la señal

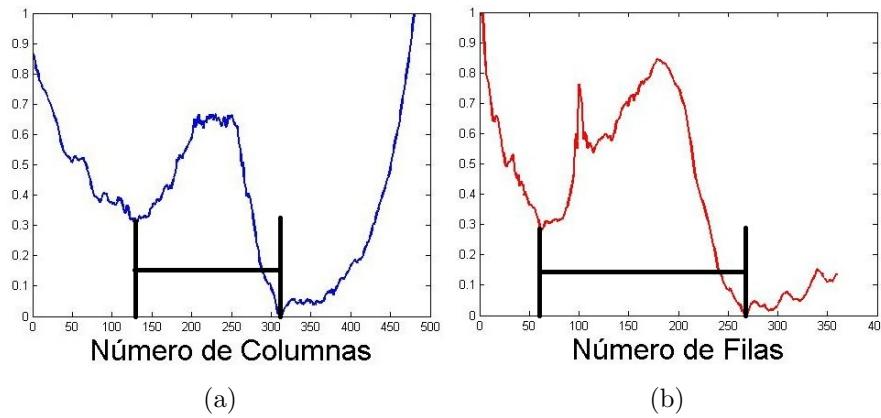


Figura 4-13.: Dispersión de la lesión melanocítica tanto por columnas como por filas.

modelo es una ecuación parabólica y la representación por mínimos cuadrados se obtiene encontrando los parámetros de la ecuación 4-3, (Ver Anexo B).

$$Er = \sum_{i=1}^n (\overline{Sf}_i - \hat{y}_i)^2 = \sum_{i=1}^n (\overline{Sf}_i - [ax^2 + bx + c])^2 \quad (4-3)$$

Para obtener los valores que hacen mínima la diferencia entre la función original y la función a estimar, inicialmente se deriva 4-3 con respecto a cada parámetro de la función modelo, se iguala a cero cada expresión y finalmente se reorganizan las ecuaciones en un sistema matricial dando como resultado la ecuación 4-4.

$$\underbrace{\begin{bmatrix} \sum x^4 & \sum x^3 & \sum x^2 \\ \sum x^3 & \sum x^2 & \sum x \\ \sum x^2 & \sum x & n \end{bmatrix}}_A \underbrace{\begin{bmatrix} a \\ b \\ c \end{bmatrix}}_X = \underbrace{\begin{bmatrix} \sum \bar{Sf} * x^2 \\ \sum \bar{Sf} * x \\ \sum \bar{Sf} \end{bmatrix}}_B \quad (4-4)$$

$$X = A^{-1}B \quad (4-5)$$

Al generar la función aproximación \hat{y} mediante los parámetros obtenidos con 4-5, se obtiene una señal como la ubicada en la figura 4-14, que corresponde a la función de aproximación asociada a la distribución de la lesión por filas y por columnas. En caso de que esta función sea convexa la identificación de la distribución asociada a la región de interés puede ser modificada, por consiguiente, siempre es evaluada la concavidad de la función \hat{y} al verificar el signo del parámetro a . De ser $a < 0$, la señal aproximación \hat{y} no es considerada en el análisis posterior, ya que esto indicaría que la región de interés es muy dispersa dentro de la señal original, tal como pasa en la figura 4.14(b).

Procediendo a eliminar las regiones laterales de la lesión, ahora solo basta restar \hat{y} de la señal inicial \overline{Sf} , como indica la ecuación 4-6.

$$SR = \overline{Sf} - \hat{y} \quad (4-6)$$

4.3 Mejoramiento de la Segmentación mediante la detección de la región de interés (ROI)

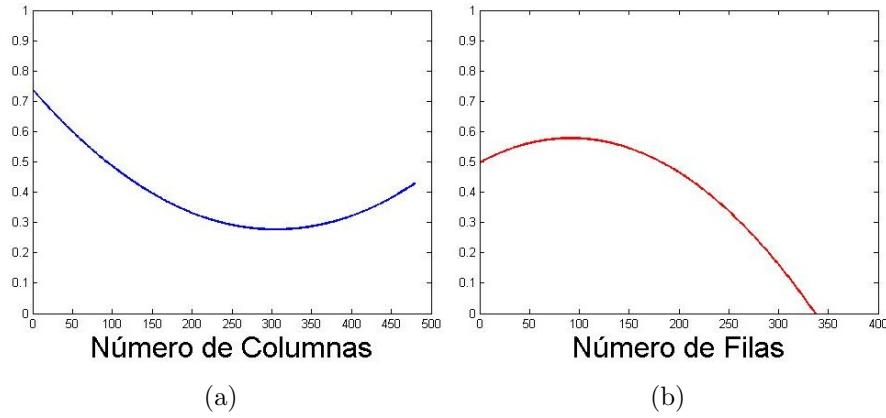


Figura 4-14.: Aproximación parabólica de la señal original, tanto por filas como por columnas.

Al obtener la señal *SR* (figura 4-15), la región de interés se torna más notable. Sin embargo, para garantizar que sea completamente distinguible, se propone agregar la extracción de una función base, que como en el paso previo también se eliminará de la señal *SR* con la intención de atenuar las regiones que no son de interés. La función base corresponde a la función envolvente inferior construida mediante interpolación lineal empleando los valores mínimos que tienden a localizarse en la base de la señal.

La figura 4.15(a), muestra en tonos rojos los valores mínimos de la señal filtrada. Además, encerrados en círculos negros se ubican los puntos mínimos de la señal que conservan la tendencia de localizarse en la base, los cuales fueron identificados al verificar que se encuentran dentro del intervalo $[\mu - \sigma^2, \mu + \sigma^2]$ luego de haber sido modelada la altura de los valores mínimos mediante la distribución de probabilidad Normal. Finalmente la función envolvente

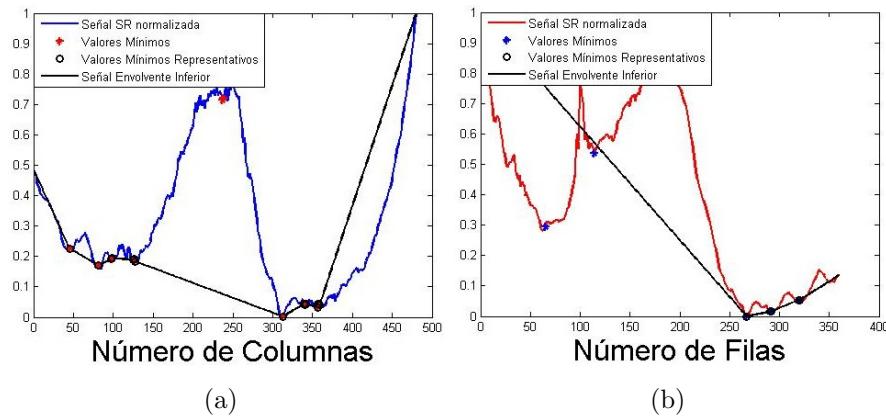


Figura 4-15.: Resultado parcial del procedimiento para resaltar la región de interés por filas y columnas.

inferior Se , es construida con base en los valores mínimos principales también mostrada en la figura 4.15(a), la cual está definida en color negro.

En este punto, nuevamente se procede a obtener la diferencia entre la señal actual SR y su señal envolvente inferior Se . Como resultado, se consigue resaltar con suficiente exactitud el intervalo asociado a la región de interés, figura 4-16. La detección precisa del intervalo se identifica empleando nuevamente el umbral $Thr = \mu + \sigma^2$ ya que con el procesado previo la región de interés se encuentra adecuadamente contrastada en relación a la base, con lo cual el valor medio de la señal se encuentra ubicado en una región que fácilmente discrimina entre la región de interés (Lesión) y base (Piel ó Fondo). En la figura 4.16(a), esta región \overline{ROI} es identificada por estar encerrada por dos líneas paralelas con trazo continuo y color negro, perteneciendo a todos los puntos que superan el umbral Thr .

Para garantizar que la lesión está completamente definida dentro de ese intervalo y no eliminar regiones importantes, se identifica el valor mínimo de la señal que se encuentra ubicado antes del límite inferior de la región encontrada con el ultimo umbral \overline{ROI} , ese punto corresponde al límite inferior final. Para encontrar el límite superior final, se procede a identificar el primer valor mínimo localizado después del límite superior que encierra la región de interés \overline{ROI} . La Figura 4.16(a) indica en líneas paralelas con trazos discontinuos y tonos rojos la detección de los límites finales.

El mismo proceso expuesto anteriormente se repite con la señal obtenida mediante la suma de todas las intensidades por columna que se encuentran ubicadas en la fila $j - esima$, ecuación 4-7.

$$SC_j = \sum_{i=1}^n I^C(j, i) \quad (4-7)$$

Mediante los cuatro límites que encierran la región de interés, en otras palabras, las dos parejas que detectan la lesión tanto por filas como por columnas, pueden ser empleadas

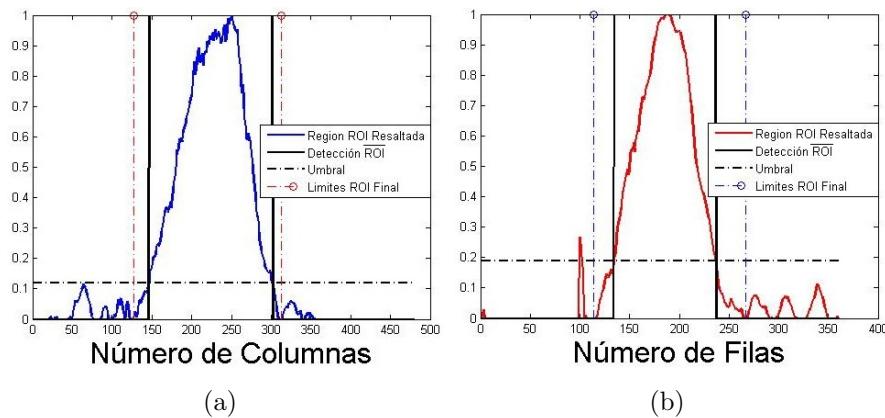


Figura 4-16.: Resultado final del procedimiento para identificar la región de interés, por filas y columnas.

para generar una máscara binaria con las mismas dimensiones de la imagen original, figura 4.17(a). Luego, aplicada la máscara sobre la imagen obtenida en la etapa preprocesamiento se obtiene exclusivamente la región perteneciente a la lesión (figura 4.17(b)) de la cual se puede extraer esta región para análisis posteriores, figura 4.17(c).

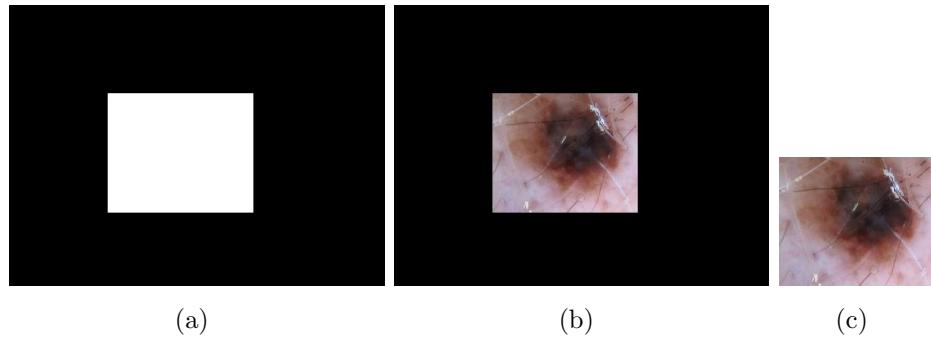


Figura 4-17.: (a). Máscara binaria que resalta la región de interés ROI. (b). Imagen original restringida a la Máscara ROI. (c). Imagen asociada a la región ROI.

4.4. Marco Experimental

4.4.1. Bases de datos

El análisis de desempeño de los métodos propuestos fue llevado a cabo con el empleo de 77 imágenes dermatoscópicas, entre ellas 27 imágenes obtenidas por los especialistas bajo el protocolo de adquisición y 27 imágenes sin el protocolo de adquisición, en las cuales se descuidó el procedimiento de captura, las 23 imágenes restantes fueron aportadas por el equipo de especialistas, tomada de [35].

Del protocolo de adquisición se estableció la dimensión de las imágenes de 1200x1600 pix, sin embargo para efectos de procesamiento fueron reducidas al 30 % de la dimensión original sin pérdida de información. Con la reducción establecida, el tamaño promedio del cuadrado que encierra perfectamente la superficie de las lesiones es: 118(53)*pix.* en filas y 121(69)*pix.* columnas, donde los valores encerrados por paréntesis corresponden a la desviación estándar.

4.4.2. Medidas de desempeño

Los dos métodos propuestos para la segmentación de la imagen fueron comparados con el algoritmo de segmentación popular, Método de Otsu y con base en el cálculo de las medidas de sensibilidad y especificidad (Tabla 3-1) sobre las imágenes segmentadas de manera automática y de manera manual por parte del experto.

La evaluación del algoritmo para la detección *ROI*, fue realizada al considerar el porcentaje de pixeles que siendo de la región encontrada I_{roi} pertenecen igualmente a la superficie

de la lesión, ecuación 4-8. La superficie de la lesión es representada por la imagen binaria perteneciente a la segmentación manual generada por el equipo de especialistas I_e .

$$D_{ROI} = \frac{\sum \sum (I_e \cap I_{roi})}{\sum \sum I_e} * 100 \% \quad (4-8)$$

4.4.3. Discusión y Resultados

Método de detección de la Región de Interés

En el análisis de desempeño del método diseñado para la identificación de la región de interés ROI, fue considerado el efecto de algunas transformaciones del espacio de color, pero también de la imagen original presentada en el espacio *RGB*. Luego de generar la imagen binaria asociada a la Región de Interés ROI, fue calculado el desempeño de detección mediante la ecuación 4-8. La Tabla 4-1, presenta los desempeños para las transformaciones del color incluidas en el estudio.

Tabla 4-1.: Desempeño del método propuesto para la detección ROI.

Método de Realce	Desempeño ROI
$L^*a^*b^*$ to <i>RGB</i>	84.79
$L^*a^*b^*$ to <i>XYZ</i>	85.94
<i>CMYK</i>	61.73
$L^*a^*b^*$	88.83
<i>XYZ</i>	92.54
<i>XYZ</i> to $u'v'L$	63.75
$L^*a^*b^*$ to L^*ch	55.80
<i>RGB</i>	94.16
Compactación del Color	87.31

Métodos de Segmentación

Debido a la popularidad del método de contornos activos, inicialmente fue sometido a prueba [53] con un conjunto de 23 imágenes, cuando el contorno inicial era entregado por el usuario u obtenido de manera automática, se comprobó su elevada dependencia con respecto al contorno de partida. En modo automático, se empleo el perímetro extraído de la máscara de Detección ROI; fue necesario incrementar el número de iteraciones, con la intención de

que el contorno inicial se aproximara adecuadamente a la lesión. Con base en los resultados del análisis preliminar, se concluyó que este método de segmentación no es eficiente en ambos modos (Supervisado y Automático), específicamente, porque no detecta los bordes, frecuentemente el contorno final resulta inmerso dentro de la lesión y el tiempo de computo es elevado, demandando en promedio un tiempo de computo equivalente a 24.4334 seg/imagen. A razón de lo anterior, este procedimiento no es tenido en cuenta en el análisis de desempeño de los algoritmos de segmentación.

Al momento de evaluar el método propuesto para la segmentación mediante la regresión del color, se notó con frecuencia que aunque este detectaba la lesión melanocítica, igualmente conservaba regiones ubicadas en la periferia de la imagen, efecto similar al mostrado en la figura 4.18(b). Lo cual es consecuencia de ubicar el umbral en la región intermedia de la distribución de los clusters, sin embargo, es un efecto necesario si se desea conseguir que los bordes difusos se preserven en la segmentación final. Para contrarrestar esa dificultad, fue obtenida la región de interés (Detección ROI), figura 4.18(c), luego, mediante la intersección de la Mascara ROI y la imagen binaria que resulta al identificar todos los valores diferentes a cero dentro de la imagen que posee el efecto tipo túnel (Figura 4.18(b)), se elimina todo tipo de región que no es localizada dentro de la región de interés, como resultado, se obtiene la imagen segmentada, figura 4.18(d). Con el propósito de evitar que el efecto previamente visto altere el comportamiento de los métodos de segmentación, la solución propuesta también es aplicada a estos y así garantizar un análisis de desempeño homogéneo sobre cada método.

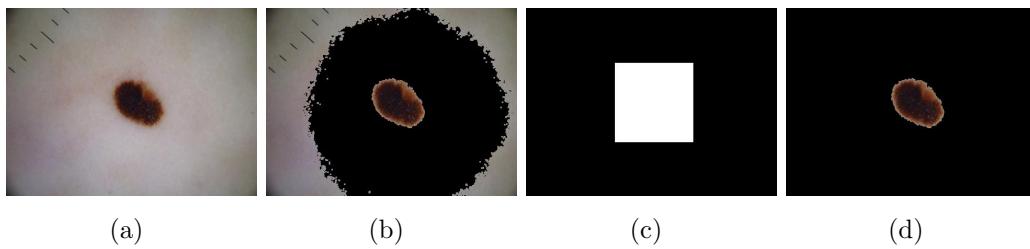


Figura 4-18.: (a). Imagen dermatoscópica. (b). Efecto tipo tunel, resultado de conservar colores presentes en la lesión. (c). Mascara asociada a la region de interes. (d). Imagen segmentada final producto de la intersección con la imagen segmentada y la mascara ROI.

Finalmente, con el ánimo de conocer la influencia de la etapa de preprocesamiento (Método de eliminación de vellos y filtrado) sobre la segmentación de la lesión pigmentada, se estudian todos los algoritmos de segmentación cuando la imagen de entrada posee la combinación de los siguientes parámetros: dimensión original, se presenta exclusivamente sobre la región de interés (Detección ROI), ha sido rasurada automáticamente ó sencillamente cuando la imagen de entrada no ha sido preprocesada. Para mayor detalle, la Tabla 4-2 indica el desempeño de segmentación luego de aplicar la combinación de parámetros previos sobre la imagen. Interesados en identificar los métodos más consistentes, nótese que la tabla 4-2 presenta

Tabla 4-2.: Desempeño de los métodos de segmentación.

		Segmentación					
Preproceso	Superficie	Método Otsu		Regresión Color		Ajuste GMM	
		Sens.(%)	Espe.(%)	Sens.(%)	Espe.(%)	Sens.(%)	Espe.(%)
Remoción Auto. de Vellos. Suavizado	Área ROI Original	69.56 (21.36)	99.55 (1.63)	77.29 (19.55)	99.45 (1.30)	84.32 (19.42)	99.04 (1.31)
		32.67 (39.96)	86.81 (10.98)	66.61 (25.83)	97.38 (8.61)	93.23 (10.33)	97.84 (2.29)
Ninguno	Área ROI Original	68.66 (24.71)	99.04 (3.08)	76.62 (21.37)	98.97 (3.18)	85.05 (18.34)	98.98 (1.23)
		34.80 (43.9)	87.00 (11.24)	61.62 (31.05)	93.43 (15.08)	93.24 (10.46)	97.32 (2.72)

las variables de sensibilidad y especificidad en forma de $\mu(\sigma)$, [20]. La consistencia de un método básicamente está determinada por los parámetros de desempeño (Sensibilidad y Especificidad) que poseen valores μ cercanos al 100 % pero que adicionalmente presentan una variabilidad σ reducida.

Según el criterio de consistencia, el algoritmo de segmentación con el menor desempeño es el método de Otsu, los resultados indican que este método no detecta completamente la lesión (Sensibilidad Baja), sin embargo, en la mayoría de veces detecta bien el fondo (Especificidad Alta). Notablemente, los resultados sugieren que la detección de la lesión mediante el ajuste de mezclas gaussianas logra un elevado nivel de precisión, superando la precisión mostrada por el otro método propuesto (S. Regresión del Color) y aunque este ultimo fue superior al método de Otsu, no es ampliamente eficiente.

En relación a los parámetros considerados, todos los métodos consiguen mejores resultados cuando la imagen de entrada ha sido procesada con el algoritmo de eliminación de vellos. Específicamente, el método de Otsu y el procedimiento de la regresión del color obtienen una precisión superior cuando la región de análisis ha sido reducida a la superficie obtenida por el método de detección ROI. Sin embargo, la detección automática por parte del procedimiento de mezclas gaussianas es más exitosa cuando la imagen posee las dimensiones originales. El éxito de segmentación del algoritmo de mezclas gaussianas, básicamente se debe a la gran similitud que poseen las distribuciones del color con las funciones gaussianas, lo que conduce a una mejor detección. Por el contrario, la frontera de decisión lineal del algoritmo de la regresión del color, provoca que la separación de los clusters no sea tan precisa.

En síntesis, el método de segmentación que obtuvo mejores desempeños fue el procedimiento de segmentación mediante el ajuste del color a las mezclas gaussianas y específicamente fue superior cuando la imagen de entrada posee las dimensiones originales y ha sido preprocesada mediante el modulo de preprocesamiento planteado en este trabajo.

4.5. Conclusiones

La detección automática de lesiones melanocíticas es una tarea necesaria y generalmente compleja, específicamente por el tipo de características que se presentan en toda la superficie de la imagen original. Por tal razón se han desarrollado múltiples enfoques reportados en la literatura, de los cuales el método sobresaliente es el algoritmo de Otsu.

Al evaluar la influencia de la transformación del espacio de color con respecto al algoritmo de segmentación de Otsu, se notó la dificultad que tienen los métodos automáticos para detectar la región de interés, básicamente porque aunque se eliminan regiones con tonos oscuros, la iluminación no homogénea provoca que las regiones externas de la imagen posean colores similares a los presentes en la región de interés. Por consiguiente, se decidió implementar el algoritmo para la detección ROI, el cual detecta exitosamente con 94.16 % de efectividad el perímetro cuadrado que encierra la lesión melanocítica y de este modo evitar que el algoritmo de segmentación se confunda al preservar otro tipo de región no relacionado a lesión.

Según la bibliografía, el color no es suficientemente discriminante en el reconocimiento de las regiones asociadas a piel y lesión. No obstante, en este trabajo se proponen dos métodos que emplean el color como criterio de segmentación, específicamente porque las dos clases presentes en la imagen son visiblemente reconocibles y separables en el espacio de color. Para tal fin, se encontró la proyección del mapa de color que ostenta con mayor claridad la separación de ambas clases. Con base en esa distribución se desarrolló un método que identifica el umbral que separa las clases adecuadamente pero también se planteó utilizar el método GMM (Modelo de Mezclas Gaussianas), esencialmente porque se ajusta de manera precisa a las dos agrupaciones principales.

Como resultado, los métodos de segmentación propuestos e integrados con el procedimiento de detección ROI, demostraron ser superiores al algoritmo popularmente empleado; Método de Otsu, el cual obtuvo 69.56 % sensibilidad y 99.55 % especificidad. Concretamente, el método de segmentación GMM reveló una identificación exitosa, mostrando valores de sensibilidad (93.23 %) y especificidad (97.84 %) cercanos al 100 %. Los resultados indican que el algoritmo de segmentación mediante GMM se aproxima estrechamente a la segmentación realizada por el experto, conservando apropiadamente regiones difusas y lesión, además es eficiente en términos computacionales, procesando en poco tiempo una imagen dermatoscópica (Tiempo de computo = 0.6396 seg/imagen).

Aunque la detección por color en imágenes dermatoscópicas no ha sido fuertemente atrayente en la literatura, se ha mostrado que el empleo del color es un factor que es discriminante en la segmentación y adicionalmente contribuye a superar las dificultades presentes cuando la imagen fue adquirida sin respetar el protocolo de adquisición o cuando este se desconoce, lo cual hace del método propuesto un algoritmo de segmentación robusto. Sin embargo, considerando las ventajas obtenidas cuando el protocolo de adquisición es aplicado correctamente, en este trabajo se le da prioridad a las imágenes generadas de este modo, buscando que los patrones de interés sean más notables.

5. Caracterización y Clasificación

Con el ánimo de simular el comportamiento humano, los sistemas de inteligencia artificial establecen decisiones basados en la experiencia. En los cuales, la experiencia es aportada por un conjunto de datos asociados a las características que principalmente definen al objeto de interés. A razón de lo anterior, el éxito de la decisión por parte del sistema automático, es fuertemente dependiente del conjunto de datos de entrenamiento, siendo más eficiente cuando las características han sido cuantificadas con una precisión elevada. Sin embargo, la precisión en la cuantificación de las características no es una tarea trivial, aun más cuando estas poseen una estructura compleja.

Como fue indicado en el capítulo 2, existe una serie de procedimientos manuales que facilitan la detección del melanoma, basados en exámenes específicos sobre algunas variables de interés presentes en la lesión. Dentro del conjunto de variables de interés asociados a malignidad se encuentran: Retículo pigmentado prominente o atípico, puntos y glóbulos irregulares, proyecciones irregulares, velo azul-gris ó azul-blanquecino, áreas desestructuradas, estructuras de regresión, estructuras vasculares. Debido a la eficiencia de este tipo de exámenes, estos han servido de inspiración para el desarrollo de sistemas de diagnóstico automático [48, 13, 46, 56, 74], sin embargo, su empleo se ve restringido a los conocimientos por parte del especialista y a la subjetividad inmersa en cada procedimiento de diagnóstico manual. Entre los procedimientos de diagnóstico existentes para la detección del Melanoma, la lista de los tres puntos es el que ofrece un buen balance en desempeño (Alto), complejidad (Media) y experiencia (Baja), básicamente, analizando en la lesión, la presencia de varias o todas las siguientes características malignas: Asimetría, patrón reticular atípico y estructuras blanco-azuladas.

Para la caracterización de las variables de interés, múltiples estudios utilizan medidas estadísticas, cromáticas, textura o de forma [48, 13, 78, 56, 74, 5]. Sin embargo, son pocos los estudios en los que se analizan puntualmente las características principales.

Para la detección del patrón reticular, los procedimientos encontrados parten de la premisa de que el patrón reticular se localiza como todas las áreas oscuras que constituyen una malla, pero que también encierran orificios con intensidades claras [75]. En [10], para la detección de la malla emplean un procedimiento de dos etapas: estructural y espectral. La etapa estructural se encarga de obtener estructuras primitivas (Líneas ó puntos) que definen la textura de la red. La etapa espectral está basada en un análisis de Fourier, con la cual se proponen encontrar todas las regiones que poseen el periodo asociado al patrón reticular. En [42], proponen detectar los orificios encerrados por el patrón reticular mediante la substracción de

la imagen original y una imagen suavizada, luego, buscan todas las estructuras cerradas, las cuales son asociadas a la presencia del patrón reticular. En [44], proponen la detección de la malla mediante un procedimiento de tres etapas. La primera etapa se encarga de detectar las líneas ubicadas sobre la superficie de lesión, luego son unidas todas las líneas encontradas y finalmente, la tercer etapa se encarga de descartar todas las estructuras que no posean un contorno cerrado. Además de los procedimientos previos, se encuentra un método basado en textura [6] o un método diseñado con el filtro LoG [75], con el cual se identifican las componentes de alta frecuencia y se definen los bordes asociados a los orificios que indican la presencia del patrón reticular. En promedio, todos los métodos previos tienen un desempeño superior al 87.333 % en sensibilidad y 91.333 % en especificidad.

Respecto a la extracción automática del velo blanco-azulado, en [57] desarrollan un método en el cual dividen la lesión en tantas clases como estructuras con intensidad similar posea la imagen. Para la identificación de las intensidades similares emplean el histograma bidimensional obtenido mediante la transformada Karhunen-Loéve (KL) [87], luego de identificar la región asociada al patrón del velo azul, se extrae de esta la intensidad promedio y la dispersión de sus colores que sirven para definir las fronteras de decisión del clasificador Árbol de modelo logístico (*LMT*), (87 % sensibilidad y 85 % Especificidad). Un enfoque similar es reportado en [18], donde extraen algunas medidas del color sobre las imágenes con presencia de velo azul con las cuales buscan definir las reglas de decisión que gobiernan la clasificación de pixeles mediante arboles de decisión, Como resultado, obtienen un desempeño superior al 69.35 % en Sensibilidad y 89.97 % en Especificidad, sobre un conjunto de 545 imágenes dermatoscópicas.

La cuantificación de la asimetría de las estructuras presentes en la lesión, usualmente se obtiene al calcular la separación de cada estructura con respecto al centro de gravedad, donde las estructuras son identificadas mediante la umbralización de la lesión en escala de grises, con base en este concepto, se ha extendido la idea a imágenes a color [24]. En [81], calculan un índice de asimetría el cual básicamente es aplicado al canal de luminosidad del espacio de color L^*a^*b , el índice de asimetría se calcula como la diferencia de la imagen original y la imagen reflejada en los ejes de asimetría principales, los cuales son obtenidos mediante la transformada KL [67].

La clasificación de las características extraídas generalmente corresponde a la última etapa en el desarrollo de sistemas de diagnóstico automático, con la cual se puede reconocer de manera general el estado de la lesión. Como se mostró en el primer capítulo, algunos de los sistemas de diagnóstico existentes suelen utilizar para la etapa de clasificación, procedimientos de clasificación supervisada, entre ellos $K-nn$, Análisis discriminante Lineal, Arboles de decisión [78, 13, 56] y redes neuronales [48, 74]. Como resultado de la variedad de estrategias en clasificación, el desempeño promedio actual de los sistemas de reconocimiento y detección de lesiones melanocíticas se encuentra para los valores de sensibilidad 87.1 % y especificidad 83.7 %.

Con base en los trabajos mencionados, se proponen varias modificaciones para la detección y

cuantificación de las características más relevantes (Patrón Reticular, Velo Azul y Asimetría), sin embargo también se tendrán en cuenta medidas de forma, textura y color. En las siguientes secciones se ofrece una descripción más detallada de las características empleadas en este trabajo, por último se define la etapa de clasificación.

5.1. Extracción de Características

Luego de obtener la máscara binaria asociada a la región de interés (Capítulo 3), se calculan varias medidas, sobre esta (Figura 5.1(b)) y sobre la imagen RGB asociada a la máscara binaria (Figura 5.1(c)). Con frecuencia, para cuantificar la presencia de un patrón específico se emplean medidas generales, como las indicadas previamente (descriptores estadísticos, de color, forma o textura). Sin embargo, para contribuir en la precisión del sistema y para ofrecer un vector de datos con información más sustancial, en este trabajo se propone extraer medidas directamente de los patrones principales e integrarlos con el conjunto de variables más discriminantes según la bibliografía, (Ver Anexo C).

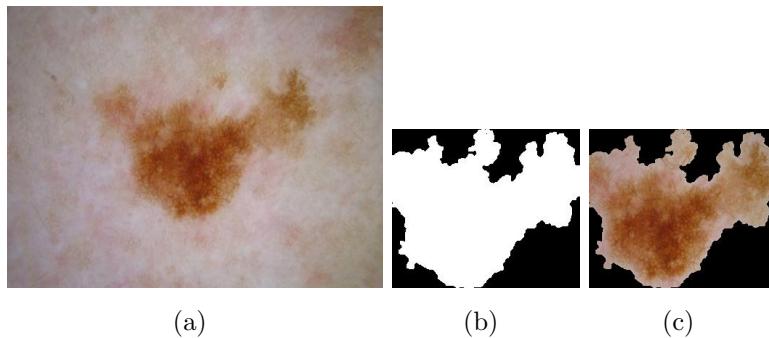


Figura 5-1.: (a). Imagen dermatoscópica. (b). Máscara binaria asociada a la lesión melanocítica, obtenida mediante el método de segmentación propuesto. (c). Imagen RGB asociada a la máscara binaria obtenida en la etapa de segmentación.

El reconocimiento de características eficiente no es la única dificultad inmersa en el desarrollo de la etapa de caracterización, un problema importante se encuentra en asignar el puntaje apropiado a la influencia de los patrones relevantes en la lesión, con lo cual, se puede superar la subjetividad de los diagnósticos dermatológicos; específicamente, porque la práctica moldea los criterios con los que el especialista toma su decisión y con frecuencia esos criterios no se encuentran fuertemente definidos en el medio clínico. Luego de una discusión en el tema y bajo la aprobación de un equipo de especialistas en dermatología, se establece como puntaje: el porcentaje de superficie que ocupa cada patrón relevante sobre la dimensión total de la lesión. Con base en el concepto previo, se cuantifica la influencia del patrón reticular y del velo azul, sobre la imagen.

5.1.1. Patrón Reticular

El patrón reticular atípico se encuentra entre las tres características que permiten distinguir las lesiones PSL benignas de malignas y se define como la malla pigmentada de líneas amplias, con presencia de orificios ó islas irregulares [45]. Para la detección del patrón reticular, se elaboró un procedimiento que combina una serie de operaciones y parte de la imagen en escala de grises, (Figura 5.3(a)). El diagrama de la figura 5-2, ofrece una descripción general de las etapas que integran el procedimiento para la identificación del patrón reticular.

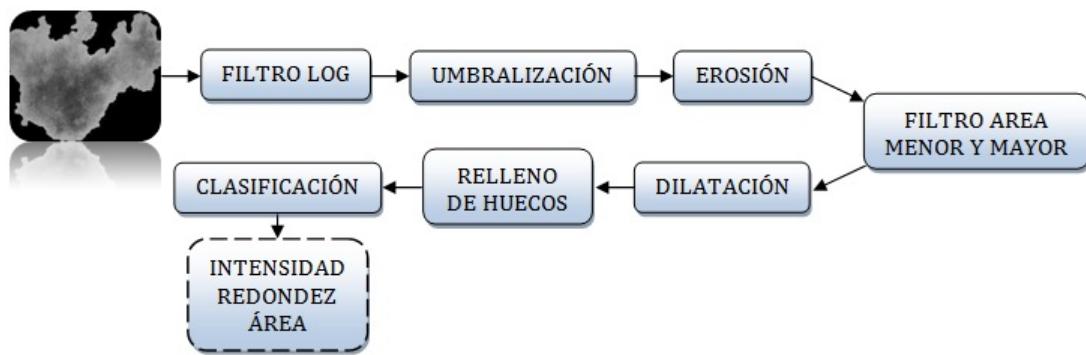


Figura 5-2.: Esquema general del procedimiento diseñado para la detección del patrón reticular atípico.

Con base en el estudio realizado en [75], se aplica el *Filtro LOG* (Laplacian of Gaussian) a la imagen de entrada, (Figura 5.3(b)); en vista que esta se normaliza a un tamaño superior a **500x500 pix**, es posible asignar un tamaño de ventaneo de 20 sin pérdida de información, adicionalmente, tal como en [75], se conserva el parámetro $\sigma = 0,15$ en virtud de la buena representación de los datos, no obstante, σ puede ser calibrado, de acuerdo a la escala y magnificación del conjunto de imágenes.

Luego, se umbraliza la imagen obtenida en el paso previo, como resultado se obtiene una imagen similar a la mostrada en la figura 5.3(c), posteriormente se aplica la operación morfológica de erosión; con estructura cuadrada de tamaño igual a 3, (Figura 5.3(d)), con lo cual se definen todos los orificios generados por la presencia del patrón reticular, sin embargo, también se conservan regiones asociadas a ruido, las cuales son eliminadas mediante filtrado de área, tanto para los objetos con área mínima como para los objetos con área fuera del promedio. Con la intención de eliminar las discontinuidades y mejorar el contorno de cada isla, el siguiente paso es aplicar la operación morfológica de dilatación; con estructura cuadrada de tamaño igual a 4; para recuperar con la misma magnitud, los píxeles que se eliminaron en la operación de dilatación, a continuación, se aplica el relleno de cada una de ellas por separado, (Figura 5.3(e)). Por último, sobre la imagen RGB asociada a la máscara resultante, se calcula la intensidad promedio dentro de cada isla y la intensidad promedio de la región que la rodea, su diferencia, el área y la redondez de cada islote, son los criterios empleados para determinar si la isla está asociada a la existencia del patrón reticular atípico,

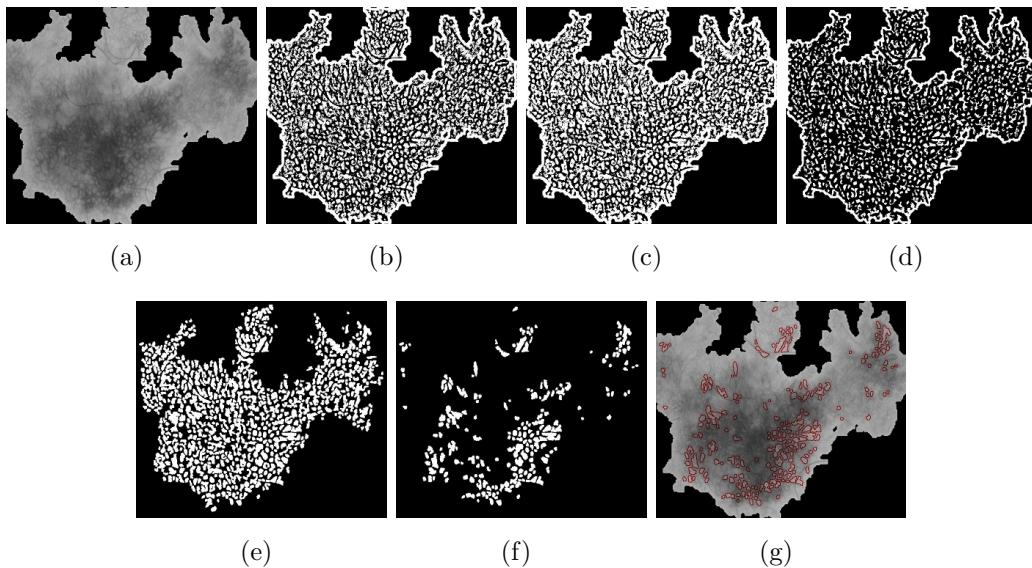


Figura 5-3.: Secuencia de imágenes obtenidas mediante la aplicación del procedimiento de detección del patrón reticular: (a). Imagen original con presencia de factor reticular, presentada en escala de grises. (b). Imagen resultante IF_{log} luego de aplicar el Filtro LOG. (c). Imagen IF_{log} umbralizada. (d). Imagen obtenida mediante la operación morfológica de erosión. (e) Objetos asociados a la presencia del factor reticular. (f). Orificios ó islas finales. (g). Factor reticular superpuesto sobre la imagen de entrada.

para la clasificación de estas variables, se empleo el método de análisis discriminante, el cual fue entrenado con un conjunto de datos obtenidos manualmente, extrayendo de cada isla las características mencionadas.

5.1.2. Velo Azul

La detección del velo azul se realiza usando el mapa de color, el cual previamente se normaliza con la intención de incrementar la nitidez de los colores presentes en la imagen original. Luego de la normalización del color sobre la imagen original (Figura 5.4(a)) la imagen luce más radiante, (Figura 5.4(b)). Básicamente, el velo azul se puede reconocer, al condicionar el intervalo de existencia del color azul [71], el cual, para una imagen en el espacio *RGB*, se encuentra ubicado en el rango de intensidades de $[0 \leq R \leq 0,5, 0 \leq G \leq 0,5, 0,5 \leq B \leq 1]$. Luego de identificar los colores que se encuentran fuera de ese rango, se procede a sustituirlos en el mapa de color, en este caso son reemplazados con el color blanco, en seguida, el nuevo mapa de color es reemplazado sobre la imagen indexada, (Figura 5.4(c)). Con el propósito de mejorar la superficie resultante, luego se aplica el procedimiento de filtrado de área y la operación morfológica de cierre, como resultado, se obtienen las regiones que presentan la

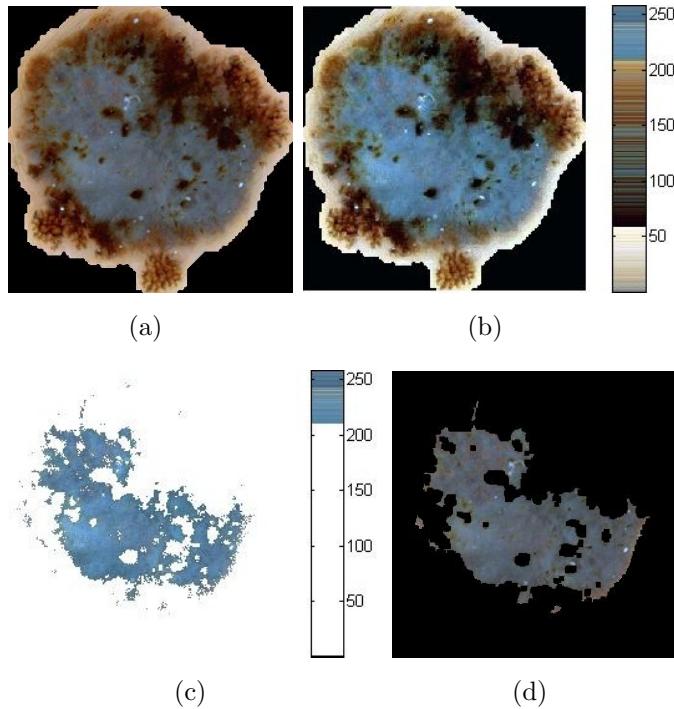


Figura 5-4.: Secuencia de imágenes obtenidas con el procedimiento para la detección de velo azul: (a). Imagen dermatoscópica que presenta velo azul en su superficie. (b). Imagen obtenida luego de la normalización del color. (c). Regiones que poseen todos los colores pertenecientes al intervalo mencionado. (d). Imagen que indica la detección del velo azul.

característica de velo azul, figura 5.4(d).

5.1.3. Asimetría

Para la cuantificación de la asimetría del color, son empleados los índices de asimetría reportados en [24]. Adicionalmente, se plantea un procedimiento para extraer la asimetría en función del borde de la lesión, el cual se presenta en seguida.

Usualmente, los objetos simétricos se caracterizan por tener una distribución similar al lado opuesto de cada eje de simetría principal. Con base en ese concepto, se calculan las distancias del centro de gravedad de la región C al punto $B(x_i, y_i)$ ubicado en el borde de la lesión y al punto diagonalmente opuesto $D(x_i, y_i)$. Es decir $dC|_\theta = Dist(C, B)$ y $\overline{dC}|_{\theta+180} = Dist(C, D)$. En caso de que la diferencia de ambas distancias sea mínima para cada pareja de puntos, el contorno del objeto exhibe simetría, por el contrario, si la diferencia es elevada, es indicio de asimetría.

Luego de obtener el borde de la imagen binaria, (Figura 5.5(b)), se procede a calcular el ángulo de cada punto con respecto al centro de gravedad, con el cual es posible encontrar

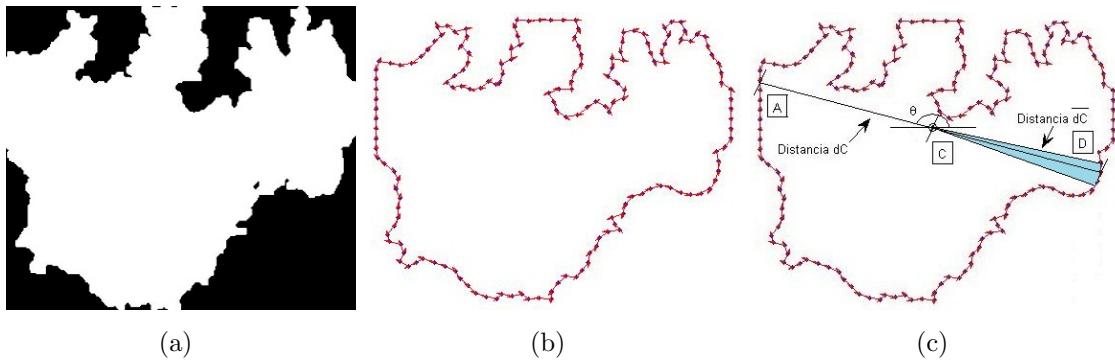


Figura 5-5.: (a). Imagen binaria obtenida mediante el procedimiento de segmentación propuesto. **(b).** Curvatura asociada al perímetro de la imagen binaria. **(c).** Puntos extremos relacionados con el ángulo θ .

el punto opuesto de valor $Ed(x_i, y_i)$ localizado a un ángulo específico. El ángulo al que se ubica cada punto $Ed(x_i, y_i)$ con respecto al centro de gravedad, se calcula mediante 5-1.

$$\theta_i = \arctan \left(\frac{y_i - \mu_y}{x_i - \mu_x} \right) \quad (5-1)$$

Donde μ_x y μ_y , corresponden a las coordenadas del centro de gravedad y con $0^\circ \leq \theta \leq 180^\circ$. La diferencia de las distancias puede ser calculada como en la ecuación 5-2.

$$D_i = \sqrt{\left(dC|_\theta - d\bar{C}|_{\theta+180} \right)^2} \quad (5-2)$$

Donde $dC|_\theta$ es la distancia promedio de todos los puntos $Ed(x, y)$ ubicados a un ángulo θ , respecto al origen. El elemento $\bar{dC}|_{\theta+180}$ corresponde a la distancia promedio de los puntos localizados a un ángulo $(\theta + 180)$, el cual se encuentra ubicado dentro del intervalo $[\theta + 180 - \kappa, \theta + 180 + \kappa]$, tal como se indica en la región sombreada de la figura 5.5(c). Es necesario restringir el punto \bar{dC} al intervalo previo, con la intención de que este se encuentre ubicado precisamente en el lado opuesto del punto $A(x_i, y_i)$, así superar la dificultad asociada al empleo de valores discretos.

El valor κ , se define como el promedio de la variación de todos los ángulos θ ordenados en forma ascendente, tal como en 5-3.

$$\kappa = \frac{1}{N} \sum_i^N \Delta\theta_i \quad (5-3)$$

Finalmente, la medida de asimetría se define como el promedio de la diferencia de distancias D_i , ecuación 5-4.

$$Ma = \sum_i^N \frac{D_i}{N} \quad (5-4)$$

Sin importar que tan tortuoso es el borde la distancia de todos los puntos ubicados a un mismo ángulo es promediada, así el valor de la distancia final varía debido a la influencia de los puntos ubicados en esa dirección, lo cual es indicio de asimetría.

5.2. Clasificación

La clasificación de características ó reconocimiento de patrones, corresponde al procedimiento de captura de datos en bruto para luego tomar una acción basada en la categoría del patrón [32]. En este caso, se desea identificar las características asociadas a lesiones con diagnóstico maligno y benigno. Para resolver esto, se han reportado estudios en los que se emplean clasificadores sencillos [48, 13, 56] ó integrados [78, 74]. Por ejemplo, en [69] desarrollan un sistema compuesto por tres clasificadores (knn, SVM, Gaussian ML) donde a cada clasificador se le ingresa el conjunto de datos con un grupo de características específicas, la clasificación final se obtiene mediante la combinación del vector de salida de cada uno de ellos. Para una descripción general de los sistemas recientes de diagnóstico automático del melanoma, la tabla 2-6 ofrece los principales detalles asociados a cada estudio.

De la revisión bibliográfica se ha concluido que las técnicas de clasificación más populares para el reconocimiento automático del melanoma son: El método de los k vecinos más cercanos (knn), redes neuronales artificiales (ANN), maquinas de vectores de soporte (SVM) y arboles de decisión.

Por ejemplo en [30] realizaron un estudio comparativo de cinco técnicas populares en reconocimiento de patrones (Knn, ANN, SVM, Regresión Logística y Arboles de decisión) aplicados a la clasificación de lesiones pigmentadas de la piel, específicamente utilizados en la identificación de tres clases principales: Nevus comunes, nevus displásicos y Melanoma. Experimentalmente encontraron que mientras el método de arboles de decisión no es adecuado para este problema; concretamente por el tipo de las variables asociadas a las lesiones, los otros métodos se desempeñaron bien (kNN) a muy bien (SVM, ANN y Regresión logística) sobre los datos. Sin embargo detectaron que los mejores desempeños de clasificación se presentaban al incluir solamente dos clases. También que las redes neuronales demandan mucho tiempo en la sintonización de los parámetros.

5.3. Marco Experimental

Para la conformación general de la etapa de clasificación fueron realizados una serie de experimentos con los métodos de clasificación disponibles. Los experimentos consisten en la calibración de los parámetros de cada uno de los métodos de clasificación, con la intención de identificar el método y los parámetros que presentan los mejores resultados en la clasificación de lesión maligna y benigna. En esta etapa de experimentación se realizaron tres análisis principales.

El primer análisis tuvo como objetivo establecer el método de clasificación que se desempeña mejor en relación a las otras técnicas de clasificación. El segundo análisis consiste en modificar los parámetros de la técnica de clasificación sobresaliente, para establecer el intervalo prometedor donde los parámetros calibran mejor el método en función de los resultados de clasificación y el número de variables incluidas. Debido a que los resultados del segundo procedimiento indicaban que el método de clasificación selecto era vulnerable a sufrir de una complicación asociada a la dimensión de los datos, el tercer experimento fue implementado para analizar nuevamente el comportamiento del método de clasificación cuando se ingresan los datos transformados a una dimensión inferior. Sin embargo, esta vez fueron sintonizados los parámetros de manera automática.

A continuación se describen detalladamente las medidas de desempeño usadas en la evaluación de los métodos de clasificación, el conjunto de datos obtenido de la etapa de caracterización y luego cada uno de los experimentos previos enfatizando en el análisis y resultados.

5.3.1. Descripción del conjunto de datos

Se emplearon 184 imágenes dermatoscópicas, de las cuales 96 corresponden a lesiones pigmentadas benignas y las 88 imágenes restantes, corresponden a lesiones con diagnóstico de melanoma maligno y previamente validadas por un equipo de expertos. La base de datos se generó con un conjunto balanceado de imágenes normales y anormales, con la intención de obtener un arreglo de datos representativo e insesgado, de tal forma que la dimensión de las clases no afectara la etapa de entrenamiento y posteriormente, el desempeño general.

Del conjunto de imágenes total, la mayoría de ellas fue adquirida rigiéndose al protocolo de adquisición propuesto en la sección A de este trabajo. Debido a la escasez de personas con diagnóstico de Melanoma en la región, fue necesario emplear imágenes PSL malignas de otras bases de datos (Cortesía [96, 97, 52]), eligiendo las que exhibían propiedades similares a las imágenes capturadas con el protocolo de adquisición propuesto, para lo cual fueron analizadas con respecto a la iluminación y el nivel de detalle de cada imagen.

Como se mencionó en la descripción del protocolo de adquisición, las imágenes capturadas con este procedimiento poseen una dimensión de $1200 \times 1600 \text{ pix.}$, con una resolución de 8 bits en formato *JPEG*. A pesar de que el formato *JPEG* utiliza un método de compresión con pérdida de información, en este caso el formato de compresión de la imagen no afecta considerablemente la extracción de características. Básicamente porque en este estudio se busca conservar la dimensión original de la lesión, de este modo el nivel de detalle se conserva en una escala superior. Y aunque el formato *JPEG* agrega una leve distorsión, ese ruido generalmente afecta las regiones de escala reducida donde existen cambios bruscos del color. Sin embargo, los métodos de compresión sin pérdida de información también pueden ser empleados eficientemente.

Con la finalidad de extraer las características sin contratiempos, se propone normalizar en dimensión la imagen resultante de la etapa de segmentación, para que posea un tamaño

superior a $500 \times 500\text{pix}$, pero conservando la relación original de filas y columnas; con la intención de evitar modificar la superficie de la imagen, lo cual puede alterar el resultado en la extracción de características. Además, se normaliza la imagen para que las características de las imágenes conserven una dimensión estándar, de este modo evitar que el sistema sufra de la influencia de la dimensión; por ejemplo, los orificios generados con la presencia del patrón reticular son fácilmente detectados cuando estos son moderadamente grandes (Radio mayor a 10pix .).

Como resultado de la etapa de caracterización propuesta en este trabajo, se obtuvieron 69 características por lesión, agrupadas en características globales y locales, las cuales son descritas en el Anexo B. La extracción del vector de datos, tuvo un tiempo de procesamiento promedio de $t = 45,78\text{seg/imagen}$, desde la etapa de pre-procesamiento, hasta la etapa de caracterización.

5.3.2. Medidas de desempeño

Nuevamente las medidas de desempeño son expresadas en términos de la sensibilidad y especificidad, sin embargo se consideran resultados eficientes aquellos que presentan valores de sensibilidad y especificidad balanceadas y próximas al 100 %. Esto con la intención de que el sistema detecte con la misma proporción de efectividad las lesiones malignas y benignas, ya que el diagnóstico final es trascendental para el cuidado del paciente. De este modo se garantiza una reducción en las falsas detecciones.

Para ilustrar mejor el concepto suponga que el sistema fue ejecutado con una lesión benigna y sin embargo el diagnóstico automático fue maligno, en este caso los resultados alertan al especialista y se ve en la obligación de establecer exámenes más rigurosos. En este sentido un caso peor puede suceder cuando siendo maligna la lesión de entrada, tuvo un diagnóstico automático de benignidad, lo cual despreocuparía al especialista y el Melanoma pasaría desapercibido, poniendo en riesgo la salud del paciente. Ambos casos previos son causados principalmente por el desbalance en la efectividad de detección de malignidad (Sensibilidad) y la efectividad de detección de benignidad (Especificidad), siendo uno más alto que el otro.

5.3.3. Experimentos de clasificación

Para la clasificación y aprendizaje de máquina, se empleo el Toolbox de Bioinformática de Matlab® R2008a, del cual fueron aprovechadas las funciones correspondientes a los clasificadores: K-vecinos más cercanos ($k = 1$, métrica euclíadiana), maquinas de vectores de soporte SVM (Kernel Lineal, Cuadrático y Función de base radial $\sigma = 1$) y análisis discriminante lineal (Tipo lineal y diagLineal).

Fueron estandarizados los datos mediante la norma $zscore$ para prevenir problemas de escala.

Experimento 1:

Para evitar el sobre-entrenamiento y obtener una evaluación confiable, diez veces fue aplicada la técnica de validación cruzada sobre el conjunto de datos, esta técnica elige aleatoriamente un porcentaje p del conjunto de datos total y los asigna para evaluación, los valores restantes los conserva como datos de entrenamiento. En este caso se utilizó un porcentaje de entrenamiento $p = 15\%$, ya que si este era superior, el desempeño disminuía.

Posteriormente, el conjunto de prueba fue analizado con los métodos de clasificación previamente mencionados y entrenados con el conjunto de datos obtenidos de la partición mediante la validación cruzada para este propósito. Adicionalmente, para verificar la influencia de las características propuestas, el proceso previo se repitió cuando el conjunto de datos poseía las n características más relevantes (Método de filtrado para selección de características [68]); particularmente, el procedimiento de evaluación se repitió con n igual a un múltiplo de 10, hasta que poseía la totalidad de características, $n = 69$. En cada iteración se inicializó el generador de números aleatorios para uniformizar la evaluación.

Los resultados de clasificación del actual experimento son mostrados en la tabla 5-1 y discutidos en la siguiente sección 5.3.4.

Experimento 2:

Del primer experimento, se encontró que el clasificador de maquinas de vectores de soporte presenta el mejor desempeño de clasificación. Con el ánimo de buscar resultados superiores con este método, nuevamente se evaluó el procedimiento de validación cruzada sobre el clasificador SVM, pero esta vez modificando los parámetros del kernel polinomial y el kernel gaussiano de base radial RBF. Específicamente fueron manipulados, el parámetro σ de la función de base radial y el grado n del kernel polinomial. Sin embargo, también se analizó el comportamiento del método de los k-vecinos más cercanos cuando el parámetro k incrementa. La variación de los parámetros previamente mencionados se indica en 5-5.

$$\begin{aligned} \sigma &= 1, 3, 6, 9, 20, 40, 60, 80, 1^{-1}, 3^{-1}, 6^{-1}, 9^{-1}, 20^{-1}, 40^{-1}, 60^{-1}, 80^{-1} \\ n &= 1, 2, 3, 4, 5, 6, 7, 8 \\ k &= 1, 3, 6, 9, 20, 40, 60, 80 \end{aligned} \tag{5-5}$$

Los resultados de clasificación del actual experimento son mostrados en las figuras 5.6(a), 5.6(b), 5.7(a), 5.7(b) y discutidos en la siguiente sección 5.3.4.

Experimento 3:

Del segundo experimento se observó que la mayoría de clasificadores posee un desempeño ineficiente, lo cual sugiere que fueron afectados por un factor desconocido el cual provoca que los clasificadores no resulten entrenados apropiadamente y generen un resultado poco confiable. Sin embargo, la razón más probable para que esto suceda, se debe a que no hay

una población muestral (184 Imágenes) significativamente grande en comparación con el conjunto de variables analizadas (69 Características). A razón de lo anterior, los clasificadores son vulnerables a la "maldición de la dimensión".

En particular, el clasificador de maquinas de vectores de soporte puede ser el más afectado. Básicamente porque las SVMs transforman el espacio inicial; que en este caso es $d=69$, a un espacio de dimensión superior donde los datos sean linealmente separables [32], lo que ocasiona la generación de nuevas variables. Adicionalmente, la dimensión final dependerá de la cantidad de parámetros utilizados en el kernel aplicado a las SVM.

Para superar esta dificultad es necesario reducir la cantidad de variables a un número apropiado, que en este caso puede ser inferior a 10 de este modo se logra evitar algún tipo de problema asociado al número de variables. Como alternativas de solución, se pueden seleccionar las 10 características más relevantes (Como se vio previamente) ó se puede transformar el arreglo de los datos para que concentre la mayor cantidad de información en un espacio de dimensión inferior, lo que es conocido como reducción de dimensionalidad. En este caso, se emplean dos técnicas populares y fuertemente utilizadas en el área de reconocimiento de patrones, que son: Análisis de componentes principales PCA y Análisis Discriminante Lineal LDA. Ambas técnicas de reducción de dimensión, buscan la proyección espacial que maximiza las medidas de dispersión en los datos [90, 66]. Luego de proyectar el conjunto de datos inicial, se eligen exclusivamente las nuevas características que poseen la información más discriminante, es decir, las características que poseen la varianza acumulada más significativa.

Ahora el experimento consiste en la sintonización automática de los parámetros del clasificador SVM. Para tal fin se emplea el esquema de clasificación propuesto por Jaramillo et al. [7], en el que sintonizan los parámetros del Kernel Gaussiano de base radial (Costo y σ) en función de los posibles valores que maximizan el desempeño de clasificación ó en otras palabras los parámetros que minimizan el error. La etapa de minimización se realiza mediante optimización por enjambre de partículas PSO [25], en el que el usuario establece un intervalo de valores para las variables de interés, en este caso se utilizaron $0,0001 \leq C \leq 1$ y $0,00001 \leq \sigma \leq 0,1$. El intervalo de valores se estableció intencionalmente para que el clasificador no perdiera generalidad y no sufriera de la influencia del sobre-entrenamiento, ya que cuando la variable de costo es $C > 10$ el clasificador tiende a ser vulnerable al sobre-entrenamiento. La variable de costo determina la importancia de los errores de clasificación en el conjunto de entrenamiento, permitiendo mayor ó menor exactitud en la frontera de decisión.

Particularmente, el procedimiento de optimización *PSO* elige aleatoriamente varias parejas ordenadas del intervalo de partida, donde cada pareja corresponde a los parámetros de interés (C, σ), luego se evalúa el método de clasificación SVM cuando el Kernel se calculó con cada una de las parejas seleccionadas, dependiendo del resultado de clasificación cada pareja se reorientará hacia el punto óptimo que minimiza el error. En este caso el error (Ecuación 5-6) se mide como el complemento del desempeño general del clasificador. Donde, la combinación

de las medidas de sensibilidad y especificidad define el desempeño general del clasificador y en este caso se realizó a partir de la media geométrica M_g . El procedimiento se repite hasta que todas las parejas convergen en un solo punto, siendo ese el criterio de parada. Además en cada iteración se divide el conjunto de datos haciendo validación cruzada. Al final el procedimiento arroja las coordenadas del punto óptimo (C_{op} , σ_{op}).

$$\text{error} = 1 - M_g = 1 - \sqrt{Sn * Sp} \quad (5-6)$$

Donde Sn corresponde a la sensibilidad y Sp corresponde a la especificidad.

En este análisis experimental, se consideraron principalmente tres conjuntos de datos: (1) El conjunto de características relevantes seleccionadas del arreglo de datos original mediante [92], (2) El conjunto de datos original transformado mediante PCA, (3) El conjunto de datos original transformado a partir de LDA.

Mediante la etapa de sintonización de parámetros, se obtuvieron los desempeños de clasificación mostrados en las Tablas 5-2, 5-3, 5-4.

5.3.4. Discusión y Resultados

Como resultado del primer experimento (Sección 5.3.3) se obtuvieron los valores de desempeño mostrados en la tabla 5-1. De la tabla 5-1, la clasificación más confiable se obtuvo con

Tabla 5-1.: Desempeño de los Métodos de Clasificación.

Método de Clasificación	No. de Características								
	<i>n</i>	1	10	20	30	40	50	60	69
SVM Kernel Lineal	Sens. %	87.86	84.29	80.71	83.57	82.14	85	85.71	88.57
	Espec. %	75.38	76.92	83.08	83.08	86.92	86.15	83.85	84.62
SVM Kernel Cuadrático	Sens. %	91.43	81.43	79.29	82.86	76.43	78.57	79.29	77.14
	Espec. %	71.54	76.15	64.62	66.15	60	60.77	59.23	61.54
SVM Función Gauss BR	Sens. %	89.29	78.57	68.57	99.29	100	100	100	100
	Espec. %	73.08	89.23	88.46	2.31	1.54	0.77	0	0
<i>Knn</i>	Sens. %	78.57	85	76.43	78.57	83.57	85	85	85
	Espec. %	70	75.38	70.77	68.46	66.92	66.15	63.08	61.54
LDA Lineal	Sens. %	87.14	82.86	79.29	–	–	–	–	–
	Espec. %	76.92	78.46	85.38	–	–	–	–	–
LDA DiagLineal	Sens. %	87.14	85	81.43	82.86	82.86	82.86	82.14	81.43
	Espec. %	76.92	69.23	63.08	62.31	64.62	64.62	63.08	63.08

el método de maquinas de vectores de soporte con kernel lineal, confirmando lo expuesto

en [30]. Además, se muestra que hay un desempeño superior cuando el conjunto de datos posee todas sus características, lo cual indica que cada una tiene un aporte significativo. Analizando las características relevantes incluidas por cada iteración (Anexo C.1), los valores obtenidos sugieren que la mayoría de los métodos de clasificación presentan resultados superiores al 80 %, en sus valores de sensibilidad y especificidad cuando el conjunto de datos posee las 20 características principales. Estas variables relevantes corresponden a medidas de color, momentos estadísticos y a las medidas propuestas para la detección del patrón reticular y velo azul, demostrando que son medidas discriminantes para el reconocimiento del melanoma. Nótese, que el método de selección de características indica que la variable X_{66} es la más discriminante, en vista que provoca desempeños superiores cuando es la única variable de entrada. Este resultado se debe a que la intensidad del borde (Variable X_{66}) es una característica importante, debido a que los melanomas tienden a poseer bordes abruptos [49, 93] son más contrastados con el fondo a diferencia de las lesiones benignas. Pero también sugiere que el borde ha sido detectado correctamente, reafirmando los resultados obtenidos en la etapa de segmentación.

En general, todos los métodos de clasificación poseen resultados aceptables hasta las primeras 30 características relevantes. Sin embargo, luego de estas su desempeño decrece con las características restantes. A pesar de esto, el algoritmo de clasificación de maquinas de soporte supera esta dificultad conservando resultados estables y finalmente generando un desempeño más eficiente cuando se utilizan todas las características.

Sin embargo el segundo experimento ha sido incluido para determinar el kernel que presenta los mejores desempeños cuando es integrado al clasificador SVM. De este experimento se obtuvieron los desempeños visualizados en las imágenes 5.6(a), 5.6(b), 5.7(a), 5.7(b). Nótese que los resultados son presentados en función de la sensibilidad y especificidad cuando son modificados los parámetros del kernel actual. Pero también se analiza la influencia de la cantidad de características utilizadas. En esos términos, en las figuras indicadas se visualizan los desempeños de clasificación para una variación específica del parámetro particular y el número de características incluidas. Para cada caso, se muestra una pareja de segmentos rectangulares, donde el rojo corresponde a la sensibilidad y el azul a la medida de especificidad. Además la altura de cada segmento es directamente relacionada con cada medida.

Analizando los resultados, se concluye que no se consiguieron desempeños superiores a los mostrados en la tabla 5-1, con excepción del método SVM con Kernel polinomial de grado $n = 1$ (SVM Poli.), consiguiendo los mismos resultados que el clasificador SVM con kernel lineal, no obstante, su precisión disminuye al incrementar el grado del polinomio. En esta última prueba el algoritmo de clasificación que obtuvo los peores desempeños fue el clasificador SVM con Kernel de base radial (SVM - RBF), específicamente cuando su parámetro posee valores $\sigma < 1$, aunque con $\sigma > 1$, se obtuvo un comportamiento general del 86.32 % y 59.61 % en la pareja de sensibilidad y especificidad. Además, se puede notar que al incrementar la cantidad de vecinos considerados en el clasificador knn , se pierde considerablemente el balance en las medidas de desempeño, siendo cada vez menor la especificidad en comparación

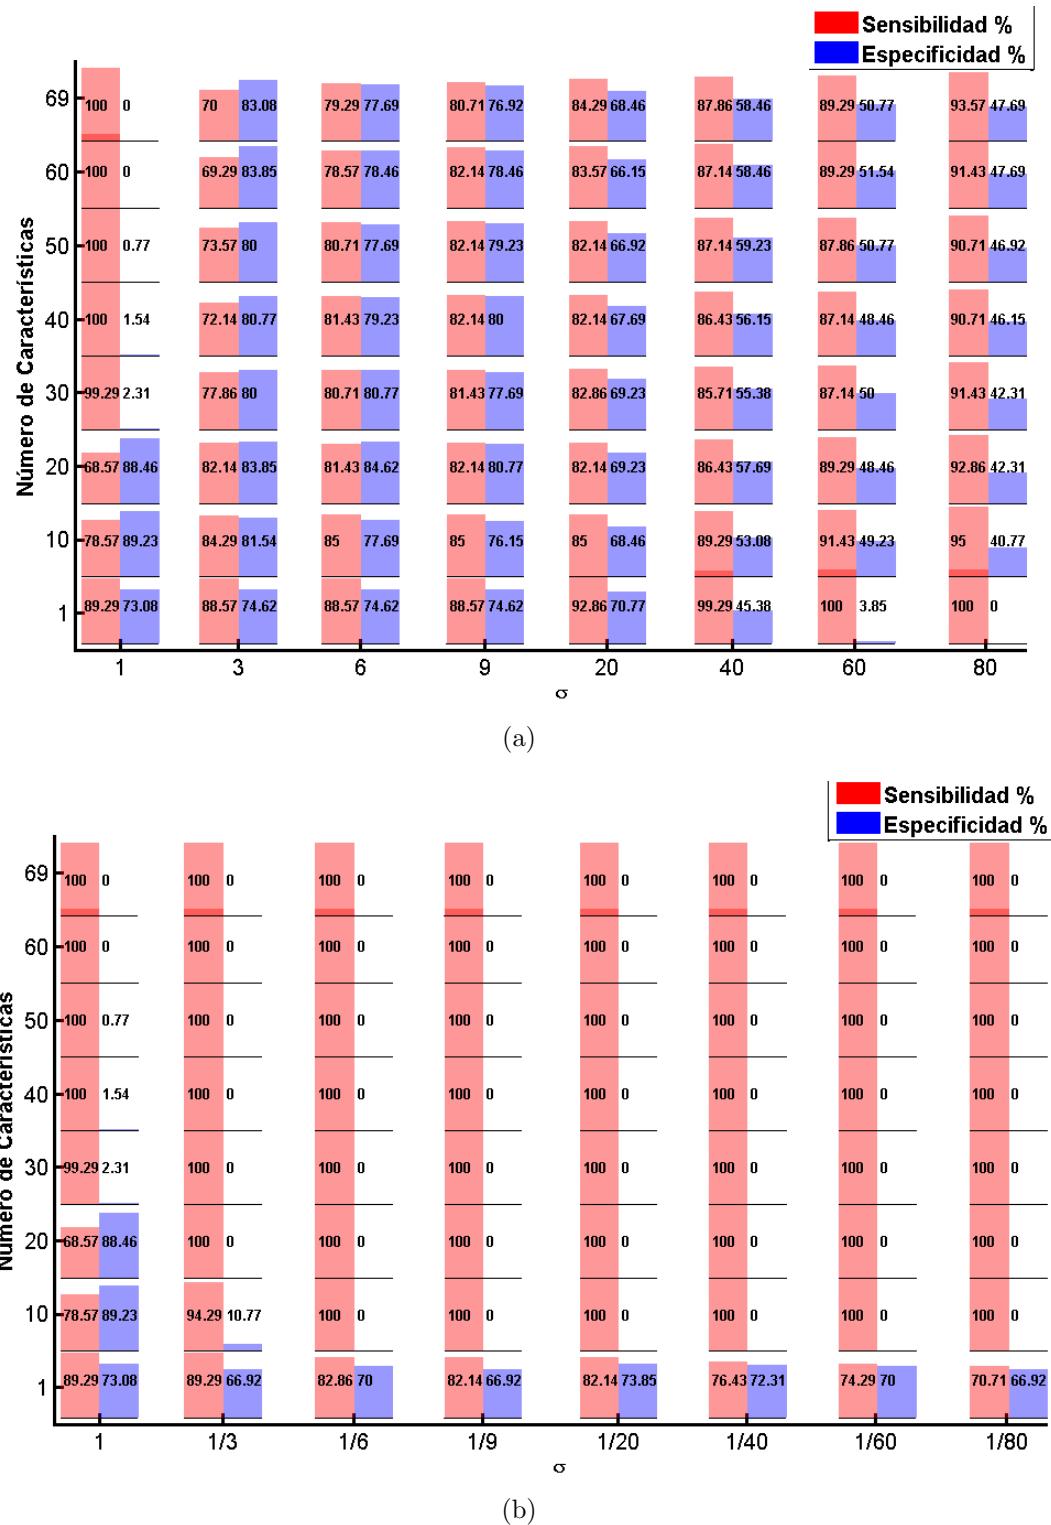
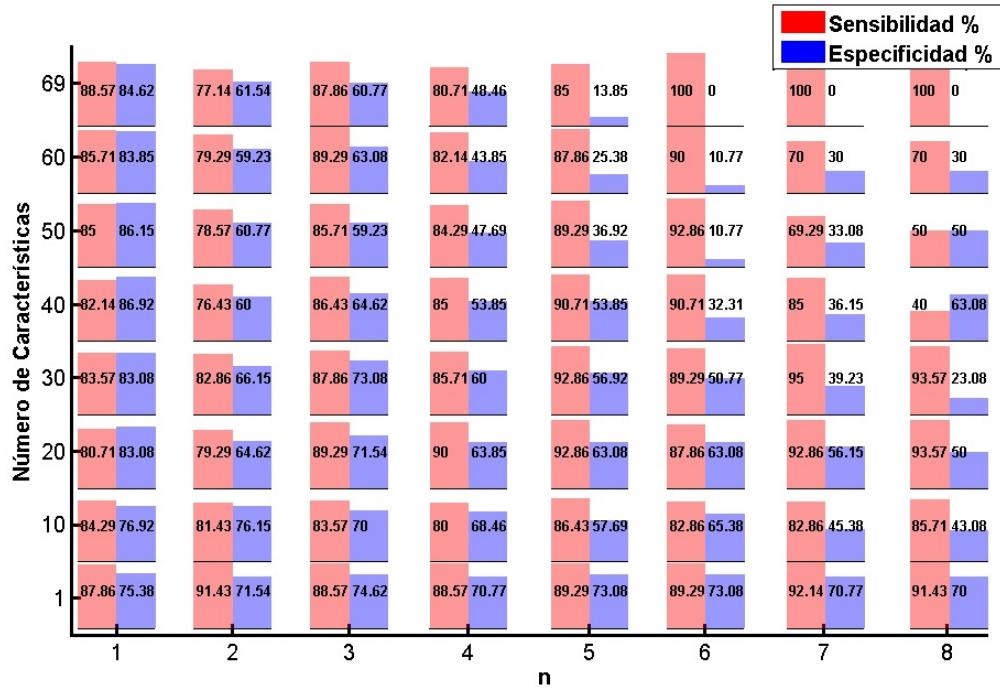
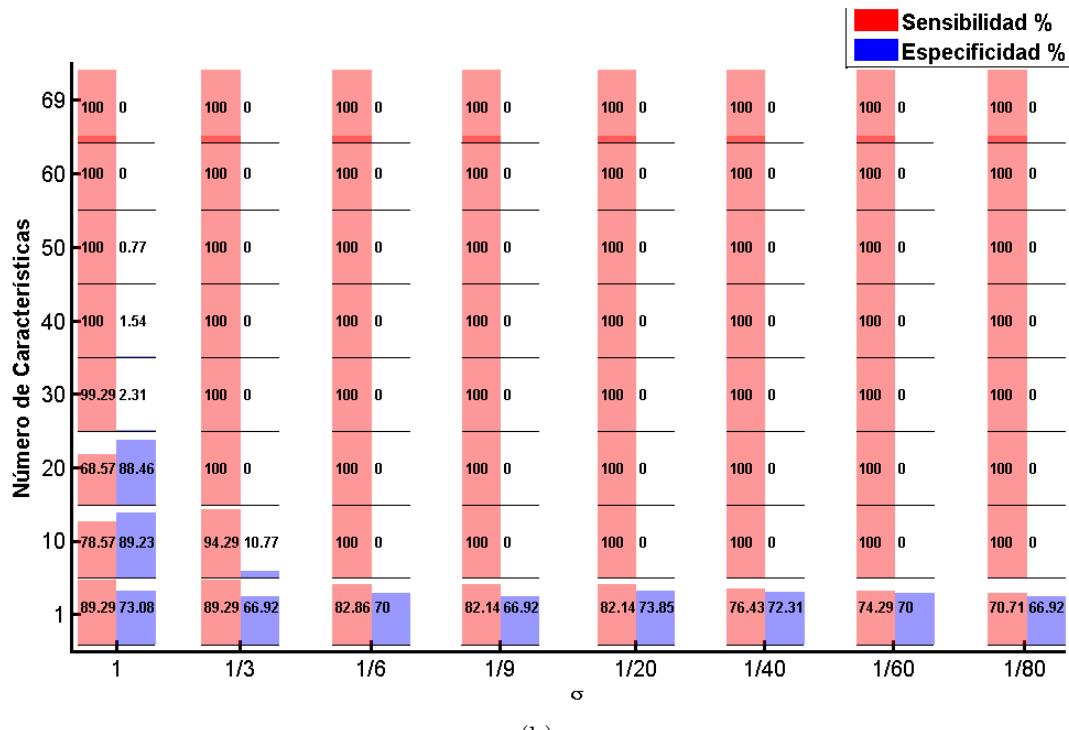


Figura 5-6.: (a). Desempeño de clasificación para el método *MSV – RBF*. **(b).** Desempeño de clasificación para el método *MSV – RBF*.



(a)



(b)

Figura 5-7.: (a). Desempeño de clasificación para el MSV Polinomial. (b). Desempeño de clasificación para el método *Knn*.

con la sensibilidad, lo que conduce a una decisión poco confiable al instante de reconocer una imagen con características benignas.

En conclusión los métodos de clasificación resultan afectados por el incremento de las variables, lo que obliga a encontrar un equilibrio entre el número de características utilizadas y el conjunto muestral. Por lo anterior, el tercer experimento busca resolver esta dificultad, cuando se reduce el número de características a las 10 variables más discriminantes (Tabla 5-2) y también cuando el conjunto de datos original fue reducido mediante proyecciones espaciales (Tablas 5-3 y 5-4).

La tabla 5-2 muestra las características del conjunto de datos inicial que ofrecen más información para distinguir entre las clases benignas y malignas. Para la selección de características, se emplea un método de filtrado rápido que identifica características relevantes y también la redundancia entre ellas. Para la ejecución del procedimiento, se debe establecer un umbral de relevancia δ que contribuye a identificar las variables que poseen más correlación con una clase en particular. Esta técnica de selección de características es ampliamente discutida en [92].

Adicional a los valores δ utilizados para la selección de características, en la tabla 5-2 se indican los parámetros del clasificador (C_{op}, σ_{op}) óptimos que provocaron las mejores medidas de desempeño. Particularmente, el desempeño incrementa según la cantidad de variables relevantes utilizadas, sin estabilizarse en un número determinado de características.

Tabla 5-2.: Desempeño del clasificador SVM-RBF para el conjunto de datos formado con las características originales más relevantes.

Características	δ	Sens. %	Espec. %	Desempeño Gral. %	Parámetros Sint.	
					Costo C_{op}	σ_{op}
66	0.35	70.8333	81.818181	76.127	0.86189	0.066156
66, 57	0.33	69.7919	80.6818	75.0394	0.435296	0.04418464
66, 57, 69	0.26	69.7916	90.9090	79.7536	0.1418967	0.1
66, 57, 69, 10	0.255	69.7916	92.054	80.1499	0.3609206	0.0473389
66, 57, 69, 10, 19	0.23	68.75	93.18182	80.03905	0.04553503	0.1
66, 57, 69, 10, 19 2	0.2	73.9583	89.77273	81.4827	0.9749712	0.08110031
66, 57, 69, 10, 19 2, 59	0.19	70.8333	90.9090	80.24583	0.324417	0.06682221
66, 57, 69, 10, 19 2, 59, 30	0.18	71.875	93.18182	81.83791	0.4510057	0.05884909
66, 57, 69, 10, 19 2, 59, 30, 63	0.15	76.04167	90.9090	83.1437	0.8355741	0.0758441
66, 57, 69, 10, 19 2, 59, 30, 63, 53	0.145	75	90.9090	82.5722	0.4990188	0.06456001

Como se planteó anteriormente, en este estudio se definen como buenos desempeños a los resultados que presentan valores de sensibilidad y especificidad balanceados entre ellos y cercanos al 100 %. Con base en esta premisa, los mejores valores de sensibilidad y especificidad son resaltados en color azul. En este caso, el mejor desempeño se obtuvo cuando se emplearon nueve características, consiguiendo un 76.041 % de efectividad en la detección de malignidad y un 90.9090 % de efectividad en la detección de lesiones benignas. No obstante, el desbalance en los valores de desempeño no garantiza un diagnóstico confiable, porque existe una debilidad en la detección del melanoma. El desempeño general fue calculado usando la media geométrica de la sensibilidad y especificidad, en este caso fue del 83.143 %.

Debido a que las 10 características principales del arreglo de datos extraído son insuficientes para la identificación eficiente del melanoma, entonces mediante las transformaciones espaciales se encuentra la proyección que mejor comprime la información y contribuyen a la generación de nuevas variables que son la combinación de las variables originales. Así, se construye un arreglo de menor dimensión que contiene el aporte informativo de la base de datos original. A continuación se discuten los resultados obtenidos mediante la clasificación de los datos obtenidos con reducción de dimensionalidad PCA y LDA.

La tabla 5-3, se construyó con el mismo experimento de sintonización, sin embargo en esta ocasión se transformó el conjunto de datos original a un nuevo conjunto generado con la técnica de reducción de dimensionalidad PCA. Nuevamente, los mejores valores de desempeño son resaltados en color azul y corresponden a 73.958 % en sensibilidad y 89.772 % en especificidad. En esta ocasión, los resultados son levemente inferiores que con el conjunto de datos original, por lo cual se requiere un número superior a 10 características para generar un desempeño superior, siendo poco conveniente. Así mismo, las dos últimas columnas de la tabla 5-3, indican los parámetros de sintonización para el clasificador SVM. De acuerdo a los resultados, la transformación de los datos mediante PCA no es una opción apropiada para identificar las agrupaciones asociadas a malignidad y benignidad. Lo que indica que los datos proyectados por este método no exhiben suficiente separación de las clases.

Por último, en la tabla 5-4 se presentan los resultados de clasificación cuando el arreglo de los datos fue transformado espacialmente por medio de Análisis Discriminante Lineal, LDA. Como fue mencionado previamente, solo se utilizan las 10 nuevas características con los valores propios más pesados, que en conjunto acumularon el 100 % de la variabilidad de los datos. Para más detalle, la figura 5-8, indica la proporción en que los vectores propios influyen en las nuevas variables. Evidentemente, los valores propios asociados a los vectores propios **3, 2 y 4** son los más significativos, indicando que estos concentran ampliamente la mayor parte de información discriminante.

En este caso, se generó un incremento notable en las medidas de desempeño, logrando estabilizarse al incluir la característica número tres. Los mejores resultados de clasificación fueron del 90.625 % en sensibilidad y 100 % en especificidad, adicionalmente se obtuvo un

Tabla 5-3.: Desempeño del clasificador SVM-RBF para el conjunto de datos reducido en dimensión, mediante PCA.

Características	Sens. %	Espec. %	Desemp. Gral. %	Parámetros Sint.	
				Costo C_{op}	σ_{op}
1	14.5833	95.4545	37.31013	0.816245	0.0828646
1:2	64.5833	84.0901	73.6944	1	0.0686137
1:3	72.91667	82.95455	77.7738	0.09501802	0.095713
1:4	70.8333	79.54545	75.0631	0.0934805	0.058752
1:5	66.6666	87.50	76.3762	0.8537868	0.077149798
1:6	71.875	90.9090	80.83372	0.8294791	0.05467968
1:7	70.8333	92.0454	80.7488	0.862557	0.04055323
1:8	70.8333	92.054545	80.74581	0.94545121	0.03706466
1:9	70.8333	90.9090	80.24583	0.9029217	0.0981282
1:10	73.95833	89.77273	81.48277	0.9265728	0.0639145

desempeño general del 95.197 % calculado mediante la media geométrica de la sensibilidad y especificidad. Nótese que al incluir todas las características el nivel de desempeño es constante. La estabilidad del desempeño está directamente relacionada con el aporte informativo de los ejes principales, según la figura 5-8, los vectores superiores a los tres primeros poseen un aporte casi nulo. De este modo, con el ánimo de hacer más significativa la diferencia entre el número de sujetos por el número de variables incluidas, se prefiere utilizar la mínima

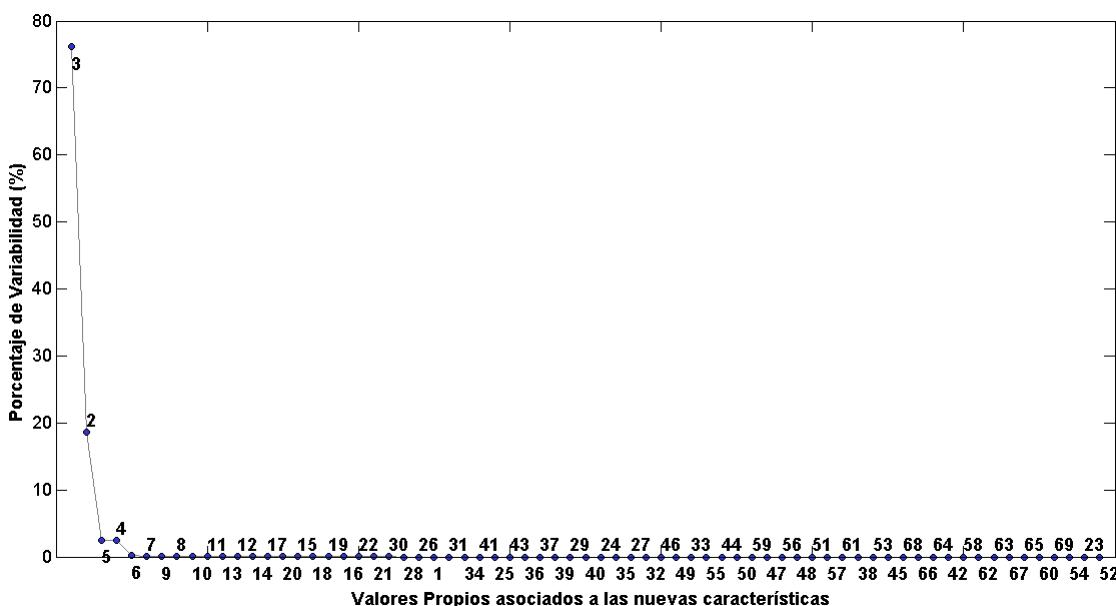


Figura 5-8.: Diagrama del aporte informativo de cada vector propio.

Tabla 5-4.: Desempeño del clasificador SVM-RBF para el conjunto de datos reducido en dimensión, mediante LDA.

Características	Sens. %	Espec. %	Desemp. Gral. %	Parámetros Sint.	
				Costo C_{op}	σ_{op}
1	91.66667	98.86364	95.19716	0.1	1,00e-04
1:2	90.625	98.86364	94.65473	0.9871461	0.06153595
1:3	90.625	100	95.19716	0.9135455	0.02101997
1:4	91.66667	98.86364	95.19716	0.9938959	0.08078024
1:5	91.66667	98.86364	95.19716	0.4475192	0.0850690
1:6	90.625	97.72727	94.10916	0.8923494	0.07195929
1:7	90.625	98.86364	94.65473	0.9167259	0.01623247
1:8	91.66667	98.86364	95.19716	0.9059714	0.07307509
1:9	91.66667	97.72727	94.64847	0.9162332	0.0306465
1:10	91.66667	98.86364	95.19716	0.8024926	0.1

cantidad de características posible, que en este caso es tres.

En comparación a los experimentos previos, en esta ocasión, los resultados sugieren que los datos son más separables y que las maquinas de vectores de soporte generaron una frontera de decisión con elevado nivel de precisión. Y aprovechando que las tres características principales pueden ser visualizadas en el espacio, en la figura 5-9 se indica la dispersión de los datos proyectados, luego de haber sido estandarizados con la norma zscore. Además, es posible distinguir visualmente las clases de interés.

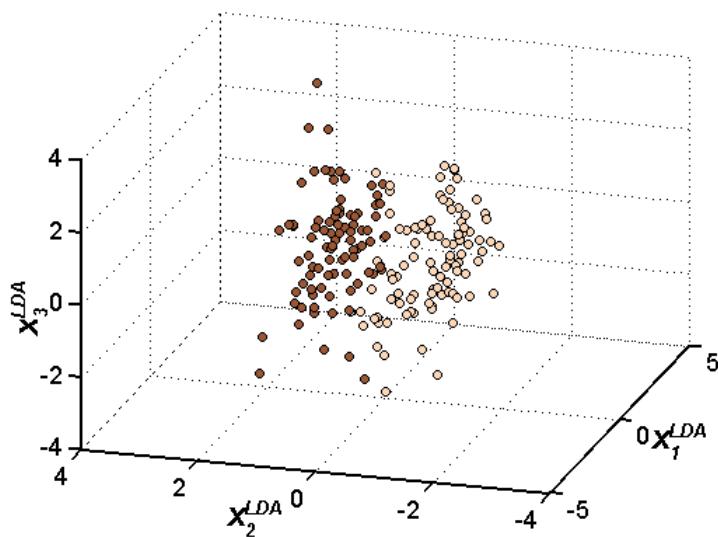


Figura 5-9.: Dispersión de los datos proyectados con LDA en el espacio 3D.

La notable separación de las clases para el experimento previo (Tabla 5-4) se debe principalmente al método de reducción de dimensión LDA, que busca maximizar la dispersión entre las clases y al mismo tiempo minimizar la dispersión espacial de cada clase.

5.4. Conclusiones

Las etapas de caracterización y clasificación podrían considerarse como el paso más trascendental en un sistema de inteligencia artificial, ya que como resultado de una caracterización inadecuada, la clasificación presentará fallas, con el agravante que de esto podría depender una decisión determinante ó incluso vital. La detección automática del melanoma, comparte la misma vulnerabilidad, una clasificación incorrecta podría desencadenar una serie de procedimientos muy incómodos para el usuario, como por ejemplo que deba ser sometido a exámenes detallados y rigurosos.

Por lo anterior, este tipo de sistemas son una herramienta muy útil si tienen la capacidad de superar múltiples dificultades, especialmente, ruido incluido en la etapa de adquisición, segmentación óptima sobre imágenes con protocolo desconocido, eficiente extracción de características y excelente clasificación.

Recientemente, se ha mostrado que los valores de desempeño respecto a la clasificación del melanoma para un dermatólogo experto, se encuentran en el intervalo de [75-84] %. Con la intención de ofrecer un soporte confiable en la tarea de diagnóstico del melanoma, se ha implementado un sistema de procesamiento de imágenes el cual finaliza en la etapa de caracterización y clasificación de lesiones pigmentadas benignas y malignas, el cual fue probado con imágenes capturadas especialmente y además, con un conjunto de imágenes dermatoscópicas tomadas de una base de datos que no poseía las mismas condiciones de captura. Del desarrollo del sistema, se consiguió estructurar una etapa de caracterización eficiente, proponiendo medidas que contribuyen a reconocer automáticamente los patrones malignos y benignos, las cuales están integradas por un conjunto de características locales, globales y particularmente medidas asociadas a la cuantificación del patrón reticular atípico, velo azul y asimetría.

Como resultado de la experimentación, se concluye que el método de máquinas de vectores de soporte es el algoritmo de clasificación de características que ofrece mejores valores de confiabilidad, generando un balance adecuado en la detección de malignidad (90.625 %) y benignidad (100 %), superando el desempeño obtenido por el especialista con experiencia y el desempeño promedio de los sistemas de diagnóstico automático similares. Además, se mostró que las medidas implementadas para la cuantificación del patrón reticular atípico y el velo azul, son características que influyen fuertemente en la clasificación correcta del melanoma. Los resultados sugieren además, que el sistema propuesto logra superar ampliamente las dificultades técnicas previamente mencionadas (ruido incluido en la etapa de adquisición, segmentación óptima sobre imágenes con protocolo desconocido, eficiente extracción de características y excelente clasificación), como consecuencia, puede entregar en un periodo

inferior a 50 seg., un aporte valioso para la tarea de reconocimiento de malignidad en imágenes dermatoscópicas, contribuyendo en la toma de decisiones por parte del especialista, pero también, siendo útil para el entrenamiento de técnicos inexpertos o personas en formación en el tema.

6. Conclusiones y Trabajo Futuro

En este trabajo se han planteado las estrategias para el desarrollo de un sistema de diagnóstico automático del Melanoma por medio del empleo de imágenes capturadas con la técnica de dermatoscopía. Para la implementación del sistema, se debieron superar las dificultades que presentan las lesiones pigmentadas PSL, entre las principales: bajo contraste, vellos localizados en la superficie de la lesión y por último, una estrecha similitud en características correspondientes a melanoma y lesión benigna. A fin de eliminar tales dificultades, fueron planteadas e implementadas diferentes estrategias en cada etapa de procesamiento.

Con la intención obtener imágenes con elevado nivel de detalle sobre sus estructuras relevantes, se propuso una metodología de adquisición en la que se controlaron parámetros físicos y parámetros técnicos. Del protocolo de adquisición propuesto se obtuvieron imágenes con calidad suficiente para ser detectadas eficientemente en la etapa de segmentación.

Para garantizar la calidad del detalle en las estructuras localizadas sobre la región de interés, se propuso un esquema de pre-procesamiento. Luego de la experimentación correspondiente, se determinó que la imagen original y sin ruido presentaba mayor nitidez en relación a otras técnicas de corrección de contraste, especialmente la transformación del espacio de color.

Para la eliminación del ruido ó las estructuras indeseables (Particularmente el vello) fue planteado un procedimiento para su remoción mediante operaciones morfológicas sucesivas. A pesar de las dificultades y exigencia en la implementación de una fase de evaluación cuantitativa se desarrolló una herramienta que simplifica la tarea de detección de vellos. De este modo se implementó un análisis supervisado con el que se encontró que el procedimiento propuesto para la remoción de vellos desempeña eficientemente su labor. Además, fue considerada la opinión del experto para el análisis de desempeño, al estudiar un conjunto de imágenes procesadas con el método diseñado y comparadas con las mismas imágenes procesadas por los algoritmos populares; *DullRazor* y la técnica de reconstrucción *Inpainting*. Con base en su criterio científico, el equipo de especialistas concluye que el método propuesto cumple de manera exitosa su función, elimina los vellos y no altera la textura de la superficie correspondiente a la región de interés.

Aunque en la bibliografía se subestima la capacidad de discriminación del color para la segmentación de la lesión pigmentada, en este trabajo se propone emplear el mapa color como criterio de segmentación. Con ese propósito, se utilizó el algoritmo de clustering mediante el Modelo de Mezclas Guassianas para detectar las distribuciones del color asociadas a piel y a lesión. Luego, se integró el procedimiento de detección del área de interés (Detección ROI)

a la imagen obtenida con el método de clustering. Como resultado del esquema propuesto se consiguieron resultados superiores a los métodos populares; Método de Otsu y Contornos activos. Adicionalmente, se observó que el método diseñado para la segmentación, tiene la capacidad de desempeñarse eficientemente en imágenes que no poseen el protocolo de adquisición sugerido, permitiendo la posibilidad de evaluar el sistema con bases de datos diferentes. El esquema de segmentación propuesto, además de rectificar los reportes bibliográficos con respecto al color no posee un estudio similar en la literatura, siendo un aporte novedoso y eficiente.

Para la caracterización se implementó una etapa en la que se cuantifican los patrones principales según la **lista de los tres puntos**, específicamente, el patrón reticular atípico, la asimetría de patrones y el velo blanco-azulado. Como resultado de la caracterización se obtuvieron 69 medidas sobre la imagen, integradas por un conjunto de variables locales y globales. De la evaluación de estas, se encontró que las medidas locales propuestas para la detección del patrón reticular y velo azul, hacían parte de las características más importantes para la discriminación del melanoma. También se encontró, que la intensidad promedio del borde de la lesión, es la variable que ofrece más información relevante, lo que concuerda con el procedimiento de diagnóstico técnico, Regla ABCD.

Adicionalmente, los experimentos de clasificación indican que la máquina de vectores de soporte con kernel gaussiano de base radial genera desempeños superiores cuando el conjunto de datos posee todas sus características, consiguiendo valores de sensibilidad y especificidad del 90.625 % y 100 %, respectivamente. Los resultados fueron comparados con los métodos de clasificación *knn*, *SVM*-Lineal, *SVM – polinomial*, y análisis discriminante lineal.

Aunque la ausencia de un conjunto de imágenes propias, en un principio dificultó la tarea de evaluación del sistema, esta situación contribuyó a evaluar la capacidad real del mismo, específicamente, porque fue utilizado en imágenes que no poseían el protocolo propuesto desempeñándose de manera destacada.

Entre los principales beneficios que ofrece el sistema, cabe mencionar que es una herramienta valiosa al momento de realizar un diagnóstico. Con base en los resultados experimentales, el sistema es capaz de ofrecer una segunda opinión con un alto grado de confiabilidad. Tal opinión puede ser cotejada con la diagnosis del especialista, de este modo no solo se reduce la subjetividad implícita en el análisis técnico, sino que también contribuye a establecer las decisiones importantes que preservan la calidad de vida humana. Adicionalmente, la herramienta computacional propuesta, puede ser empleada como medio de capacitación para técnicos inexpertos ó como instrumento de prevención mediante el control de evolución de las lesiones, reduciendo el riesgo de alcanzar un estado letal.

6.1. Trabajos Futuros

Como consecuencia de esta investigación se establecen los siguientes trabajos futuros:

- Integrar una base de datos con un número de imágenes superior. En la medida que se procesan nuevas imágenes con un diagnóstico establecido, estas servirán para alimentar la base de datos que a la poste contribuyen a incrementar la experiencia en la clasificación. De este modo, la confiabilidad en el diagnóstico del melanoma incrementara aun más.
- Usualmente, los métodos de diagnóstico requieren la extracción de un número elevado de características cuando las medidas obtenidas fueron de carácter global. Lo cual es debido a que las variables globales no ofrecen suficiente información. Sin embargo el problema principal subyace en que al incrementar el número de características, la etapa de clasificación se vuelve propensa a perder generalidad y a sufrir de sobre-entrenamiento. Con la intención de evitar la influencia con el número de características, es apropiado agregar nuevas características discriminantes. Para la cual se considera que las variables locales son una opción prometedora. Específicamente, se propone integrar las medidas de presencia del patrón reticular atípico y velo azul para encontrar una nueva característica que cuantifique la asimetría de patrones.
- Explorar nuevas técnicas de clasificación que contribuyan al incrementar el desempeño general del sistema.
- Implementar una interfaz grafica en una plataforma que ofrezca más ventajas que **Matlab**, en términos de portabilidad y eficiencia computacional. Básicamente, porque este software demanda un tiempo considerable para la finalización de un proceso. La interfaz deberá ser amigable con el usuario para facilitar su uso, lo cual hará del sistema una herramienta práctica en las tareas médicas.

A. Anexo: Protocolo de Adquisición

El protocolo de adquisición se estableció con base en múltiples pruebas experimentales bajo la supervisión del especialista en dermatología, quien indicó bajo que variación de parámetros se visualizaban con mayor nitidez las estructuras melanocíticas. Adicionalmente, buscando que el procedimiento fuera menos complejo, para luego ser aplicado con facilidad y evitar la omisión de alguno de los pasos, lo que como consecuencia provocaría la variabilidad en las características discriminantes sobre las imágenes. Entre los parámetros que se modificaron se encuentran: iluminación, distancia con el foco, inclusión de aceite de inmersión, presión sobre la lesión y finalmente configuración de la cámara, que fue obtenida como se indica en la siguiente sección A.1. Como resultado del proceso experimental, el procedimiento para la captura de las imágenes empleó un dermatoscopio *DermLite II Pro* unido a una cámara *Canon PowerShot A2200*. Se describe el protocolo a continuación:

1. Configurar la cámara con los parámetros predeterminados, Tabla A-1.
2. Humectar la lesión y verificar que tanto el dermatoscopio como la lesión están libres de partículas indeseables.
3. Luego de encender y extender la placa frontal del dispositivo, ubicar el dermatoscopio sobre la piel de manera que la lesión quede en el centro de la imagen.
4. Para evitar el efecto tipo túnel, enfocar la cámara variando el zoom de tal manera que las estructuras de la lesión sean nítidas y desaparezcan las regiones oscuras a los extremos, adicionalmente, teniendo en cuenta, no utilizar el zoom digital.
5. Para la toma de la imagen, pulsar ligeramente hasta que la cámara emita un doble pitido lo que indica el enfoque exitoso, entonces, oprimir por completo el botón de disparo.

Las imágenes fueron tomadas conservando una dimensión de 1200×1600 píxeles, la cual es una dimensión promedio que permite incluir con suficiente grado de detalle las estructuras melanocíticas y el procesado sin un elevado costo computacional. Adicionalmente, con el parámetro macro activo, que según el manual de la cámara permite fotografiar un objeto a una distancia extremadamente corta.

Tabla A-1.: Configuración de la Cámara

Característica	Parámetro
Modo	Programación P
ISO	800
Iluminación	Luz Día
Tonos	Intenso
Enfoque	Media Ponderada Central
Calidad	Normal

A.1. Elección de los Parámetros de la Cámara (Canon PowerShot A2200)

La elección de los parámetros de la cámara fueron realizados principalmente con el objetivo de manipular completamente la captura de las imágenes y reducir el margen de error que podría aparecer en el protocolo de adquisición. Por tal motivo, se consideró adecuado analizar el comportamiento de todos los parámetros de la cámara en modo manual, inspirados en encontrar la configuración que básicamente cumpliera con dos criterios: definir apropiadamente la región de interés y a la vez, favorecer la nitidez de los patrones.

En este sentido, la región de interés fue estudiada empleando los algoritmos de segmentación desarrollados hasta el momento y comparando los resultados con el Método de Otsu, de tal manera que el parámetro de la cámara más indicado corresponde al que provoca la consistencia de todos los desempeños asociados a los métodos de segmentación, e igualmente, fomenta la identificación de la lesión pigmentada con mayor exactitud por parte de los algoritmos de segmentación.

El análisis de nitidez fue incluido de manera supervisada al establecer el parámetro de la cámara que perteneciendo a una categoría específica, ofrece los mejores contrastes.

Esencialmente, la configuración de la cámara requirió de un procedimiento de calibración, iterativo para cada parámetro de una categoría específica, donde las categorías a considerar fueron ISO, Iluminación, Colores, Enfoque y Calidad, los parámetros de cada tipo son mostrados en la segunda columna de la Tabla A-2. Inicialmente, se estableció la configuración estándar de la cámara en modo manual, luego se capturaron las imágenes variando todos los parámetros de la categoría específica actual, posteriormente se procedió a identificar visualmente el parámetro que contrastó con mayor detalle la imagen dentro de esa categoría, en ese punto, el parámetro encontrado puede ser empleado para la captura de imágenes y proceder a cubrir las siguientes categorías de manera sucesiva.

El procedimiento iterativo previamente mencionado, dio como resultado 108 imágenes co-

rrespondientes a la variación de cada parámetro sobre 6 imágenes seleccionadas intencionalmente.

Finalmente, se evaluaron las imágenes con los algoritmos de segmentación mencionados, comparando cada imagen segmentada automáticamente con su respectiva imagen segmentada manualmente por el especialista. Los desempeños son mostrados en la Tabla A-2, se eligieron los parámetros que provocaron el valor promedio más alto y la menor desviación estándar.

Tabla A-2.: Desempeños de Segmentación de las imágenes obtenidas mediante la variación de los parámetros de la cámara.

Característica	Parámetro	Desempeño Otsu	Desempeño Cmap	Desempeño Reg.	Media	Desviación Estándar
<i>ISO</i>	80	0.7600	0.7239	0.7706	0.7515	0.0245
	100	0.6778	0.7113	0.7914	0.7268	0.0584
	200	0.6750	0.7204	0.7774	0.7243	0.0513
	400	0.7511	0.7297	0.7605	0.7471	0.0158
	800	0.7596	0.7600	0.7574	0.7590	0.0014
	1600	0.6900	0.6734	0.7344	0.6993	0.0315
<i>Iluminación</i>	Luz Día	0.7642	0.6978	0.8193	0.7604	0.0608
	Nublado	0.6564	0.6967	0.7000	0.6844	0.0243
	Tungsteno	0.6852	0.7180	0.5484	0.6505	0.0900
	Fluorescente	0.6649	0.7035	0.7585	0.7090	0.0470
	Fluorescente H	0.7500	0.7431	0.7502	0.7478	0.0040
<i>Tonos</i>	Intenso	0.6707	0.7429	0.7592	0.7243	0.0471
	Neutro	0.6586	0.7404	0.7316	0.7102	0.0449
<i>Enfoque</i>	Evaluativo	0.6665	0.6491	0.7050	0.6735	0.0286
	Media	0.7576	0.7552	0.8061	0.7730	0.0287
	Ponder. Central					
	Puntual	0.6744	0.7391	0.6573	0.6903	0.0431
<i>Calidad</i>	Fina	0.6558	0.6659	0.6848	0.6688	0.0147
	Normal	0.6687	0.7269	0.7549	0.7168	0.0440

B. Anexo: Aproximación de Funciones Mediante Ajuste Polinomial Usando el Método Mínimos Cuadrados

Considere una función $f(x_i, y_i)$ definida en el espacio de los números reales, ecuación B-1.

$$f = \{(x_i, y_i) : [x_i, y_i] \in R^2\} \quad (\text{B-1})$$

Obtener una representación continua de la función f es posible al extender el concepto de mínimos cuadrados, básicamente, encontrando los coeficientes que definen el polinomio $P(x)$ de grado n , que al mismo tiempo minimizan la diferencia entre la función original y el polinomio $P(x)$ encontrado.

Según el método de mínimos cuadrados, el procedimiento de minimización facilita la estimación de los coeficientes de una recta [86]. Para encontrar los coeficientes que definen el polinomio $P(x)$, se procede a minimizar la función B-2.

$$E = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (\text{B-2})$$

$$\text{Dónde } \hat{y}_i = P(x_i) = a_0 x_i^n + a_1 x_i^{n-1} + \cdots + a_n x_i^0 = \sum_{j=0}^n a_j x_i^{n-j}.$$

Derivando con respecto a cada coeficiente a_p e igualando a cero.

$$\frac{\partial E}{\partial a_p} = \left(\sum_i^N y_i - \sum_j^n a_j x_i^{n-j} \right)^2 = 0 \quad (\text{B-3})$$

Luego de calcular la derivada parcial y extender la sumatorias presentes en la función B-2 sobre algunos coeficientes, se obtiene que la derivada parcial para el coeficiente a_p , se calcula mediante B-4.

$$\frac{\partial E}{\partial a_p} = \sum_i^N y_i x_i^{2n-p} - \sum_i^N \sum_j^n a_j x_i^{n-j-p} = 0 \quad (\text{B-4})$$

Ahora, reorganizando los elementos de la ecuación B-4, se encuentra:

$$\sum_i^N \sum_j^n a_j x_i^{2n-j-p} = \sum_i^N y_i x_i^{n-p} \quad (\text{B-5})$$

Posteriormente, generando el conjunto de ecuaciones asociadas a cada coeficiente a_p , se obtiene:

$$\begin{aligned} \sum_i^N a_0 x_i^{2n} + \sum_i^N a_1 x_i^{2n-1} + \sum_i^N a_2 x_i^{2n-2} + \cdots + \sum_i^N a_n x_i^n &= \sum_i^N y_i x_i^n \\ \sum_i^N a_0 x_i^{2n-1} + \sum_i^N a_1 x_i^{2n-2} + \sum_i^N a_2 x_i^{2n-3} + \cdots + \sum_i^N a_n x_i^{n-1} &= \sum_i^N y_i x_i^{n-1} \\ \sum_i^N a_0 x_i^{2n-2} + \sum_i^N a_1 x_i^{2n-3} + \sum_i^N a_2 x_i^{2n-4} + \cdots + \sum_i^N a_n x_i^{n-2} &= \sum_i^N y_i x_i^{n-2} \\ &\vdots \\ \sum_i^N a_0 x_i^n + \sum_i^N a_1 x_i^{n-1} + \sum_i^N a_2 x_i^{n-2} + \cdots + \sum_i^N a_n x_i^0 &= \sum_i^N y_i x_i^0 \end{aligned} \quad (\text{B-6})$$

Finalmente, el conjunto de ecuaciones en B-6, puede tomarse como un sistema de ecuaciones donde las incógnitas son todos los coeficientes a_p , el cual puede ser fácilmente resuelto mediante la ecuación B-8 (Cuando A^{-1} existe), después de haber sido reorganizado de manera matricial.

$$\underbrace{\begin{bmatrix} \sum_i^N x_i^{2n} & \sum_i^N x_i^{2n-1} & \sum_i^N x_i^{2n-2} & \cdots & \sum_i^N x_i^n \\ \sum_i^N x_i^{2n-1} & \sum_i^N x_i^{2n-2} & \sum_i^N x_i^{2n-3} & \cdots & \sum_i^N x_i^{n-1} \\ \sum_i^N x_i^{2n-2} & \sum_i^N x_i^{2n-3} & \sum_i^N x_i^{2n-4} & \cdots & \sum_i^N x_i^{n-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_i^N x_i^n & \sum_i^N x_i^{n-1} & \sum_i^N x_i^{n-2} & \cdots & \sum_i^N x_i^0 \end{bmatrix}}_A \underbrace{\begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}}_X = \underbrace{\begin{bmatrix} \sum_i^N y_i x_i^n \\ \sum_i^N y_i x_i^{n-1} \\ \sum_i^N y_i x_i^{n-2} \\ \vdots \\ \sum_i^N y_i x_i^0 \end{bmatrix}}_B \quad (\text{B-7})$$

$$X = A^{-1}B \quad (\text{B-8})$$

Si se desea aproximar la función f con un polinomio $P(x) = a_0x^2 + a_1x^1 + a_2x^0$ de grado $n = 2$, entonces, se obtiene un sistema de ecuaciones como el mostrado en B-9.

$$\underbrace{\begin{bmatrix} \sum_i^N x_i^4 & \sum_i^N x_i^3 & \sum_i^N x_i^2 \\ \sum_i^N x_i^3 & \sum_i^N x_i^2 & \sum_i^N x_i^1 \\ \sum_i^N x_i^2 & \sum_i^N x_i^1 & \sum_i^N x_i^0 \end{bmatrix}}_A \underbrace{\begin{bmatrix} a_0 \\ a_1 \\ a_3 \end{bmatrix}}_X = \underbrace{\begin{bmatrix} \sum_i^N y_i x_i^2 \\ \sum_i^N y_i x_i \\ \sum_i^N y_i \end{bmatrix}}_B \quad (\text{B-9})$$

C. Anexo: Descripción de las Características Empleadas

A continuación se describen las características utilizadas en este trabajo.

Variable	Nombre de Variable	Descripción
X_1	Área/(No. Pixeles en la imagen)	Porcentaje de píxeles en la imagen que pertenecen a lesión melanocítica.
X_2	Perímetro	Suma de píxeles en el borde de la lesión.
X_3	Redondez	Grado de circularidad de la lesión.
X_4	Convexhull	Área de la diferencia de la imagen original encerrada por un polígono convexo y la imagen original.
X_5	Relación en Dimensión (Aspect Ratio)	Relación entre el ancho de la imagen con respecto al largo de la imagen.
X_6	Índice Fractal Área	
X_7	Índice Fractal Perímetro	
X_8	Razón Índices Fractales	
X_9	Abscisa Centro de Gravedad	
X_{10}	Ordenada Centro de Gravedad	
X_{11}	% Dispersión del Eje de Simetría Mayor	
X_{12}	% Dispersión del Eje de Simetría Menor	
X_{13-56}	Momentos Estadísticos centralizados Hu φ_{pq}	$\mu_{pq} = \sum_{x=0}^M \sum_{y=0}^N (x - \bar{x})^p (y - \bar{y})^q f(x, y)$ con $p, q = 1, \dots,$
X_{57}	Promedio de intensidades	
X_{58}	Entropía	
X_{59}	Curvatura	
X_{60}	Índice de Asimetría 1	Reportado en [24]
X_{61}	Índice de Asimetría 2	Reportado en [24]
X_{62}	Índice de Asimetría 3	Reportado en [24]

X_{63}	Velo Azul	Expuesto en la sección 5.1.2
X_{64}	Patrón Reticular	Expuesto en la sección 5.1.1
X_{65}	Índice de Asimetría 4	Expuesto en la sección 5.1.3
X_{66}	Intensidad Promedio del borde en Canal B	
X_{67}	Intensidad Mínima del Canal G	
X_{68}	Intensidad Promedio del Canal B	
X_{69}	Desviación Estándar R	

Los momentos estadísticos fueron usados con las ecuaciones descritas en [22].

C.1. Características Relevantes Obtenidas en la etapa de Clasificación

No. Selección de Características Relevantes	Características
$n = 1$	X_{66}
$n = 10$	$X_{66}, X_{68}, X_{57}, X_{69}, X_{10}, X_{13}, X_{25}, X_{20}, X_{33}, X_{18}$
$n = 20$	Las mismas que en $n = 10$, y adicionando: $X_{64}, X_{63}, X_{19}, X_{59}, X_{17}, X_5, X_{53}, X_{55}, X_2, X_{54}$
$n = 30$	Las mismas que en $n = 20$, y adicionando: $X_{51}, X_{56}, X_{30}, X_{23}, X_{40}, X_{67}, X_{38}, X_{52}, X_{65}, X_{11}$
$n = 40$	Las mismas que en $n = 30$, y adicionando: $X_{12}, X_{24}, X_{14}, X_{50}, X_{34}, X_9, X_{32}, X_8, X_{15}, X_{16}$
$n = 50$	Las mismas que en $n = 40$, y adicionando: $X_{22}, X_{60}, X_{62}, X_{42}, X_{26}, X_{36}, X_{27}, X_3, X_{49}, X_6$
$n = 60$	Las mismas que en $n = 50$, y adicionando: $X_4, X_{44}, X_{31}, X_{41}, X_{47}, X_{45}, X_{21}, X_{58}, X_{46}, X_7$
$n = 69$	Las mismas que en $n = 60$, y adicionando: $X_1, X_{28}, X_{29}, X_{35}, X_{37}, X_{39}, X_{43}, X_{48}, X_{61}$

D. Anexo: Publicaciones y Memorias de Eventos

- Cristian F. Ocampo B., Juan C. Riaño R., F. A. Prieto, E. Sanchez. Segmentación de Imágenes Capilares Basado en Colormap. Novena Conferencia Iberoamericana en Sistemas, Cibernética e Informática: CISCI, Orlando, Florida EE.UU (2010). Memorias del evento.
- C. F. Ocampo B, J. C. Riaño R. & E. Restrepo P. A Dynamic Approach and Color Regression to Image Segmentation. Presentación de Poster en ICIAM 2011. Vancouver, Canada.
- Cristian F. Ocampo B., Juan C. Riaño R. and Elisabeth Restrepo P. Contrast Enhancement by Applying Color Compaction in Dermoscopy Images. Bajo correcciones.
- Cristian F. Ocampo B., Juan C. Riaño R. and Elisabeth Restrepo P. Contrast Enhancement by Searching Discriminant Color Projection in Dermoscopy Images. Bajo correcciones.
- Cristian F. Ocampo B., Juan C. Riaño R. and Elisabeth Restrepo P. Multi-Scale Morphological Reconstruction for Hair Removal in Dermoscopy Images. Bajo correcciones.
- Cristian F. Ocampo B., Juan C. Riaño R. and Elisabeth Restrepo P. Skin Lesion Segmentation by Fitting Gaussian Mixture Model on Colormap. En preparación.
- Cristian F. Ocampo B., Juan C. Riaño R. and Elisabeth Restrepo P. Automatic Melanoma Classification based on the Three Point Checklist Screening Method. En preparación.

Bibliografía

- [1] A., S. S. ; KALYANKAR, N.V. ; S.D.KHAMITKAR.: Linear and Non-linear Contrast Enhancement Image. En: *International Journal of Computer Science and Network Security*. 10 (2010), p. 139–143.
- [2] ABBAS, Q. ; CELEBI, M. E. ; GARCÍA., I. F.: Hair removal methods: A comparative study for dermoscopy images. En: *Biomedical Signal Processing and Control*. (2011), p. .
- [3] ABBAS, Q. ; FONDON, I. ; RASHID., M.: Unsupervised skin lesions border detection via two-dimensional image analysis. En: *Comput. Meth. Prog. Bio.*, 2010, p. .
- [4] ALCÓN, J. F. ; CIUHU, C. ; KATE, W. ; HEINRICH, A. ; UZUNBAJAKAVA, N. ; KREKELS, G. ; SIEM, D. ; HAAN., G.: Automatic Imaging System With Decision Support for Inspection of Pigmented Skin Lesions and Melanoma Diagnosis. En: *IEEE Journal of Selected Topics in Signal Processing* 3 (2009), p. 14–25.
- [5] AMALIAH, Bilqis ; FATICHAH, Chastine ; WIDYANTO., M. R.: ABCD Feature Extraction of Image Dermatocopic Based on Morphology Analysis for Melanoma Skin Cancer Diagnosis. En: *Jurnal Ilmu Komputer Fakultas Ilmu Komputer* 2 (2010), p. 1–8.
- [6] ANANTHA, Murali ; MOSS, Randy H. ; STOECKER., William V.: Detection of pigment network in dermatoscopy images using texture analysis. En: *Computerized Medical Imaging and Graphics*. 28 (2004), p. 225–234.
- [7] ARANGO-ARGOTY, G.A. ; JARAMILLO-GARZON, J. A. ; ROTHLISBERGER, S. ; CASTELLANOS-DOMINGUEZ, G. C.: Classification of unaligned sequences based on prototype motifs representation. En: *6th Colombian Computing Congress (CCC)*, 2011, p. 1–5.
- [8] ARGENTZIANO, G. ; FABBROCINI, G. ; CARLI, P. ; GIORGI, V. ; SAMMARCO, E. ; DELFINO., M.: Epiluminescence Microscopy for the diagnosis of doubtful Melanocytic Skin lesions. Comparison of the ABCD rule and a new 7 Point checklist based on Pattern Analysis. En: *Arch. Dermatology* 134 (1998), p. 1563–1570

- [9] ARGENZIANO, G. ; SOYER, H. P. ; CHIMENTI, S. ; TALAMINI, R. ; ET AL.: Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the Internet. En: *J. Am. Acad. Dermat.* 48 (2003), p. 680–693
- [10] BETTA, G. ; LEO, G. D. ; FABBROCINI, G. ; PAOLILLO, A. ; SOMMELLA., P.: Dermoscopic image-analysis system: estimation of atypical pigment network and atypical vascular pattern. En: *International Workshop on Medical Measurement and Applications.*, 2006, p. 63–67.
- [11] BURRONI, M. ; CORONA, R. ; DELL'EVA, G. ; SERA, F. ; BONO, R. ; PUDDU, P. ; PEROTTI, R. ; NOBILE, F. ; ANDREASSI., L. ; RUBEGNI., P.: Melanoma computer-aided diagnosis: reliability and feasibility study. En: *Clinical Cancer Research.* 10 (2004), p. 1881–1886.
- [12] CAPDEHOURAT, G. ; COREZ, A. ; BAZZANO, A. ; ALONSO, R. ; MUSÉ., P.: Toward a combined tool to assist dermatologists in melanoma detection from dermoscopic images of pigmented skin lesions. En: *Pattern Recognition Letters* (2011), p. 1–10.
- [13] CAPDEHOURAT, G. ; COREZ, A. ; BAZZANO, A. ; MUSÉ., P.: Pigmented skin lesions classification using dermatoscopic images. En: *CIARP*, 2009.
- [14] CARRERA, C. ; ZABALLOS, P. ; PUIG, S. ; MALVEHY, J. ; MASCARO-GALY, J. ; PALOU., J.: Correlacion Histologica en Dermatoscopia: Lesiones Melanociticas y no Melanociticas. Criterios Dermatoscopicos de Nevus Melanociticos. En: *Med. Cut. Am. Lat.* 32(3) (2004), p. 47–60.
- [15] CELEBI, M. ; IYATOMI, G. Schaeferand H. ; STOECKER., W. V.: Lesion Border Detection in Dermoscopy Images. En: *Comput. Med. Imaging Graph.* 33 (2009), p. 148–153.
- [16] CELEBI, M. E. ; IYATOMI, H. ; SCHAEFER., G.: CONTRAST ENHANCEMENT IN DERMOSCOPY IMAGES BY MAXIMIZING A HISTOGRAM BIMODALITY MEASURE. En: *IEEE International Conference on Image Processing (ICIP 2009).*, 2009, p. .
- [17] CELEBI, M. E. ; HWANG, Sae ; IYATOMI, Hitoshi ; SCHAEFER., Gerald: Robust Border Detection in Dermoscopy Images using Threshold Fusion. En: *IEEE 17th International Conference on Image Processing.*, 2010, p. 2541–2544.
- [18] CELEBI, M. E. ; IYATOMI, Hitoshi ; STOECKER, William V. ; MOSS, Randy H. ; RABINOVITZ, Harold S. ; ARGENZIANO, Giuseppe ; SOYER., H. P.: Automatic Detection of Blue-White Veil and Related Structures in Dermoscopy Images. En: *Computerized Medical Imaging and Graphics.* 32 (2008), p. 670–677.

- [19] CELEBI, M. E. ; KINGRAVI, Hassan A. ; IYATOMI, Hitoshi ; ASLANDOGAN, Y. A. ; STOECKER, William V. ; MOSS, Randy H. ; MALTERS, Joseph M. ; GRICHNIK, James M. ; MARGHOOB, Ashfaq A. ; RABINOVITZ, Harold S. ; MENZIES., Scott W.: Border detection in dermoscopy images using statistical region merging. En: *Skin Res. Technol.* 14 (2008), p. 347–353.
- [20] CELEBI, M. E. ; SCHAEFER, Gerald ; IYATOMI, Hitoshi ; STOECKER, William V. ; MALTERS, Joseph M. ; GRICHNIK, James M.: An Improved Objective Evaluation Measure for Border Detection in Dermoscopy Images. En: *Skin Res. Technol.* 15 (2009), p. 444–50.
- [21] CHENG, H.D. ; XUE, M. ; SHI., X.J.: Contrast enhancement based on a novel homogeneity measurement. En: *Pattern Recognition.* 36 (2003), p. 2687–2697.
- [22] CHIM, Y. C. ; KASSIM, A. A. ; IBRAHIM., Y.: Character recognition using statical moments. En: *Images and vision computing.* 17 (1999), p. 299–307.
- [23] CHUNG, D. H. ; SAPIRO., G.: Segmenting Skin Lesions with Partial-Differential-Equations-Based Image Processing Algorithms. En: *IEEE Tran. on Medical Imaging.* 19 (2000), p. 763–767.
- [24] CLAWSON, K. M. ; MORROW, P. J. ; SCOTNEY, B. W. ; MCKENNA, D. J. ; DOLAN., O. M.: Computerised Skin Lesion Surface Analysis for Pigment Asymmetry Quantification. En: *International Machine Vision and Image Processing Conference.*, 2007, p. 75–82.
- [25] CLERC, M. ; ET AL. Url: http://www.particleswarm.info/standard_pso_2007.c. 2010
- [26] CONTRA EL CÁNCER., Liga. Url: <http://www.ligacontraelcancer.com.co/tiposcancerdepiel.php>. 2010
- [27] CRIMINISI, A. ; PEREZ, P. ; TOYAMA., K.: Region filling and object removal by exemplar-based Image inpainting. En: *IEEE Trans. Image Process.* 13 (2004), p. 1–13.
- [28] DAY, G. R. ; BARBOUR., R. H.: Automated Melanoma Diagnosis: Where are we at? En: *Skin Research and Technology.* 6 (2000), p. 1–5.
- [29] DELASCO. *Dermlite II Pro, Instructions.* <http://www.delasco.com/pcat/1/Diagnostic/DLiteProII/DLiteProII/>
- [30] DREISEITL, S. ; OHNO-MACHADO, L. ; KITTNER, H. ; VINTERBO, S. ; BILLHARDT, H. ; BINDER., M.: A Comparison of Machine Learning Methods for the Diagnosis of Pigmented Skin Lesions. En: *Journal of Biomedical Informatics.* 34 (2001), p. 28–36.

- [31] DU, C. ; SUN., D.: Recent developments in the applications of image processing techniques for food quality evaluation. En: *Trends in Food Science & Technology*. 15 (2004), p. 230–249.
- [32] DUDA, Richard O. ; HART, Peter E. ; STORK., David G.: *Pattern Classification*. 2nd Ed. John Wiley & Sons., 2001.
- [33] DYNAMED.: Melanoma / <http://dynamed.ebscohost.com/>. 2011. – Informe de Investigación
- [34] ESPACIAL CIVIL ECUATORIANA., Agencia. *Informe Hiperión*. 2008
- [35] EHRSAM, Eric: Dermoscopy / <http://dermoscopic.blogspot.com/>. 2011. – Informe de Investigación
- [36] FIGUEREIDO, M. ; JAIN., A. J.: Unsupervised Learning of Finite Mixture Models. En: *IEEE Tran. Pattern Analysis and Machine Intelligence*. 24 (2002), p. 381–396.
- [37] FRIEDMAN, R. J. ; GUTKOWICZ-KRUSIN, D. ; FARBER, M. J. ; WARYCHA, M. ; SCHNEIDER-KELS, L. ; PAPASTATHIS, N. ; MIHM, M. C. ; GOOGE, P. ; KING, R. ; PRIETO, V. G. ; KOPF, A. W. ; POLSKY, D. ; RABINOVIT, H. ; OLIVIERO, M. ; A.COGNETTA ; RIGE, D. S. ; MARGHOOB, A. ; RIVERS, J. ; JOHR, R. ; GRANT-KELS, J. M. ; TSAO., Hensin: The Diagnostic Performance of Expert Dermoscopists vs a Computer-Vision System on Small-Diameter Melanomas. En: *ARCH DERMATOL*. 144 (2008), p. 476–482.
- [38] G., M. C. ; ONSUN, N. ; ATILGANOGLU, U. ; DEMIRKESEN., C.: Comparison of two dermoscopic techniques in the diagnosis of clinically atypical pigmented skin lesions and melanoma: seven-point and three-point checklists. En: *International Journal of Dermatology*. 49 (2010), p. 33–38.
- [39] GANSTER, H. ; PINZ, A. ; RÖHRER, R. ; WILDLING, E. ; BINDER, M. ; KITTNER., H.: Automated Melanoma Recognition. En: *IEEE Transactions on Medical Imaging* 20 (2001), p. 233–239.
- [40] GARNAVI, R. ; ALDEEN, M. ; FINCH, S. ; VARIGOS., G.: Global versus Hybrid Thresholding for Border Detection in Dermoscopy Images. En: *Image and Signal Processing: 4th International Conference*, 2010, p. 531–540.
- [41] GEUSEBROEK, J. M. ; SMEULDERS, A. ; J., V. W.: Fast Anisotropic Gauss Filtering. En: *IEEE Trans on Image Processing* 12 (2003), p. 938–943.

- [42] GOLA, Andrés I. ; ZAPIRAIN, Begoña G. ; ZORRILLA, Amaia M. ; OLEAGORDIA., Ibon R.: Automated Diagnosis of Melanomas Based on Globular And Reticular Pattern Recognition Algorithms for Epiluminiscence Images. En: *18th European Signal Processing Conference (EUSIPCO-2010)*., 2010, p. 264–268.
- [43] GONZALEZ, R. ; WOODS, R. ; EDDINS, S.: *Digital Image Processing Using MATLAB, 2nd edition*. Gatesmark Publishing, 2009.
- [44] GRANA, Costantino ; DANIELE, Vanini ; PELLACANI, Giovanni ; SEIDENARI, Stefania ; CUCCHIARA., Rita: Network patterns recognition for automatic dermatologic images classification. En: *SPIE 2007*., 2007
- [45] H.P., Soyer ; G., Argenziano ; I., Zalaudek ; R., Corona ; F., Sera ; R., Talamini ; F., Barbato ; A., Baroni ; L., Cicale ; A., Di S. ; P., Farro ; L., Rossiello ; E., Ruocco ; S., Chimenti: Three-point checklist of dermoscopy. A new screening method for early detection of melanoma. En: *Dermatology*. 208 (2004), p. 27–31.
- [46] ISASI, A. G. ; ZAPIRAIN, B. G. ; ZORRILLA., A. M.: Melanomas non-invasive diagnosis application based on the ABCD rule and pattern recognition image processing algorithms. En: *Computers in Biology and Medicine*. 41 (2011), p. 742–755.
- [47] IYATOMI, H. ; OKA, H. ; CELEBI, M. E. ; HASHIMOTO, M. ; HAGIWARA, M. ; TANAKA, M. ; OGAWA., K.: An improved Internet-based melanoma screening system with dermatologist-like tumor area extraction algorithm. En: *Computerized Medical Imaging and Graphics* 32 (2008), p. 566–579.
- [48] IYATOMI, H. ; OKA, H. ; HASHIMOTO, M. ; TANAKA, M. ; OGAWA., K.: An internet-based melanoma diagnostic system Toward the practical application. En: *Proc. 2005 IEEE Symp. Computational Intelligence in Bioinformatics and Computational Biology*., 2005, p. 1–4.
- [49] JOHR., R. H.: Dermoscopy: alternative melanocytic algorithm: the ABCD rule of dermatoscopy, menzies scoring method, and 7-point checklist. En: *Clinics in Dermatology*. 20(3) (2002), p. 240–247.
- [50] J.WANG ; YAU, W. ; SUWANDY, A. ; SUNG., E.: Person recognition by using palmprint and palm vein images based on *LaplacianPalm* representation. En: *Pattern Recognition*. 41 (2008), p. 1514–1527.
- [51] KITTLER, H. ; PEHAMBERGER, H. ; WOLFF, K. ; BINDER., M.: Diagnostic accuracy of dermoscopy. En: *THE LANCET Oncology*. 3 (2002), p. 160–165.
- [52] KOPF, Alfred: Interactive Tutorial Module. <http://howardzzh.com/research/medical/data/nyu/index.html>. / NYU Medical Center. 2008. – Informe de Investigación

- [53] KUMAR, R.: Snakes: Active Contour Models <http://people.seas.harvard.edu/~rkumar/>. / Harvard University. 2010. – Informe de Investigación
- [54] LARUSSO, L.: Skin Cancer - Overview. En: *EBSCO Publishing Health Library*.
- [55] LEE, T.K. ; NG, V. ; GALLAGHER, R. ; COLDMAN, A. ; MCLEAN., D.: Dullrazor, Software approach to hair removal from images. En: *J. Comput. Biol. Med.* 27 (1997), p. 533–543.
- [56] LEO, G. D. ; PAOLILLO, A. ; SOMMELLA, P. ; FABBROCINI., G.: Automatic Diagnosis of Melanoma: a Software System based on the 7-Point Check-List. En: *HICSS.*, 2010.
- [57] LEO, Giuseppe D. ; FABBROCINI, Gabriella ; PAOLILLO, Alfredo ; RESCIGNO, Orsola ; SOMMELLA., Paolo: Towards An Automatic Diagnosis System for Skin Lesions: Estimation of Blue-Whitish Veil and Regression Structures. En: *6th International Multi-Conference on Systems, Signals and Devices.*, 2009, p. 1–6.
- [58] LORENTZEN, H. ; WEISMANN, K. ; SECHER, L. ; PETERSEN, C. S. ; LARSEN., F. G.: The Dermatoscopic ABCD Rule Does Not Improve Diagnostic Accuracy of Malignant Melanoma. En: *Acta Derm Venereol* 79 (1999), p. 469–472.
- [59] MAGLOGIANNIS, I. ; DOUKAS, C. N.: Overview of Advanced Computer Vision Systems for Skin Lesions Characterization. En: *IEEE Trans. Inf. Tech. Bio.* 13 (2009), p. 721–733.
- [60] MATLAB., R2008a. *Gmdistribution class*. <http://www.mathworks.com/help/toolbox/stats/gmdistributionclass.html>. 2008.
- [61] McLACHLAN, G. ; PEEL., D.: *Finite Mixture Models*. New York : John Wiley & Sons., 2000.
- [62] MELLI R, Cucchiara R.: Comparison of color clustering algorithms for segmentation of dermatological images. En: *SPIE Med Imaging*. 6144 (2006), p. 3S1–3S9.
- [63] MENDONZA, T. ; MARCIAL, A. ; VIEIRA, A. ; NASCIMENTO, J. ; SILVEIRA, M. ; MARQUES, J. ; ROZEIRA., J.: Comparison of Segmentation Methods for Automatic Diagnosis of Dermoscopy Images. En: *Image and Signal Processing: 4th International Conference.*, 2010, p. 531–540.
- [64] MENZIES, S. W. ; INGVAR, C. ; CROTTY, K. A. ; McCARTHY., W. H.: Frequency and Morphologic Charateristics of Invasive Melanoma Lacking Specific Surface Microscopic Features. En: *Arch. Dermatology* 132 (1996), p. 1178–1182
- [65] OTSU, N.: A Threshold Selection Method from Gray-Level Histograms. En: *IEEE Transactions on Systems, Man. and Cybernetics* 9 (1979), p. 62–66

- [66] PEÑA, Daniel: *Análisis de datos Multivariantes*. MCGRAW HILL., 2002
- [67] PETROU, Maria ; PETROU., Costas: *Image Processing: The Fundamentals*. John Wiley & Sons., 2010.
- [68] R2008A, MatLab. *RankFeatures*. 2008
- [69] RAHMAN, M.M. ; BHATTACHARYA., P.: An integrated and interactive decision support system for automated melanoma recognition of dermoscopic images. En: *Computerized Medical Imaging and Graphics* 34 (2010), p. 479–486.
- [70] RAJAB, M.I. ; WOOLFSON, M.S. ; MORGAN., S.P.: Application of region-based segmentation and neural network edge detection to skin lesions. En: *Computerized Medical Imaging and Graphics*. 28 (2004), p. 61–68.
- [71] RIAÑO, J. ; OCAMPO, C. ; PRIETO, F. ; SÁNCHEZ., E.: Segmentación de Imágenes Capilares Basado en Colormap. En: *9th CISCI 2010.*, 2010
- [72] ROCKOFF, A. ; LEHRER, M. S. ; HECHT, F. ; STÖPPLER., M. C.: Melanoma 101: Introduction to a Deadly Skin Cancer. / <http://www.medicinenet.com/melanoma/article.htm>. 2011. – Informe de Investigación
- [73] RUBEGNI, P. ; BURRONI, M. ; CEVENINI, G. ; PEROTTI, R. ; DELL'EVA, G. ; FIMIANI, P. Barbini M. ; ANDREASSI., L.: Digital dermoscopy analysis and artificial neural network for the differentiation of clinically atypical pigmented skin lesions: a retrospective study. En: *The Journal of Investigative Dermatology*. 119 (2002), p. 471–474.
- [74] RUIZ, et a.: A decision support system for the diagnosis of melanoma: A comparative approach. En: *Expert Systems with Applications*. 38 (2011), p. 15217–15223.
- [75] SADEGHI, Maryam ; RAZMARA, Majid ; WIGHTON, Paul ; LEE, Tim K. ; ATKINS., M. S.: Modeling the Dermoscopic Structure Pigment Network Using a Clinically Inspired Feature Set. En: *Medical Imaging and Augmented Reality - 5th International Workshop.*, 2010, p. 467–474.
- [76] ORGANIZACIÓN MUNDIAL DE LA SALUD, OMS. *Ultraviolet radiation and the INTER-SUN Programme*, Url: http://www.who.int/uv/uv_and_health/en/. 2011.
- [77] RECOMENDACIÓN CONJUNTA DE: ORGANIZACIÓN MUNDIAL DE LA SALUD, Programa de las Naciones Unidas para el Medio Ambiente Comisión Internacional de Protección contra la Radiación no I. *índice Solar UV, Guía Práctica*. 2003
- [78] SBONER, A. ; ECCHER, C. ; BLANZIERI, E. ; BAUER, P. ; CRISTOFOLINI, M. ; ZUMIANI, G. ; FORTI., S.: A Multiple Classifier System for early Melanoma Diagnosis. En: *Artificial Intelligence in Medicine*. 27 (2003), p. 29–44.

- [79] SCHAEFER, G. ; RAJAB, M. I. ; CELEBI, M. E. ; IYATOMI., H.: Colour and contrast enhancement for improved skin lesion segmentation. En: *Computerized Medical Imaging and Graphics.* 35 (2011), p. 99–104.
- [80] SCHMID., P.: Segmentation Of Digitized Dermatoscopic Images By Two-Dimensional Color Clustering. En: *IEEE transactions on medical imaging* 18 (1999), p. 164–171.
- [81] SCHMID-SAUGEON., Phillippe: Symmetry axis computation for almost-symmetrical and asymmetrical objects: Application to pigmented skin lesions. En: *Medical Image Analysis.* 4 (2000), p. 269–282.
- [82] STANGANELLI, I. *Dermoscopy*, <http://emedicine.medscape.com/article/1130783-overview#aw2aab6b4>.
- [83] STETSON, P. F. ; SOMMER, F. G. ; MACOVSKI., A.: Lesion Contrast Enhancement in Medical Ultrasound Imaging. En: *IEEE Transactions On Medical Imaging.* 16 (1997), p. 416–425.
- [84] STOLZ, W. ; RIEMANN, A. ; COGNETTA, A. B. ; PILLET, L. ; ABMAYR, W. ; HOELZEL, D. ; ET AL.: ABCD rule of dermatoscopy: a new practical method for early recognition of malignant melanoma. En: *Eur. J. Dermatol.* 4 (1994), p. 521–7.
- [85] VILLEGAS, M. P. ; JARAMILLO, F.: Comportamiento clínico, epidemiológico e histológico del melanoma maligno en el Departamento de Caldas (Colombia). En: *Rev. Soc. Col. Dermatol.* 7 (1999), p. 192:196.
- [86] WALPOLE, Ronald E. ; MYERS, Raymon H. ; MYERS., Sharon L.: *Probabilidad y Estadística Aplicada para Ingenieros.* México : Prentice Hall., 1999
- [87] WK., Pratt: *Digital Image Processing: PIKS Inside.* Hoboken, NJ: John Wiley & Sons., 2007.
- [88] XU, L. ; JACKOWSKI, M. ; GOSHTASBYA, A. ; ROSEMAN, D. ; BINES, S. ; YU, C. ; DHAWAN, A. ; HUNTLEY., A.: Segmentation of skin cancer images. En: *Image and Vision Computing.* 17 (1999), p. 65–74.
- [89] YANG, H. ; LEE, Y. ; FAN, Y. C. ; TASO., H.: A Novel Algorithm of Local Contrast Enhancement for Medical Image. En: *2007 IEEE Nuclear Science Symposium Conference.*, 2007, p. 3951–3954.
- [90] YANG, J. ; ZHANG, D. ; YANG, J.y. ; NIU., B.: Globally Maximizing, Locally Minimizing: Unsupervised Discriminant Projection with Applications to Face and Palm Biometrics. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence.* 29 (2007), p. 650–664.

- [91] YAO, Yi ; ABIDI, B. R. ; KALKA, N. D. ; SCHMID, N. A. ; ABIDI., M. A.: Improving long range and high magnification face recognition: Database acquisition, evaluation, and enhancement. En: *Computer Vision and Image Understanding.* 111 (2008), p. 111–125.
- [92] YU, Lei ; LIU., Huan: Feature Selection for High-Dimensional Data: A Fast Correlation-Based Filter Solution. En: *ICML*, 2003, p. 1–8.
- [93] ZABALLOS, P. ; CARRERA, C. ; PUIG, S. ; MALVEHY., J.: Criterios Dermatoscópicos para el Diagnóstico del Melanoma. En: *Medicina Cutánea.* 31 (2004), p. 1.
- [94] ZALAUDEK, I. ; ARGENZIANO, G. ; SOYER, H.P. ; CORONA, R. ; SERA, F. ; BLUM, A. ; BRAUN, R.P. ; CABO, H. ; FERRARA, G. ; KOPF, A.W. ; LANGFORD, D. ; MENZIES, S.W. ; PELLACANI, G. ; PERIS, K. ; SEIDENARI., S.: Three-point checklist of dermoscopy: An Open Internet Study. En: *British Journal of Dermatology* 154 (2006), p. 431–437.
- [95] ZHANG, Q.L.L. ; YOU, J. ; ZHANG, D. ; BHATTACHARYA., P.: Dark line detection with line width extraction. En: *IEEE International Conference on Image Processing.*, 2008, p. 621–624.
- [96] ZHOU., H.: An Atlas of Surface Microscopy of Pigmented Skin Lesions: Dermoscopy. / <http://howardzzh.com/research/medical/data/book/index.html>. 2008. – Informe de Investigación
- [97] ZHOU., H.: Discrimination between melanomas and nevi. <http://howardzzh.com/research/medical/data/hosei/index.html>. / Hosei University. 2008. – Informe de Investigación
- [98] ZHOU, H. ; CHEN, M. ; GASS, R. ; REHGA, J. M. ; FERRIS, L. ; HO, J. ; DROGOWSKI., L.: Feature-preserving Artifact Removal from Dermoscopy Images. En: *SPIE Medical Imaging Symposium San Diego.*, 2008, p. .
- [99] ZHOU, Huiyu ; SCHAEFER, Gerald ; CELEBI, M. E. ; IYATOMI, Hitoshi ; NORTON, Kerri-Ann ; LIU, Tangwei ; LIN., Faquan: Skin lesion segmentation using an improved snake model. En: *32nd Annual International Conference of the IEEE EMBS Buenos Aires, Argentina*, 2010, p. 1974–1977.
- [100] ZHOU, Huiyu ; SCHAEFER, Gerald ; CELEBI, M. E. ; LIN, Faquan ; LIU., Tangwei: Gradient vector flow with mean shift for skin lesion segmentation. En: *Computerized Medical Imaging and Graphics* 35 (2011), p. 121–127.